

# Übungen: Quantitative Methoden - Statistik mit R

Bodo Sturm, HTWK Leipzig

01.09.2026

## Zu den Übungen

Zu jedem Kapitel in der Vorlesung gibt es ein Aufgabenblatt. Die Aufgaben sind nach dem Abschluss des Kapitels selbstständig zu lösen. In der Veranstaltung werden Fragen beantwortet und besonders schwierige Aufgaben ggf. kurz besprochen (max. 30 min.). Nach der Übung werden im OPAL Lösungshinweise hinterlegt. Bei Fragen zu den Aufgaben melden Sie sich bitte per email unter [bodo.sturm@htwk-leipzig.de](mailto:bodo.sturm@htwk-leipzig.de).

### Aufgabenblatt: Basics in R (alle Module)

**Aufgabe 1: Tanken** Beim Tanken eines Autos wurde der Kilometerstand notiert. Sieben dieser Werte lauten:

65311, 65624, 65908, 66219, 66821, 67145, 67447

Speichern Sie diese Daten in einer Variable `km`. Wenden Sie darauf die Funktion `diff()` an. Nutzen Sie ggf. die Hilfe für `diff()`. Was ist das Ergebnis? Interpretieren Sie das Ergebnis der Befehle `mean(km)` und `mean(diff(km))`.

**Aufgabe 2: Zahlenreihen** Speichern Sie die folgenden Daten jeweils in einer Variablen ab:

- a) 1, 2, 3, 4, 5, 6, 7, 8, 9, 10
- b) 1, 4, 9, 16, 25, 36, 49, 64, 81, 100
- c) 1, 1/2, 1/3, 1/4, 1/5, 1/6, 1/7, 1/8, 1/9, 1/10
- d) 1, 8, 27, 64, 125, 216, 343, 512, 729, 1000
- e) 1964, 1965, . . . , 2003
- f) 0, 25, 50, 75, 100, . . . , 975, 1000

Verwenden Sie `c()` nur, wenn `seq()` oder ein anderer Befehl nicht funktioniert! Achten Sie dabei auf Regelmäßigkeiten in den Daten.

**Aufgabe 3: Fahrzeiten** Eine Studentin hatte an den letzten 10 Werktagen die folgenden Fahrzeiten (in Minuten) zur HTWK:

17, 16, 20, 24, 22, 15, 21, 15, 17, 22

Geben Sie diese Werte in R ein und definieren Sie eine Variable `zeit`.

- a) Benutzen Sie die Funktionen `max()`, `mean()` und `min()`, um die längste, durchschnittliche und kürzeste Fahrzeit herauszufinden.
- b) Gibt es einen Unterschied zwischen dem Median und dem arithmetischen Mittel?
- c) Die 24 hat sich als Fehler herausgestellt. Es waren 18 Minuten. Ändern Sie die Variable in R und berechnen Sie die durchschnittliche Fahrzeit neu.

**Aufgabe 4: Rechner** Berechnen Sie die folgenden Ausdrücke mit R:  $1 + 2(3 + 4)$ ,  $4^3 + 3^{(2+1)}$ ,  $\sqrt{((4+3)(2+1))}$ ,  $(\frac{1+2}{3+4})^2$ ,  $\log(1.05) - \log(1)$

**Aufgabe 5: Vektoreigenschaft** Der folgende kleine Datensatz sei gegeben: 5, 4, 10, 8, 2

- Definieren Sie diese Daten als Datenvektor  $\mathbf{x}$  in R.
- Berechnen Sie das Quadrat jeder Zahl.
- Subtrahieren Sie 6 von jeder Zahl.
- Subtrahieren Sie 9 von jeder Zahl und quadrieren Sie das Ergebnis.

Hinweis: Nutzen Sie die Vektoreigenschaft von Funktionen.

**Aufgabe 6: Marathon I** Die Variable `time` im Datensatz `data.nym.2002.csv` enthält die Finisher-Zeit von zufällig ausgewählten Teilnehmern des 2002 New York City Marathon (vgl. auch das entsprechende html-Dokument).

- Wie viele Zeiten enthält der Datensatz?
- Was war die schnellste Zeit? Rechnen Sie diese Zeit in Stunden und Minuten um.
- Was war die langsamste Zeit? Rechnen Sie diese Zeit in Stunden und Minuten um.
- Wie viel Prozent aller Teilnehmer laufen unter 3h 30min?

**Aufgabe 7: Patienten** Lesen Sie den Datensatz `patients2.csv` mit der Funktion `read.csv()` ein.

- Welche Variablen gibt es?
- Berechnen Sie das mittlere Alter aller Patienten.
- Berechnen Sie das mittlere Gewicht aller Frauen und das mittlere Gewicht aller Männer.
- Berechnen Sie den Median für die Körpergröße getrennt nach Geschlecht.

**Aufgabe 8: Funktionen** Erzeugen Sie einen Vektor  $\mathbf{x}$  mit ganzen Zahlen im Intervall  $[0, 1000]$  und stellen Sie folgende Funktionen graphisch dar.

- $Y = \sqrt{x}$
- $Y = \log(x)$
- $Y = 10x - x^2/100$

## Aufgabenblatt: Qualitative Daten (alle Module)

**Aufgabe 1: Kneipe** Eine Befragung von 25 Gästen in einer Kneipe ergab die Daten in `kneipe.csv`. Dabei ist `ID` die Nummer der/des Befragten. Erhoben wurden die Merkmale **Getraenk** mit den Ausprägungen {Bier, Mix, Wein, alkohfrei} und Geschlecht. Letztere wurde zur Variable **Frau** umkodiert mit den Ausprägungen {0, 1}, wobei 0 = Mann und 1 = Frau.

- Ermitteln Sie die Häufigkeitsverteilung und den Modus für das Merkmal **Getraenk**. Stellen Sie die Verteilung graphisch dar.
- Erstellen Sie die Kontingenztafel für die gemeinsame Verteilung beider Merkmale (mit Randverteilung).
- Wie viel Prozent aller Frauen konsumieren alkoholfreie Getränke? Welcher Anteil der Befragten, die Wein konsumieren, sind Frauen?
- Treffen Sie eine Aussage darüber, ob beide Merkmale statistisch unabhängig voneinander sind.

**Aufgabe 2: Autos** Betrachten Sie den Datensatz `Cars93.csv` (vgl. auch das entsprechende html-Dokument).

- a) Erstellen Sie die absolute Häufigkeitsverteilung für **Type**. Welche Klasse ist der Modus der Verteilung?
- b) Erstellen Sie ein Barplot für die relative Häufigkeitsverteilung für **Type**. Achten Sie auf die korrekten Achsenbezeichnungen.
- c) Erstellen Sie eine Kontingenztafel für **Origin** und **Type**. Berechnen und interpretieren Sie folgende bedingte relative Häufigkeiten:  $\text{relH}(\text{Type} = \text{Compact} | \text{Origin} = \text{USA})$ ,  $\text{relH}(\text{Type} = \text{Compact} | \text{Origin} = \text{non-USA})$ ,  $\text{relH}(\text{Origin} = \text{USA} | \text{Type} = \text{Compact})$ ,  $\text{relH}(\text{Origin} = \text{non-USA} | \text{Type} = \text{Compact})$ .

Hinweis: Die Notation für die relative Häufigkeit von A unter der Bedingung B ist  $\text{relH}(A|B)$ .

**Aufgabe 3: Lohn und Bildung I** Lesen Sie den Datensatz `wage1.csv` (erläutert in `wage1.txt`) ein.

- a) Wieviel Prozent aller Männer bzw. aller Frauen sind verheiratet?
- b) Wieviel Prozent aller Männer bzw. aller Frauen arbeiten in der Bauindustrie?
- c) Erstellen Sie ein Säulendiagramm/Barplot für die absolute Häufigkeitsverteilung der Variable **educ** (Jahre in Bildung). Interpretation. Wie viel Prozent der Teilnehmer haben mehr als 12 Jahre Bildung?

## Aufgabenblatt: Quantitative Daten (alle Module)

**Aufgabe 1: Studenten I** Diese Aufgabe bezieht sich auf den Datensatz `student.csv`. Der Datensatz ist in `student.txt` erklärt.

- a) Zeichnen Sie die empirische Verteilungsfunktion für das Merkmal **height** getrennt nach Männern und Frauen. Wie viel Prozent der Männer (Frauen) sind größer als 170 cm?
- b) Wie viel Prozent der Männer (Frauen) essen mindestens fünf Mal am Tag eine Portion Obst oder Gemüse (Empfehlung der DGE)?

**Aufgabe 2: Temperatur** Der Datensatz `normtemp.csv` (aus dem R Paket `UsingR`) enthält Angaben von 130 gesunden, zufällig ausgewählten Personen. Die Variable **temperature** enthält die Körpertemperatur (in Grad Fahrenheit). Vgl. auch das entsprechende html-Dokument.

- a) Rechnen Sie die Temperaturangaben in Grad Celsius um. Erstellen Sie ein Histogramm. Kurze Interpretation.
- b) Schätzen Sie anhand des Histogramms die mittlere Körpertemperatur und prüfen Sie Ihre Schätzung mit `mean()`.

**Aufgabe 3: Marathon II** Die Variable **time** im Datensatz `data.nym.2002.csv` (aus dem R Paket `UsingR`) enthält die Finisher-Zeit von zufällig ausgewählten Teilnehmern des 2002 New York City Marathon.

- a) Wie viel Prozent der Teilnehmer liefen unter 3 Stunden?
- b) Welche Zeit trennt die top 10% vom Rest? Welche Zeit die top 25%?
- c) Unterhalb welcher Zeit liegen die 10% langsamsten Läufer?
- d) Erwarten Sie eine symmetrische Verteilung? Erstellen Sie ein Histogramm und beschreiben Sie die Verteilung? Erklärung.
- e) Bestimmen Sie den Median und das arithmetische Mittel der Zeiten.
- f) Berechnen Sie die Standardabweichung der Zeit. Angenommen ein Läufer braucht 5 Stunden. Wie viele Standardabweichungen liegt diese Zeit über dem Mittelwert?
- g) Erstellen Sie Verteilungsfunktion für die Zeit für Männer und Frauen in einer Abbildung. Interpretation.

**Aufgabe 4: Studenten II** Diese Aufgabe bezieht sich auf den Datensatz `student.csv`. Der Datensatz ist in `student.txt` erklärt. Zeichnen Sie einen Boxplot für das Merkmal `weight` getrennt für Frauen und Männer. Erklären Sie die Abbildung.

**Aufgabe 5: MPG und Type** Betrachten Sie den Datensatz `Cars93.csv` (aus dem R Paket MASS). Erstellen Sie einen Boxplot für `MPG.highway` für die Ausprägungen von `Type`. Interpretation. Identifizieren Sie die Ausreißer für `MPG.highway` in diesem Boxplot.

## Aufgabenblatt: Assoziation und Korrelation (alle Module)

**Aufgabe 1: Klimawandel** Laden Sie den Datensatz `annualTemp.csv`. Erläuterung der Daten (vgl. <https://data.giss.nasa.gov/gistemp/>): GLOBAL: Land-Ocean Temperature Index in degrees Celsius, base period: 1951-1980. Yr: Year

- Stellen Sie die globale Temperaturentwicklung in einem geeigneten Liniendiagramm graphisch dar. Achten Sie auf eine korrekte Bezeichnung der Achsen und heben Sie die Null-Linie auf der y-Achse geeignet hervor.
- Beschreiben Sie die Abbildung möglichst knapp.

**Aufgabe 2: Inflation und BIP** Lesen Sie den Datensatz `Makrodaten.csv` ein. Die Variablen `VPI_D`, `BIP_D` und `KI_Y_D` beziehen sich auf Deutschland und `Y_US` auf die USA. Die Daten sind in `Makrodaten.txt` erklärt.

- Nutzen Sie `diff()`, um die jährliche Wachstumsrate des VPI in Prozent („Inflationsrate“) seit 1992 für Deutschland zu berechnen. Zur Erinnerung:  $\pi_t = \frac{VPI_t - VPI_{t-1}}{VPI_{t-1}}$  (vgl. Makro-Vorlesung).
- Berechnen Sie den BIP-Deflator (2020 = 100) seit 1992 für Deutschland. Zur Erinnerung:  $De_{0,t} = \frac{KI_{BIP,0,t}}{KI_{Y,0,t}}$  (vgl. Makro-Vorlesung). Wie ist der aktuellste Wert des BIP-Deflators zu interpretieren? Um wieviel Prozent sind die Preise im BIP von 2010 im Vergleich zum letzten Berichtsjahr angestiegen?
- Stellen Sie die Inflationsrate basierend auf dem VPI aus a) und die Wachstumsrate des BIP-Deflators aus b) seit 1992 graphisch dar. Interpretation.
- Stellen in einer Abbildung den Kettenindex des realen BIP für Deutschland und für die USA dar (jeweils mit 1991 = 100). Interpretation. Hinweis: Der Kettenindex des realen BIP für die USA kann einfach aus `Y_US` berechnet werden, in dem Sie die Zeitreihe durch den Wert für 1991 dividieren und mit 100 multiplizieren.

**Aufgabe 3: Hypothekendarlehen** Die Aufgabe bezieht sich auf den Datensatz `interest_rates_and_mortgages.csv`. Seit 1980 schwanken die Zinsen für Hypothekendarlehen in den USA im Bereich von 6% bis 14%. Untersucht werden soll die Frage, ob es einen Zusammenhang zwischen der Zinsrate für Hypothekendarlehen (in %) und dem Volumen an Darlehen (in Mio. \$) gibt.

- Erstellen Sie ein Streudiagramm der Variablen Zinsrate (`Interest.Rate`, in %) und Hypothekendarlehen (`Total.Mortgages`, in Mio. \$). Beschreiben Sie den Zusammenhang zwischen beiden Variablen.
- Berechnen und interpretieren Sie den Pearson-Korrelationskoeffizienten.
- Nehmen Sie an, in einem weiteren Jahr sei der Zins 11% und das Darlehensvolumen sei \$250 Millionen. Welchen Effekt hat die Einbeziehung dieses Jahres auf die Korrelation?

**Aufgabe 4: Autos** Betrachten Sie den Datensatz `Cars93.csv`.

- Erstellen Sie ein Streudiagramm für die Variablen `Horsepower` und `MPG.highway`. Berechnen Sie  $r_{XY}$ . Interpretation.

- b) Erstellen Sie ein Streudiagramm für die Variablen `Weight` und `Horsepower`. Berechnen Sie  $r_{XY}$ . Interpretation.

**Aufgabe 5: Okun's Law für die USA** Laden Sie den Datensatz `Makrodaten.csv`. Die Variable `gY_US` ist das reale BIP-Wachstum pro Jahr in den USA in Prozent. Die Variable `u_US` ist die Arbeitslosenquote pro Jahr in den USA in Prozent. Vgl. `Makrodaten.txt`. Betrachten Sie den Zeitraum 1980 bis 2023.

- Berechnen Sie mit `diff()` die Veränderung der Arbeitslosenquote in Prozentpunkte und speichern Sie diese Werte als Variable `delta_u` ab.
- Erstellen Sie ein Streudiagramm mit dem realen BIP-Wachstum in Prozent auf der x-Achse und der Veränderung der Arbeitslosenquote in Prozentpunkten auf der y-Achse. Berechnen Sie den Pearson-Korrelationskoeffizienten. Interpretation.
- Identifizieren die drei Jahre mit dem stärksten prozentualen Rückgang des BIP. Erklärung.

**Aufgabe 6: Lebensmittel** Verschiedene Produkte eines Lebensmittels wurden auf Haltbarkeit und Geschmack getestet. Um die Produkte in ihrer Bewertung zu ordnen, wurde folgendes Schema verwendet: {sehr gut, gut, ausreichend, ungenügend}.

| Produkt | Geschmack   | Haltbarkeit |
|---------|-------------|-------------|
| A       | sehr gut    | ausreichend |
| B       | sehr gut    | ungenügend  |
| C       | gut         | ausreichend |
| D       | ausreichend | gut         |
| E       | gut         | gut         |
| F       | ungenügend  | gut         |
| G       | sehr gut    | ungenügend  |
| H       | gut         | gut         |

Gibt es einen Zusammenhang zwischen Haltbarkeit und Geschmack? Berechnen Sie den passenden Korrelationskoeffizienten und interpretieren Sie das Ergebnis.

**Aufgabe 7: HTWK** Beim Tag der offenen Tür an der HTWK Leipzig wurden Teilnehmer danach befragt, ob sie den neuen HTWK-Kalender kaufen würden. Bei der Befragung von 1415 Personen ergaben sich Daten für die Merkmale `Campus-Gruppe` und `Kaufwahrscheinlichkeit`. Die Daten finden sich im Datensatz `Kalender.csv` mit den Merkmalen `Gruppe` und `Kaufen`.

- Erstellen Sie eine Kontingenztafel für beide Merkmale (mit Randverteilung).
- Welcher Anteil der Befragten sind Alumni? Welcher Anteil der Befragten wird mit hoher Wahrscheinlichkeit kaufen?
- Welcher Anteil der Befragten, die mit hoher Wahrscheinlichkeit kaufen, sind Alumni?
- Welcher Anteil der Alumni wird mit hoher Wahrscheinlichkeit kaufen?
- Ermitteln Sie die Verteilung für das Merkmal `Campus-Gruppe` unter der Bedingung, dass eine hohe Kaufwahrscheinlichkeit vorliegt.
- Gibt es aus der Studie Evidenz dafür, dass man sich beim Verkauf des Kalenders auf eine bestimmte Gruppe konzentrieren sollte? Berechnen und interpretieren Sie den korrigierten Kontingenzkoeffizienten  $KK^*$ .

## Aufgabenblatt: Regression (nur W501 und W873)

**Aufgabe 1: Autos** Betrachten Sie den Datensatz Cars93.csv.

- Schätzen Sie die lineare Regression  $MPG.highway(Horsepower)$ . Interpretieren Sie Ihre Schätzung. Was ist der erwartete MPG-Wert für ein Auto mit 225 PS?
- Schätzen Sie das lineare Modell  $MPG.highway(Weight)$ . Finden Sie den erwarteten MPG-Wert für einen Hummer H2 (Gewicht 6400 Pfund) und einen MINI Cooper (2524 Pfund).

Hinweis: Wir arbeiten hier mit dem linearen Modell. Ggf. wäre auch eine log-Transformation sinnvoll. Die Interpretation im linearen Modell ist aber sinnvoller: Reichweite bzw. Energieeffizienz wird hier in MPG gemessen und Motorenstärke in PS (eine Nutzung von Prozent wäre unüblich).

**Aufgabe 2: Körpergröße** Häufig wird die erwartete Körpergröße eines Erwachsenen basierend von der Körpergröße mit zwei Jahren berechnet. Schätzen Sie den linearen Zusammenhang basierend auf dem folgenden Datensatz:

| Beobachtung          | 1     | 2     | 3     | 4     | 5     | 6     | 7     | 8     |
|----------------------|-------|-------|-------|-------|-------|-------|-------|-------|
| Mit 2 Jahren (in cm) | 99.6  | 76.2  | 81.3  | 86.4  | 88.9  | 91.4  | 91.4  | 76.2  |
| Erwachsen (in cm)    | 180.3 | 160.0 | 160.0 | 170.2 | 172.7 | 172.7 | 177.8 | 162.6 |

- Gegeben die Daten und der geschätzte lineare Zusammenhang, was ist die erwartete Körpergröße für einen Erwachsenen, der mit zwei Jahren 83.8 cm groß war?
- Lassen Sie sich die Fehlerterme ausgeben und erstellen Sie ein Histogramm dieser Werte. Berechnen Sie Median und arithmetisches Mittel der Fehlerterme.
- Berechnen und Interpretieren Sie das  $R^2$  der Regression. Zeigen Sie, dass die Varianz der abhängigen Variablen gleich der Summe der Varianz der Werte auf der Regressionsgeraden und der Varianz der Fehlerterme ist.

**Aufgabe 3: PM2.5-Konzentration und p.c. GDP** Betrachten Sie den Datensatz GDPpc\_pm\_live.csv (erläutert in GDPpc\_pm\_live.txt).

- Betrachten Sie die Variablen GDPpc und pm mit `summary()`. Interpretation der Lagemaße.
- Bestimmen Sie die top 3 der reichsten bzw. ärmsten Länder sowie die top 3 der saubersten und schmutzigsten Länder.
- Berechnen Sie die Regressionsgerade für das lineare Modell  $\widehat{pm} = \beta_0 + \beta_1 GDPpc$ . Stellen Sie die Regressionsgerade graphisch im Streudiagramm dar.
- Prüfen Sie die Annahmen der linearen Regression. Welche Annahmen der linearen Regression sind verletzt?
- Schätzen Sie das Modell  $\widehat{pm} = \beta_0 + \beta_1 \log(GDPpc)$ . Interpretieren Sie den Anstiegsparemeter.
- Stellen Sie das Modell aus e) im Streudiagramm für GDPpc und pm dar. Welche PM2.5-Konzentration prognostiziert das Modell für ein GDP p.c. von 10000 USD? Wie verändert sich die PM2.5-Konzentration, wenn das GDP p.c. um 10% steigt?
- Diskutieren Sie die Modellannahmen für das Modell  $\widehat{pm} = \beta_0 + \beta_1 \log(GDPpc)$ . Welche Option haben Sie?

**Aufgabe 4: Lohn und Bildung II** Lesen Sie den Datensatz wage1.csv (erläutert in wage1.txt) ein.

- Betrachten Sie die Variablen wage und educ mit `summary()`. Interpretation der Lagemaße.

- b) Berechnen Sie die Regressionsgerade für das lineare Modell  $\widehat{wage} = \beta_0 + \beta_1 educ$ . Stellen Sie die Regressionsgerade graphisch im Streudiagramm dar und interpretieren Sie den Anstiegsparemeter  $\beta_1$ . Berechnen und interpretieren Sie das  $R^2$  dieser Regression.
- c) Prüfen Sie die Annahmen der linearen Regression. Stellen Sie hierzu auch Fehlerterme und prognostizierte Werte in einem Streudiagramm dar. Welche Annahmen der linearen Regression sind verletzt?
- d) Führen Sie die Schritte b) und c) für das Modell  $\widehat{\log(wage)} = \beta_0 + \beta_1 educ$  durch.

**Aufgabe 5: CEO Verdienst** Betrachten Sie den Datensatz `ceosal.csv` (erläutert in `ceosal.txt`).

- a) Betrachten Sie die Variablen `salary` und `sales` mit `summary()`. Interpretation der Lagemaße.
- b) Berechnen Sie die Regressionsgerade für das lineare Modell  $\widehat{salary} = \beta_0 + \beta_1 sales$ . Stellen Sie die Regressionsgerade graphisch im Streudiagramm dar und interpretieren Sie den Anstiegsparemeter  $\beta_1$ . Berechnen und interpretieren Sie das  $R^2$  dieser Regression.
- c) Prüfen Sie die Annahmen der linearen Regression. Stellen Sie hierzu auch Fehlerterme und prognostizierte Werte in einem Streudiagramm dar. Welche Annahmen der linearen Regression sind verletzt?
- d) Führen Sie die Schritte b) und c) für das Modell  $\widehat{\log(salary)} = \beta_0 + \beta_1 \log(sales)$  durch.

**Aufgabe 6: Modellvergleich** Im Datensatz `PandQ.csv` gibt es die Variablen `Q` (Menge in Einheiten) und `P` (Preis pro Einheit in €). Sie vermuten eine Abhängigkeit zwischen beiden Variablen mit  $Q = f(P)$ .

- a) Schätzen Sie Modell 1 mit  $Q = \beta_0 + \beta_1 P$  und Modell 2 mit  $\log(Q) = \beta_0 + \beta_1 \log(P)$ .
- b) Interpretieren Sie den Anstiegsparemeter  $\beta_1$  sowohl für Modell 1 als auch für Modell 2. Interpretieren Sie das  $R^2$  für Modell 2.
- c) Welches Modell würden Sie bevorzugen? Erläuterung.
- d) Erläutern Sie die Methode, mit der die Regressionsgerade bestimmt wird. Gehen Sie dabei auch auf die Eigenschaften der Residuen ein.

**Aufgabe 7: Investitionen für Deutschland** Laden Sie den Datensatz `Investitionen.csv`. Die Variable `INV` gibt die realen Bruttoanlageinvestitionen in Mrd. EUR pro Quartal in Deutschland an (Quelle: Destatis). Die Variable `ZINS` gibt den Effektivzins für Unternehmenskredite in Prozent/Jahr an (Quelle: Bundesbank).

- a) Beschreiben Sie beide Zeitreihen kurz. Nutzen Sie für eine graphische Darstellung den Befehl `ts()`. Zum Beispiel für `INV`: Erzeugen Sie eine neue Variable mit `ts(data$INV, frequency = 4, start = c(2003, 1))`. Diese Variable kann man dann mit `plot()` darstellen.
- b) Schätzen Sie ein lineares Regressionsmodell mit `INV` als abhängige Variable und `ZINS` als unabhängige Variable. Erstellen Sie ein Streudiagramm beider Variablen und fügen Sie die Regressionsgerade in das Streudiagramm ein. Interpretation.

## Aufgabenblatt: Zufallsvariablen und zentraler Grenzwertsatz (alle Module)

**Aufgabe 1: Normalverteilung** Ein qq-plot ist ein exploratives, grafisches Werkzeug, in dem die Quantile einer Variablen gegen die Quantile der  $N(0,1)$ -Verteilung in einem Streudiagramm abgetragen werden. Ein solcher Plot ist eine sehr gute Methode, um zu erkennen, ob eine Verteilung ungefähr normalverteilt ist. Ziehen Sie aus den symmetrischen Verteilungen `uniform(min=0,max=1)`, `N(2,4)` und `t`-Verteilung mit drei Freiheitsgraden jeweils eine Zufallsstichprobe mit  $n=100$ . Erstellen Sie jeweils drei qq-plots. Vergleichen und interpretieren Sie die drei Plots.

Hinweis: Setzen Sie `set.seed(4)`.

**Aufgabe 2: Mathetest** Beim Mathematik ACT Test (<http://www.actstudent.org/>) sei das arithmetische Mittel für alle High School Absolventen, die diesen Test absolviert haben, 20.6 Punkte mit einer Standardabweichung von 5.5 Punkte. Die Beobachtungen folgen approximativ einer Normalverteilung.

- Welcher Prozentsatz erreicht die Bestehensgrenze von 22 Punkte oder besser?
- Wenn eine Mio. Absolventen den Test absolvieren, wie viele Teilnehmer fallen zusätzlich durch, wenn die Bestehensgrenze von 22 Punkte oder mehr auf 23 Punkte oder mehr angehoben wird?

Hinweis: Nutzen Sie die Funktion `pnorm()` zur Bestimmung der Verteilungsfunktion der Standardnormalverteilung.

**Aufgabe 3: Befragung** Angenommen, eine Population ist indifferent hinsichtlich der Durchführung eines Projektes ( $P = 0.5$ ). Eine Zufallsauswahl von 1000 Teilnehmern wird gezogen.

- Wie hoch ist die Wahrscheinlichkeit, dass es in der Zufallsstichprobe 550 oder mehr Stimmen für das Projekt gibt? Nutzen Sie die Approximation der Normalverteilung.
- Welcher Grenzwertsatz liegt Ihren Berechnungen zugrunde? Erläuterung.

**Aufgabe 4: Dichtefunktionen** Stellen Sie die Dichte der  $N(-2,1)$ -Verteilung, der  $t$ -Verteilung mit  $df=4$  und der Rechteckverteilung in  $[-4,3]$  in einer gemeinsamen Abbildung inkl. einer Legende dar. Nutzen Sie den `curve()` Befehl.

**Aufgabe 5: Chi2-Verteilung** Erstellen Sie mit `curve()` die Dichtefunktion der Chi2-Verteilung mit 3, 10, 30 und 100 Freiheitsgraden ( $df$ ). Was stellen Sie fest? Berechnen Sie jeweils das 95%-Quantil der Chi2-Verteilung mit  $df = 3, 10, 30$  und 100.

**Aufgabe 6: Flächen unter der Dichte** Berechnen Sie mit R folgende Wahrscheinlichkeiten  $P$ . Stellen Sie dazu die Dichtefunktion zunächst graphisch dar und bestimmen Sie dann die Fläche unter der Dichte über die Verteilungsfunktion (gehen Sie von stetigen Funktionen aus).

- $P(4 < X < 7)$  wenn  $X \sim N(5, 2)$
- $P(4 < X < 7)$  wenn  $X \sim \text{uniform}(min = 3, max = 8)$
- $P(0 < X < 2)$  wenn  $X \sim T_{df=4}$
- $P(-\infty < X < -2)$  wenn  $X \sim T_{df=4}$
- $P(-\infty < X < -2)$  wenn  $X \sim N(0, 1)$
- $P(0 < X < 3)$  wenn  $X \sim \chi^2_{df=4}$

**Aufgabe 7: Probleme** Wie lösen Sie folgende Probleme mit R?

- Sie suchen das 97.5%-Quantil der  $t$ -Verteilung mit 23 Freiheitsgraden.
- Sie wollen 100 Zufallszahlen aus der  $N(2,6)$ -Verteilung generieren.
- Sie wollen die Dichtefunktion der  $N(0,1)$ -Verteilung im Intervall  $[-4,4]$  graphisch darstellen gemeinsam mit der  $t$ -Verteilung mit 23 Freiheitsgraden.
- Sie wollen für  $X \sim N(3, 2)$  die Wahrscheinlichkeit  $P(-0.92 < X < 6.92)$  berechnen. Welche Wahrscheinlichkeit können Sie erwarten?

**Aufgabe 8 (fakultativ): Simulation** Angenommen Sie haben 10 Würfel (= Stichprobengröße), die Sie 100 Mal gleichzeitig werfen (= Zahl Wiederholungen).

- Simulieren Sie dieses Zufallsexperiment mit R. Berechnen Sie für jeden Versuch das arithmetische Mittel der Augenzahlen und erstellen Sie ein Histogramm.
- Um welchen Wert ist das Histogramm symmetrisch?
- Welcher Grenzwertsatz liegt Ihren Beobachtungen zugrunde? Erläuterung.

Hinweis: Nutzen Sie `sample()`, um eine Zufallsstichprobe zu ziehen.

**Aufgabe 9 (fakultativ): Zentraler Grenzwertsatz** Für welches  $n$  ist  $\bar{X}$  annähernd normalverteilt, wenn jedes  $X_i$  gleichverteilt ist mit  $uniform(0, 1)$ ? Lassen Sie mehrere Simulationen für unterschiedliche  $n$  laufen und entscheiden Sie, ab wann die Stichprobenverteilung annähernd normalverteilt ist.

Hinweis: Nutzen Sie `qqnorm()`.

## Aufgabenblatt: Inferenz für qualitative Daten (alle Module)

**Aufgabe 1: Obama** Gallup Poll hat US-Amerikaner im September 2010 in einer Umfrage befragt, ob sie bei der nächsten Präsidentenwahl Barack Obama wählen. Die Befragung basiert auf einer Zufallsauswahl von 1003 US-Bürgern. 555 Teilnehmer antworteten „Ja. Ich werde für Obama stimmen“.

- Berechnen Sie ein 95%-Konfidenzintervall für den wahren Anteil der US-Bürger, die für Obama stimmen. Interpretieren Sie das Intervall.
- Ein Mitarbeiter des Re-election Teams des Präsidenten möchte mit höherer Sicherheit wissen, in welchem Intervall der wahre Anteil der Stimmberechtigten liegt. Berechnen Sie ein 99%-Konfidenzintervall. Erläutern Sie den Unterschied zu a).
- Erläutern Sie generell die Möglichkeiten, um mit einem Konfidenzintervall für den wahren Anteilswert zu einer präziseren Aussage mit einem kleineren Margin of Error zu gelangen.
- Angenommen, Sie haben keine Erwartung hinsichtlich des Stichprobenanteils. Berechnen Sie die notwendige Zahl an Befragten in einer Zufallsstichprobe, um ein 98%-Konfidenzintervall mit einem absoluten Fehler von maximal  $\pm 3$  Prozentpunkte zu erhalten.

**Aufgabe 2: Grexit** Angenommen, im Juni 2015 lag der Anteil der Deutschen, die einem Grexit positiv gegenüberstehen bei 40%. Bei einer aktuellen Befragung (Juli 2015) von 1200 zufällig ausgewählten Wahlberechtigten in Deutschland geben 43.50% an, dass sie einen Grexit positiv bewerten. Hat sich die Zustimmung in der Bevölkerung zum Grexit seit Juni 2015 signifikant erhöht? Das Signifikanzniveau sei 5%.

- Stellen Sie die Hypothesen für einen Hypothesentest auf, um die o.g. Frage beantworten zu können.
- Erläutern Sie kurz die Annahmen für den Hypothesentest und prüfen Sie die entsprechenden Bedingungen.
- Wie lässt sich der Hypothesentest in R umsetzen? Erläuterung.
- Angenommen, Sie erhalten einen p-value = 0.007234. Wie ist dieser Wert zu interpretieren? Wie lautet Ihre Schlussfolgerung?
- Diskutieren Sie die Konzepte der statistischen und ökonomischen Signifikanz anhand des Beispiels.

**Aufgabe 3: Zu wenig Statistik** Bei einer Befragung von 680 zufällig ausgewählten Master-Absolventen in Deutschland geben 420 an, dass sie der Aussage „Ich hatte zu wenig Statistik im Studium“ zustimmen. Sie sind für die Auswertung verantwortlich und wollen ein Konfidenzintervall für den wahren Anteilswert in der Grundgesamtheit berechnen.

- a) Wie lässt sich der folgende R Output erzeugen? (... = gelöscht, hier nicht relevant)

```
1-sample proportions test with continuity correction
data: 420 out of 680, ...
...
98 percent confidence interval:
0.5727812 0.6606237
sample estimates:
p
0.6176471
```

- b) Geben Sie die korrekte Interpretation des o.g. Konfidenzintervalls an. Wie groß ist der absolute Fehler?  
c) Sie wollen mit dem Konfidenzintervall eine genauere Aussage treffen. Was können Sie tun?

**Aufgabe 4: Heimvorteil** Ein Datensatz zur US Baseball Liga der Saison 2006 zeigt, dass die Heimmannschaft in 1327 Spielen gewonnen hat. Insgesamt fanden 2429 Spiele statt. Können wir aus den Daten schließen, dass die Heimmannschaft einen Vorteil hat? Beantworten Sie diese Frage mit einem Hypothesentest. Gehen Sie von einem 5% Signifikanzniveau aus. Diskutieren Sie die Konzepte der statistischen und ökonomischen Signifikanz anhand des Beispiels.

**Aufgabe 5: Umfrage** Über das Jahr 2007 wurden in den USA mehrere Befragungen zur Einschätzung der zukünftigen ökonomischen Lage durchgeführt. Im Mittel gaben 20% der Befragten an, dass sie optimistisch hinsichtlich der zukünftigen ökonomischen Lage sind. Im Januar 2008 wurden zufällig 2590 Wahlberechtigte ausgewählt und nur 13% gaben an, dass sie optimistisch sind. Ist dies Evidenz dafür, dass weniger US-Bürger optimistisch hinsichtlich der zukünftigen ökonomischen Lage sind?

- a) Erstellen Sie die passenden Hypothesen.  
b) Prüfen Sie, ob die Bedingungen für einen Hypothesentest erfüllt sind.  
c) Führen Sie einen Hypothesentest durch. Das Signifikanzniveau sei 5%. Ermitteln Sie den p-value und interpretieren Sie diesen Wert im Kontext.  
d) Diskutieren Sie die Konzepte der statistischen und ökonomischen Signifikanz anhand des Beispiels.

**Aufgabe 6: Jury-Auswahl** Man weiß, dass in einem US-Bundesstaat 19% der Wahlberechtigten Hispanics sind. Als Jury-Mitglieder für ein Gerichtsverfahren wurden 72 Wahlberechtigte ausgewählt, von denen aber nur 10 Hispanics sind. Damit sind Hispanics in der Stichprobe offensichtlich unterrepräsentiert. Kann dies Zufall sein oder hat es hier eine unfaire Bevorzugung von Nicht-Hispanics gegeben? Beantworten Sie diese Frage mit einem Hypothesentest.

Hinweis: Eine faire Auswahl liegt hier vor, wenn der Stichprobenanteilswert nicht überraschend niedrig unter dem wahren Anteilswert liegt. Wählen Sie ein Signifikanzniveau von 5%.

**Aufgabe 7: Statistische Signifikanz** Nutzen Sie den Befehl `prop.test()` und zeigen Sie für einen oberseitigen Test mit  $H_0: p = 0.5$  vs.  $H_A: p > 0.5$  und den Stichprobengrößen  $n = 10, 100, 1000$  und  $10000$  wie groß der Stichprobenanteilswert  $h$  sein muss, damit man zu einem p-value  $< 5\%$  die Nullhypothese verwirft. Geben Sie die Werte für  $h$  in Prozent an. Interpretation.

**Aufgabe 8: Betriebliches Gesundheitsmanagement** In einem Industrieunternehmen untersucht man die Verteilung der Ausschussteile über die fünf Wochentage Montag bis Freitag. In der Vergangenheit war es so, dass 50% aller Ausschussteile montags anfielen, 20% dienstags und der Rest gleichverteilt war auf die übrigen drei Wochentage. Nach der Einführung eines Betrieblichen Gesundheitsmanagements möchte man wissen, ob sich diese Verteilung geändert hat. Die folgende Tabelle zeigt die Zahl der Ausschussteile pro Wochentag in einer Zufallsstichprobe mit  $n = 100$ .

| Wochentag | Zahl Ausschussteile |
|-----------|---------------------|
| Mo        | 46                  |
| Di        | 14                  |
| Mi        | 14                  |
| Do        | 11                  |
| Fr        | 15                  |

- Erläutern Sie, wie Sie in R vorgehen, wenn Sie testen wollen, ob sich die beobachtete Verteilung von der Verteilung in der Vergangenheit unterscheidet. Das Signifikanzniveau sei 5%.
- Welche Bedingungen sind vor dem Test zu prüfen? Was sind Null- und Alternativhypothese?
- Angenommen, Sie erhalten folgenden R Output

X-squared = 6.32, df = 4, p-value = 0.1765

Erklären Sie alle Elemente des R Outputs und interpretieren Sie den p-value im Kontext.

**Aufgabe 9: Unabhängigkeitstest** Betrachten Sie den Datensatz `student_food.csv` (erklärt in `student.txt`).

- Erstellen Sie ein Säulendiagramm für die bedingte Verteilung des Merkmals Konsum (`organic`) gegeben Geschlecht (`sex`). Hinweis: Stellen Sie  $\text{relH}(\text{Konsum von Bio-Produkten} | \text{Geschlecht} = \text{Mann})$  und  $\text{relH}(\text{Konsum von Bio-Produkten} | \text{Geschlecht} = \text{Frau})$  in einem Diagramm dar. Interpretation.
- Berechnen Sie  $KK^*$ . Interpretation.
- Untersuchen Sie mit Hilfe eines Unabhängigkeitstests, ob die Merkmale Geschlecht und Konsum von Bio-Produkten unabhängig voneinander sind. Interpretieren Sie den p-value. Welche Schlussfolgerung können Sie treffen?

## Aufgabenblatt: Inferenz für quantitative Daten (alle Module)

**Aufgabe 1: Kleine Stichprobe** Eine kleine Stichprobe aus einer normalverteilten Grundgesamtheit lieferte den folgenden Beobachtungsbefund (in g):

12.7, 13.3, 13.0, 12.9, 13.1, 12.8, 13.1

- Geben Sie ein Konfidenzintervall an, das den Mittelwert der Grundgesamtheit mit einer Wahrscheinlichkeit von 95% überdeckt. Interpretieren Sie Ihr Ergebnis.
- Berechnen Sie das 99%-Konfidenzintervall. Interpretieren Sie Ihr Ergebnis.
- Sie möchten eine präzisere Aussage treffen. Welche Möglichkeiten haben Sie? Erläuterung.

**Aufgabe 2: Versicherung** In einem Versicherungsunternehmen soll die Profitabilität von Versicherungspolicen geprüft werden. In `police.csv` sind die Gewinne (in €) von 30 zufällig ausgewählten Policen eines Mitarbeiters gegeben.

- Erstellen Sie ein Histogramm der Werte und beschreiben Sie die Verteilung mit `summary()`.
- Konstruieren Sie ein 95%-Konfidenzintervall für den mittleren Gewinn des Mitarbeiters. Diskussion der Annahmen für die Berechnung des Konfidenzintervalls. Interpretation.

**Aufgabe 3: Rundstahl** Eine Stahlfabrik produziert Rundstahl in Form von Stäben mit einem Zieldurchmesser von 10mm und einer Länge von 5000mm. Nach einem Neustart der Anlage werden 18 dieser Stäbe zufällig ausgewählt und der Durchmesser ( $D$ ) gemessen. Die Werte in mm sind in Rundstahl.csv gegeben. Die Geschäftsleitung will wissen, ob der Mittelwert der Grundgesamtheit statistisch signifikant von 10mm abweicht (das Signifikanzniveau sei 5%). Auf Grund früherer Messungen kann davon ausgegangen werden, dass die Werte in der Grundgesamtheit normalverteilt sind.

**Aufgabe 4: Kneipe** Sie vermuten, dass in Ihrer Stammkneipe der Wirt weniger Bier ausschenkt als eigentlich gefordert. Mit einem Freund trinken Sie an einem Abend sieben 0.5-Liter-Bier und messen die Füllmengen nach. Die Füllmengen der Biergläser (in Liter) sind:

0.51, 0.48, 0.5, 0.45, 0.47, 0.48, 0.47

Sie wollen zeigen, dass der Wirt tatsächlich zu wenig Bier ausschenkt. Führen Sie einen entsprechenden Hypothesentest mit einem Signifikanzniveau von 5% durch. Erläutern Sie Ihre Vorgehensweise. Interpretieren Sie den p-value im Kontext. Interpretieren Sie Ihr Ergebnis. Diskutieren Sie die Konzepte der statistischen und ökonomischen Signifikanz anhand des Beispiels.

**Aufgabe 5: Reichweitenerhöhung** Betrachten Sie den Datensatz Cars93.csv.

- Erstellen Sie ein Histogramm der Variable `MPG.highway` und beschreiben Sie die Verteilung.
- Angenommen in den 1980er Jahren lag die mittlere Reichweite bei 27 mpg. Gibt es basierend auf den Daten in der Stichprobe Evidenz dahingehend, dass sich die mittlere Reichweite der US-PKW erhöht hat? Erläutern Sie Ihre Vorgehensweise für einen Hypothesentest (das Signifikanzniveau sei 5%). Berechnen und interpretieren Sie den p-value im Kontext.

**Aufgabe 6: Zuckersäcke** Eine Firma bekommt Zuckersäcke geliefert und vermutet, dass der Lieferant pro Sack zu wenig Zucker abfüllt. Vereinbart ist ein Mindestgewicht von 27 kg. Aus früheren Untersuchungen weiß man, dass die Grundgesamtheit aller Säcke normalverteilt ist. Um die o.g. Vermutung zu untermauern, wird eine Zufallsstichprobe gezogen. Die Gewichte (in kg) der Säcke in der Stichprobe sind: {25, 27, 23, 21, 26, 30}. Gibt es Hinweise darauf, dass das mittlere Gewicht aller Säcke unter der kritischen Grenze von 27 kg liegt?

- Stellen Sie zu dieser Fragestellung die passenden Hypothesen auf.
- Prüfen Sie die Voraussetzungen zur Durchführung des Hypothesentests.
- Führen Sie den Test zu einem Signifikanzniveau von 5% durch. Interpretieren Sie den p-value im Kontext. Welche Schlussfolgerung können Sie treffen?
- Diskutieren Sie die Konzepte der statistischen und ökonomischen Signifikanz anhand des Beispiels.

## Aufgabenblatt: Inferenz für zwei Stichproben (nur W662, nicht klausurrelevant)

**Aufgabe 1: Ozon-Konzentration** Betrachten Sie den Datensatz `t.test.data.csv`. Für zwei Gärten (`gardenA` und `gardenB`) ist die Ozon-Konzentration in pphm (parts per hundred million) für 10 Sommertage angegeben.

- Vergleichen Sie beide Verteilungen mit einem Boxplot.
- Prüfen Sie die Annahmen für einen Zweistichproben-t-Test. Nutzen Sie für die Normalverteilungsannahme den Shapiro-Wilk-Test in R mit `shapiro.test()`.
- Testen Sie die Nullhypothese, dass die mittlere Ozon-Konzentration in beiden Gärten gleich ist. Interpretation des p-value.

**Aufgabe 2: Körpergewicht** Von 18 Personen (9 Frauen, 9 Männern) sei das Körpergewicht (in kg) gegeben:

Frauen: 38.9, 61.2, 73.3, 51.8, 63.4, 64.6, 48.4, 48.8, 48.5

Männer: 67.8, 60, 63.4, 76, 89.4, 73.3, 67.3, 61.3, 62.4

Gibt es einen statistisch signifikanten Unterschied zwischen dem Gewicht der Frauen und der Männer?

- Vergleichen Sie beide Verteilungen mit einem Boxplot.
- Prüfen Sie die Annahmen für einen Zweistichproben-t-Test. Nutzen Sie für die Normalverteilungsannahme den Shapiro-Wilk-Test in R mit `shapiro.test()`.
- Führen Sie einen ungepaarten Zweistichproben-t-Test durch. Interpretation.

**Aufgabe 3: Flussabwärts** Betrachten Sie den Datensatz `streams.csv`. Für zwei Messpunkte an einem Fluss (`up` und `down`) ist ein Indikator für Biodiversität (in Punkten) angegeben. Die Werte wurden für 16 Tage erhoben. Man vermutet, dass die Biodiversität durch Abwassereinleitung negativ beeinflusst wird.

- Vergleichen Sie beide Verteilungen mit einem Boxplot.
- Begründen Sie, warum Sie hier einen gepaarten t-Test verwenden sollten. Prüfen Sie die Annahmen für einen gepaarten t-Test.
- Testen Sie die Nullhypothese, dass die mittlere Biodiversität an beiden Messpunkten gleich ist mit einem gepaarten t-Test. Interpretation des p-value.

**Aufgabe 4: Punkte** Betrachten Sie den Datensatz `module.score.csv`. Für  $n = 20$  Studenten wurde vor dem Besuch eines Moduls (`pre.module.score`) und nach dem Modul (`post.module.score`) die erreichte Punktzahl in einem Test erhoben. Es stellt sich die Frage, ob das Modul zu einer Erhöhung der Punktzahl im Test geführt hat.

- Berechnen Sie die paarweise Differenz der Punkte und stellen Sie diese in einem Histogramm dar. Interpretation.
- Begründen Sie, warum Sie hier einen gepaarten t-Test verwenden sollten. Prüfen Sie die Annahmen für einen gepaarten t-Test.
- Testen Sie die Nullhypothese, dass sich die mittlere Punktzahl durch den Test nicht geändert hat. Interpretation.

## Aufgabenblatt: Inferenz für Einfachregression und Korrelation (nur W662)

**Aufgabe 1: Hypothekendarlehen** Die Aufgabe bezieht sich auf den Datensatz `interest_rates_and_mortgages.csv`. Vgl. Aufgabe 3, Blatt “Assoziation und Korrelation”. Ist die berechnete Korrelation statistisch signifikant? Interpretation.

**Aufgabe 2: Autos I** Betrachten Sie den Datensatz `Cars93.csv` und Aufgabe 4, Blatt “Assoziation und Korrelation”.

- Ist die berechnete Korrelation für die Variablen `Horsepower` and `MPG.highway` statistisch signifikant? Interpretation.
- Ist die berechnete Korrelation für die Variablen `Weight` und `Horsepower` statistisch signifikant? Interpretation.

**Aufgabe 3: Autos II** Betrachten Sie den Datensatz Cars93.csv.

- Schätzen Sie die Regressionsfunktion  $\widehat{MPG.highway} = \beta_0 + \beta_1 Horsepower$ . Interpretieren Sie Ihre Schätzung. Was ist der erwartete MPG-Wert für ein Auto mit 225 PS?
- Schätzen Sie das lineare Modell  $\widehat{MPG.highway} = \beta_0 + \beta_1 Weight$ . Finden Sie den erwarteten MPG-Wert für einen Hummer H2 (Gewicht 6400 Pfund) und einen MINI Cooper (2524 Pfund).

Hinweis: Wir arbeiten hier mit dem linearen Modell. Ggf. wäre auch eine log-Transformation sinnvoll. Die Interpretation im linearen Modell ist aber sinnvoller: Reichweite bzw. Energieeffizienz wird hier in MPG gemessen und Motorenstärke in PS (eine Nutzung von Prozent wäre unüblich).

**Aufgabe 4: Körpergröße** Häufig wird die erwartete Körpergröße eines Erwachsenen basierend von der Körpergröße mit zwei Jahren berechnet. Schätzen Sie den linearen Zusammenhang basierend auf dem folgenden Datensatz:

| Beobachtung          | 1     | 2     | 3     | 4     | 5     | 6     | 7     | 8     |
|----------------------|-------|-------|-------|-------|-------|-------|-------|-------|
| Mit 2 Jahren (in cm) | 99.6  | 76.2  | 81.3  | 86.4  | 88.9  | 91.4  | 91.4  | 76.2  |
| Erwachsen (in cm)    | 180.3 | 160.0 | 160.0 | 170.2 | 172.7 | 172.7 | 177.8 | 162.6 |

- Gegeben die Daten und der geschätzte lineare Zusammenhang, was ist die erwartete Körpergröße für einen Erwachsenen, der mit zwei Jahren 83.8 cm groß war?
- Lassen Sie sich die Fehlerterme ausgeben und erstellen Sie ein Histogramm dieser Werte. Berechnen Sie Median und arithmetisches Mittel der Fehlerterme.
- Berechnen und Interpretieren Sie das  $R^2$  der Regression. Zeigen Sie, dass die Varianz der abhängigen Variablen gleich der Summe der Varianz der Werte auf der Regressionsgeraden und der Varianz der Fehlerterme ist.
- Ist der Anstiegsparmeter statistisch signifikant von Null verschieden?

**Aufgabe 5: PM2.5-Konzentration und p.c. GDP** Betrachten Sie den Datensatz GDPpc\_pm\_live.csv (erläutert in GDPpc\_pm\_live.txt).

- Betrachten Sie die Variablen `GDPpc` und `pm` mit `summary()`. Interpretation der Lagemaße.
- Bestimmen Sie die top 3 der reichsten bzw. ärmsten Länder sowie die top 3 der saubersten und schmutzigsten Länder.
- Berechnen Sie die Regressionsgerade für das lineare Modell  $\widehat{pm} = \beta_0 + \beta_1 GDPpc$ . Stellen Sie die Regressionsgerade graphisch im Streudiagramm dar.
- Prüfen Sie die Annahmen der linearen Regression. Welche Annahmen der linearen Regression sind verletzt?
- Schätzen Sie das Modell  $\widehat{pm} = \beta_0 + \beta_1 \log(GDPpc)$ . Interpretieren Sie den Anstiegsparmeter. Ist der Anstiegsparmeter statistisch signifikant?
- Stellen Sie das Modell aus e) im Streudiagramm für `GDPpc` und `pm` dar. Welche PM2.5-Konzentration prognostiziert das Modell für ein GDP p.c. von 10000 USD? Wie verändert sich die PM2.5-Konzentration, wenn das GDP p.c. um 10% steigt?
- Diskutieren Sie die Modellannahmen für das Modell  $\widehat{pm} = \beta_0 + \beta_1 \log(GDPpc)$ . Welche Option haben Sie?

**Aufgabe 6: Lohn und Bildung II** Lesen Sie den Datensatz wage1.csv (erläutert in wage1.txt) ein.

- Betrachten Sie die Variablen `wage` und `educ` mit `summary()`. Interpretation der Lagemaße.

- Berechnen Sie die Regressionsgerade für das lineare Modell  $\widehat{wage} = \beta_0 + \beta_1 educ$ . Stellen Sie die Regressionsgerade graphisch im Streudiagramm dar und interpretieren Sie den Anstiegsparmeter  $\beta_1$ . Berechnen und interpretieren Sie das  $R^2$  dieser Regression.
- Prüfen Sie die Annahmen der Regressionsrechnung. Stellen Sie hierzu auch Fehlerterme und prognostizierte Werte in einem Streudiagramm dar. Welche Annahmen der linearen Regression sind verletzt?
- Führen Sie die Schritte b) und c) für das Modell  $\log(\widehat{wage}) = \beta_0 + \beta_1 educ$  durch.
- Testen Sie für das Modell in d) den Anstiegsparmeter auf statistische Signifikanz.

**Aufgabe 7: CEO Verdienst** Betrachten Sie den Datensatz `ceosal.csv` (erläutert in `ceosal.txt`).

- Betrachten Sie die Variablen `salary` und `sales` mit `summary()`. Interpretation der Lagemaße.
- Berechnen Sie die Regressionsgerade für das lineare Modell  $\widehat{salary} = \beta_0 + \beta_1 sales$ . Stellen Sie die Regressionsgerade graphisch im Streudiagramm dar und interpretieren Sie den Anstiegsparmeter  $\beta_1$ . Berechnen und interpretieren Sie das  $R^2$  dieser Regression.
- Prüfen Sie die Annahmen der Regressionsrechnung. Stellen Sie hierzu auch Fehlerterme und prognostizierte Werte in einem Streudiagramm dar. Welche Annahmen der linearen Regression sind verletzt?
- Führen Sie die Schritte b) und c) für das Modell  $\log(\widehat{salary}) = \beta_0 + \beta_1 \log(sales)$  durch. Testen Sie den Anstiegsparmeter auf statistische Signifikanz.

**Aufgabe 8: Modellvergleich** Im Datensatz `PandQ.csv` gibt es die Variablen `Q` (Menge in Einheiten) und `P` (Preis pro Einheit in €). Sie vermuten eine Abhängigkeit zwischen beiden Variablen mit  $Q = f(P)$ .

- Schätzen Sie Modell 1 mit  $Q = \beta_0 + \beta_1 P$  und Modell 2 mit  $\log(Q) = \beta_0 + \beta_1 \log(P)$ .
- Interpretieren Sie den Anstiegsparmeter,  $\beta_1$ , sowohl für Modell 1 als auch für Modell 2. Interpretieren Sie das  $R^2$  für Modell 2.
- Welches Modell würden Sie bevorzugen? Erläuterung.
- Erläutern Sie die Methode, mit der die Regressionsgerade bestimmt wird. Gehen Sie dabei auch auf die Eigenschaften der Residuen ein.

**Aufgabe 9: Investitionen für Deutschland** Laden Sie den Datensatz `Investitionen.csv`. Die Variable `INV` gibt die realen Bruttoanlageinvestitionen in Mrd. EUR pro Quartal in Deutschland an (Quelle: Destatis). Die Variable `ZINS` gibt den Effektivzins für Unternehmenskredite in Prozent/Jahr an (Quelle: Bundesbank).

- Beschreiben Sie beide Zeitreihen kurz. Nutzen Sie für eine graphische Darstellung den Befehl `ts()`. Zum Beispiel für `INV`: Erzeugen Sie eine neue Variable mit `ts(data$INV, frequency = 4, start = c(2003, 1))`. Diese Variable kann man dann mit `plot()` darstellen.
- Schätzen Sie ein lineares Regressionsmodell mit `INV` als abhängige Variable und `ZINS` als unabhängige Variable. Erstellen Sie ein Streudiagramm beider Variablen und fügen Sie die Regressionsgerade in das Streudiagramm ein. Interpretation.

## Aufgabenblatt: Multiple Regression (nur W662)

**Aufgabe 1: Effects of Training Grants on Hours of Training** Betrachten Sie den Datensatz `jtrain.csv`. Dieser ist im Dokument `wooldridge.pdf` beschrieben. Der Datensatz beinhaltet 105 Firmen aus dem verarbeitenden Gewerbe (manufacturing) des US Bundesstaates Michigan im Jahr 1988. Die Dummy-Variable `grant` ist gleich 1, wenn eine Firma eine Unterstützung für ein job training erhalten hat, und gleich 0, wenn es keine Unterstützung gab. Die abhängige Variable `hrsemp` ist die Zahl der Trainingsstunden pro Beschäftigter. Die Zahl der Mitarbeiter in der Firma ist `employ`.

- Erstellen Sie einen Boxplot für `hrsemp` getrennt nach `grant = 1` und `grant = 0`. Interpretation.
- Schätzen Sie das Modell  $\widehat{hrsemp} = \beta_0 + \beta_1 grant + \beta_2 \log(sales) + \beta_3 \log(employ)$ .
- Interpretieren Sie  $\beta_1$  und  $\beta_3$ .

**Aufgabe 2: Time spent sleeping and working** Betrachten Sie den Datensatz `sleep75.csv`. Dieser ist im Dokument `wooldridge.pdf` beschrieben. Der Datensatz beinhaltet Angaben zum Schlafverhalten und weitere sozio-ökonomische Variablen von 706 Befragten.

- Schätzen Sie das Modell  $\widehat{sleep} = \beta_0 + \beta_1 totwrk$ . Wie lässt sich der Achsenabschnitt  $\beta_0$  interpretieren? Interpretieren Sie das  $R^2$ . Erstellen Sie ein Streudiagramm für beide Variablen und zeichnen Sie die Regressionsgerade ein.
- Wenn `totwrk` um 2 Stunden steigt, um wie viel geht `sleep` geschätzt zurück? Ist das aus Ihrer Sicht ein großer Effekt?
- Schätzen Sie das Modell  $\widehat{sleep} = \beta_0 + \beta_1 totwrk + \beta_2 educ + \beta_3 age$ . Interpretieren Sie  $\beta_2$  und  $\beta_3$ .
- Beurteilen Sie das  $R^2$  des Modells. Welche anderen Faktoren könnten einen Einfluss auf `sleep` haben?

**Aufgabe 3: Hauspreise** Betrachten Sie den Datensatz `homeprices.csv`. Dieser ist im Dokument `homeprices.docx` beschrieben. Schätzen Sie das minimal passende Regressionsmodell zur Erklärung der Variable `PRICE`. Hinweise: Eliminieren Sie vorab die Variable `AGE` (wegen missing values) und prüfen Sie, ob ein Interaktionseffekt zwischen den Variablen `COR` und `SQFT` vorliegt.

**Aufgabe 4: Cars** Installieren und laden Sie das Paket `car`. Laden Sie den Datensatz `mtcars` aus diesem Paket (Hilfe mit `?mtcars`).

- Schätzen Sie das Modell `lm(formula = mpg ~ disp + hp + wt + drat)`. Interpretieren Sie den Regressionsoutput.
- Prüfen Sie mit Hilfe von Diagnoseplots die Regressionsannahmen.
- Welche Beobachtungen können Sie als kritische Beobachtungen identifizieren? Angenommen, Fiat 128 und Toyota Corolla stellen Ausreißer dar. Inwieweit verbessert sich die Erklärungskraft des Modells und die Erfüllung der Regressionsannahmen, wenn Sie diese Beobachtungen eliminieren?

**Aufgabe 5: Kolinearität** Lösen Sie folgende Aufgaben:

- Lesen Sie den Datensatz `data_10.5a.csv` ein. Schätzen Sie das Modell `lm(formula = y1 ~ x1 + x2)`. Was ist das Problem bei dieser Regression?
- Lesen Sie den Datensatz `data_10.5b.csv` ein. Schätzen Sie das Modell `lm(formula = y1 ~ x1 + x2)`. Wo ist das Problem bei dieser Regression? Berechnen Sie den Variance Inflation Factor (VIF) für `x1` und `x2` und entfernen Sie eine der beiden Variablen aus der Regression. Erläutern Sie das Problem der Kolinearität am Beispiel.

**Aufgabe 6: Diagnose Plots I** Lesen Sie den Datensatz `hills.csv` ein. Der Datensatz ist beschrieben auf <http://www.statsci.org/data/general/hills.html>.

- Prüfen Sie graphisch, ob zwischen `Distance` und `Time` sowie zwischen `Climb` und `Time` ein näherungsweise linearer Zusammenhang vorliegt.
- Schätzen Sie das Modell `lm(formula = Time ~ Distance + Climb)`. Interpretation.
- Stellen Sie die vier Diagnose-Plots in R dar. Welche Beobachtungen sind auffällig? Welche Beobachtungen haben eine Cook's Distance  $D > 1$ ?
- Eliminieren Sie Beobachtung 7 (`BensofJura`) und führen Sie b) und c) erneut durch.

**Aufgabe 7: Diagnose Plots II** Lösen Sie folgende Aufgaben:

- a) Lesen Sie den Datensatz `marketing_a.csv` ein. Alle Angaben zu den Variablen sind in 1000 EUR. Schätzen Sie das Modell `lm(sales ~ youtube)` und lassen Sie sich die vier Diagnoseplots ausgeben. Beschreiben Sie jeden der vier Plots kurz und diskutieren Sie, ob eine Verletzung der Regressionsannahmen vorliegt. Wenn ja, was kann man tun?
- b) Lesen Sie den Datensatz `marketing_b.csv` ein. Alle Angaben zu den Variablen sind in 1000 EUR. Schätzen Sie das Modell `lm(sales ~ youtube + facebook)` und lassen Sie sich die vier Diagnoseplots ausgeben. Beschreiben Sie jeden der vier Plots kurz und diskutieren Sie, ob eine Verletzung der Regressionsannahmen vorliegt. Wenn ja, was kann man tun?