

Statistik mit R für die Module W501, W873 und W662 (Teil I)

Bodo Sturm, HTWK Leipzig

01.10.2026

IMAGINE a world without statistics. Governments would fumble in the dark, investors would waste money and electorates would struggle to hold their political leaders to account.

— The Economist (Feb 25th 2012)

Über diese Veranstaltung

Allgemeines In dieser Veranstaltung werden **Konzepte der deskriptiven und induktiven Statistik** mit R vorgestellt. **Ziel** ist es, statistische Probleme mit Hilfe von R zu lösen und entsprechende Ergebnisse interpretieren zu können. R (<https://www.r-project.org/>) ist eine frei verfügbare Statistik-Software.

Das Teilmodul (W501/W873) bzw. Modul (W662) setzt Grundkenntnisse in Statistik voraus. Diese müssen selbst erarbeitet bzw. wieder aufgefrischt werden. Die Veranstaltung basiert auf dem Lehrbuch: Sturm, B. (2019): “Statistik. Eine Einführung mit R”, GUC-Verlag, 2. Auflage (<https://fww.htwk-leipzig.de/sturm/lehrbuecher-prof-dr-bodo-sturm/>).

Der OPAL-Kurs enthält:

- Skript (dieses pdf/html).
- Aufgabenblätter zum selbstständigen Lösen (pro Kapitel ein Blatt).
- ZIP-Datei “dataR.zip”. Diese Datei bitte **LOKAL abspeichern und extrahieren** (d.h., in einem Ordner auf Ihrem Rechner abspeichern und entpacken). Oder Sie gehen direkt auf GitHub mit <https://github.com/bodosturm/dataR.git>, dann auf Code und auf Download ZIP. Anschließend lokal extrahieren.
- Sessionplan: In diesem txt file sind stichpunktartig die wichtigsten Inhalte aufgelistet.
- R Exkurse: Ein Ordner mit txt files, die verschiedene statistische Probleme mit R lösen.
- Lösungshinweise zu den Übungsaufgaben (werden nach dem Besprechen in der Veranstaltung in OPAL eingestellt).
- Lernvideos zur Anwendung von R.

Es ist Ihre Aufgabe, sich mit den Rechnern im Zuse-Bau (wenn Sie diese nutzen: Zugang, Baumstruktur usw.) und natürlich auch mit Ihrem Rechner (Baumstruktur) vertraut zu machen. Für Studierende mit Laptop: Nutzen Sie die WLAN-Verbindung mit eduroam. Der Download von R und erste Schritte sind im o.g. Lehrbuch “Statistik. Eine Einführung mit R” beschrieben.

Sie können gerne **KI als Coach** nutzen, z.B. zur Fehlersuche im Code oder zur Erklärung der Anwendung eines Befehls. Versuchen Sie dabei möglichst mit den einfachen Befehlen aus der Vorlesung zu arbeiten (lassen Sie die KI mit base R arbeiten und möglichst nicht mit extra Paketen). Denken Sie aber immer daran, dass Sie am Ende in der Lage sein sollten, die Übungsaufgaben eigenständig bearbeiten zu können.

Warum R und nicht gleich KI? Der zentrale Vorteil von Statistik-Software wie R ist Transparenz und Reproduzierbarkeit: Jeder Rechenschritt ist im Code sichtbar, nachvollziehbar und exakt wiederholbar – wenn

sich z.B. die Rohdaten ändern, läuft das gleiche Skript erneut und liefert garantiert konsistente, überprüfbare Ergebnisse, während eine KI-Antwort eine Blackbox bleibt und bei Auswertungen und Erläuterungen auch mal halluzinieren kann. Der Trade-off: R erfordert mehr Vorwissen und Zeitaufwand, wogegen KI wie Claude schneller zu einer Antwort kommt, aber ohne die gleiche Transparenz. Faustregel “KI für schnelle Exploration, R-Code für alles, was überprüfbar, wiederholbar und zitierfähig sein muss”.

Struktur der Veranstaltung:

1. Es gibt eine Vorlesung am Rechner mit Anwendung von Statistik in R. Das Skript wird gestellt (vgl. OPAL-Kurs). Die Mitschriften der Vorlesungen werden in OPAL veröffentlicht (txt file mit Datum).
2. Es gibt Aufgabenblätter (pdf, vgl. OPAL-Kurs), die die Studierenden selbstständig (!) bearbeiten. In der Veranstaltung werden nur Probleme bei der Lösung besprochen. **Fragen zu den Aufgaben bitte vorab per email.** Wenn Sie keine Fragen haben, heißt das für mich, dass alles OK ist.
3. Die **Klausureinsicht** für meine Veranstaltungen findet immer zu Beginn des nachfolgenden Semesters (im April bzw. Oktober) in meiner Sprechzeit statt (Termine werden über Webpage/OPAL bekanntgegeben).

Hinweise für W501 (BWM) und W873 (GMM) Der Umfang des Teilmoduls beträgt 90 Min. pro Woche (2 SWS, 50% des Moduls Quantitative Methoden). Bitte tragen Sie sich in den OPAL-Kurs (“W501 Quantitative Methoden” oder “W873 Quantitative Methoden der Wirtschaftswissenschaften”) ein. Dieses pdf/html ist das Skript zum Modul. Es gibt gemäß PrüfO eine Klausur (90 min.) für das Modul. Die Klausur wird “klassisch” durchgeführt, d.h. mit Stift und Papier. **Hilfsmittel:** Taschenrechner (gem. Positiv-Liste der FWW) und ein A4-Blatt (mit Vorder- und Rückseite, frei beschriftet oder bedruckt). Die **Klausur für dieses Teilmodul** umfasst Verständnis und Anwendung von statistischen Methoden, Interpretation von Ergebnissen sowie die Anwendung von R-Code.

Hinweise für W662 (BWB/IMB) Der Umfang des Moduls beträgt 2 x 90 Min. pro Woche (4 SWS). Bitte tragen Sie sich in den OPAL-Kurs für “W662 Angewandte Statistik” ein. Das Skript zum Modul hat zwei Teile (Teil I: dieses pdf/html, Teil II: Multiple Regression als pdf). Es gibt gemäß PrüfO eine Klausur (120 min.) für das Modul. Die Klausur wird “klassisch” durchgeführt, d.h. mit Stift und Papier. **Hilfsmittel:** Taschenrechner (gem. Positiv-Liste der FWW) und ein A4-Blatt (mit Vorder- und Rückseite, frei beschriftet oder bedruckt). Die **Klausur** umfasst Verständnis und Anwendung von statistischen Methoden, Interpretation von Ergebnissen sowie die Anwendung von R-Code.

Basics in R (alle Module)

Ein- und Ausgabe in R

Nach dem Öffnen von R erwartet die **Console** hinter dem > Zeichen die Eingabe eines Befehls (Ausführung mit ENTER). Zum Beispiel kann in die Console die Rechenoperation 2+2 eingegeben werden. Ergebnis:

```
[1] 4
```

In der Console stehen Eingabe und Ausgabe zusammen. Dies ist ein Nachteil, wenn Ein- und Ausgabe umfangreicher werden. Daher werden wir im Folgenden den in R implementierten **Editor** zur Eingabe nutzen (es gibt eine Reihe von komfortableren Editoren wie z.B. R Studio, <https://www.rstudio.com/>). Der Editor kann als .txt oder .R file abgespeichert (und später wieder geöffnet und ausgeführt) werden. Die Ausgabe erfolgt dann in der Console.

Es gibt zwei Optionen für die Befehlsübergabe vom Editor an die Console:

1. Markieren des Befehls im Editor und Tastenkombination “Strg+R” oder
2. Markieren des Befehls im Editor und Ausführen von “Ausführung Zeile oder Auswahl” in der R Menü-Zeile.

Alles hinter der Raute (#) ist in R ein **Kommentar**. Zum besseren Verständnis der Befehle werden diese oft kommentiert. Am Ende des Tages ist es das Ziel, ein kommentiertes R Skript zu haben, welches einen Datensatz einliest und diesen leicht reproduzierbar auswertet.

R als Rechner

R kann als Rechner verwendet werden. Dabei gilt “Punkt- vor Strichrechnung”. Die Eingabe erfolgt einfach in der Console (Ausführung mit ENTER) oder im Editor (vgl. unten).

```
1+2      # Addition
```

```
## [1] 3
```

```
2*5      # Multiplikation
```

```
## [1] 10
```

```
3/5      # Division
```

```
## [1] 0.6
```

```
2+4*5    # Punkt- vor Strichrechnung
```

```
## [1] 22
```

Weitere Rechenoperationen:

```
sqrt(9)   # Wurzel
```

```
## [1] 3
```

```
3^2       # Quadrat
```

```
## [1] 9
```

```
log(100)  # Natürlicher Logarithmus
```

```
## [1] 4.6052
```

R ist **objektbasiert**. Objekte sind z.B. Vektoren oder Matrizen. Es gibt Regeln für die Objektbezeichnung: R ist **case sensitiv**, d.h., x ist nicht X. Objektnamen dürfen nicht mit Zahlen beginnen: also zum Beispiel x1 aber nicht 1x. Die Bezeichnung von Objekten erfolgt mit dem **Zuweisungsoperator** <=.

```
x <- 9    # Dem Objekt x wird mit "<=" die Zahl 9 zugewiesen  
x         # Ausgabe von x
```

```
## [1] 9
```

Die [1] in der Ausgabe zeigt an, dass dahinter das 1. Element der Ausgabe steht (hier die 9).

```
class(x)    # Welche Art von Objekt ist x?
```

```
## [1] "numeric"
```

Zahlenreihen

Der Befehl `seq()` erzeugt eine Zahlenreihe, wobei Beginn, Ende und Abstand (getrennt durch ein Komma) anzugeben sind. Wir definieren hier eine Zahlenreihe von 0 bis 20 mit Abstand 2. Wir weisen der Zahlenreihe mit dem Zuweisungsoperator `<-` eine Bezeichnung `a` zu.

```
a <- seq(0, 20, 2) # Definition des Objektes a  
a                # Ausgabe von a
```

```
## [1] 0 2 4 6 8 10 12 14 16 18 20
```

Die Reihe ganzer Zahlen von z.B. 8 bis 14 kann mit `seq(8, 14, 1)`, aber auch mit `8:14` definiert werden.

```
8:14        # ganze Zahlen von 8 bis 14
```

```
## [1] 8 9 10 11 12 13 14
```


```
a[1:4]      # gebe die Elemente 1 bis 4 von a aus
```

```
## [1] 0 2 4 6
```

Abbildungen mit `plot()`


Der Befehl für Abbildungen ist `plot()`, wobei ein Vektor als x-Variable und ein Vektor als y-Variable anzugeben ist. Hier nutzen wir die eben definierte Zahlenreihe `a` und $a^2 - 40$.

```
plot(a, a^2-40, cex = 1.3) # Trennung der Argumente durch Komma  
grid()                    # Gitternetz (wenn man will)
```



Mit `cex = 1.3` werden die Punkte in der Abbildung 30% größer dargestellt als normal (`cex = 1`). Der Befehl `grid()` legt ein Gitternetz über die Abbildung. Noch ein Beispiel für eine solche Abbildung:

```
X <- seq(0, 4, 0.1)      # Trennung der Argumente durch Komma
Y <- 3*X^2 + 18 - X^3
plot(X, Y, cex = 1.3)
grid()
```



Einige sinnvolle Befehle

Der Befehl `max()` liefert das Maximum einer Zahlenreihe, `min()` das Minimum und `length()` liefert die Länge des Vektors. Der Befehl `sum()` liefert die Summe der Elemente eines Vektors.

```
E <- 1:100 # 1:100 ist der gleiche Output wie seq(1, 100, 1)
sum(E)     # Summe von E
```

```
## [1] 5050
```

```
100*101/2 # Gauss-Formel sum(E) = n*(n+1)/2
```

```
## [1] 5050
```

```
min(E); max(E) # Das Semikolon spart den Zeilenumbruch.
```

```
## [1] 1
```

```
## [1] 100
```

```
length(E) # Länge des Vektors
```

```
## [1] 100
```

Betrachten wir das arithmetische Mittel von E. Hierfür haben wir zwei Optionen:

```
n <- length(E); n # Definiere Variable n
```

```
## [1] 100
```

```
(1/n)*sum(E) # Berechne das arithmetische Mittel
```

```
## [1] 50.5
```

oder

```
mean(E) # Funktion für das arithmetische Mittel
```

```
## [1] 50.5
```

R kann mit Vektoren rechnen.

```
a <- 1:5; a # Das Semikolon spart den Zeilenumbruch
```

```
## [1] 1 2 3 4 5
```

```
a*4 # Elemente des Vektors * 4
```

```
## [1] 4 8 12 16 20
```

```
a/10 # Elemente des Vektors : 10
```

```
## [1] 0.1 0.2 0.3 0.4 0.5
```

```
a + 3 # Elemente des Vektors + 3
```

```
## [1] 4 5 6 7 8
```

Nun wollen wir zeigen, wie der **Zugriff** auf einzelne Elemente eines Vektors (und später auch einer Matrix) funktioniert. Wir definieren uns eine Zahlenreihe **b** mit `c()` und greifen auf bestimmte Werte von **b** zu.

```
b <- c(6:10, 99, 5:13); b
```

```
## [1] 6 7 8 9 10 99 5 6 7 8 9 10 11 12 13
```

```
mean(b) # arithmetisches Mittel von b
```

```
## [1] 14.667
```

```
b[6]      # Ausgabe des 6. Elements von b mit []-Klammer
```

```
## [1] 99
```

```
b[6] <- NA # weise dem Ausreißer 99 den Wert NA (= not available) zu  
b      # Ausgabe der neuen Reihe b mit b[6] = NA
```

```
## [1] 6 7 8 9 10 NA 5 6 7 8 9 10 11 12 13
```

```
mean(b, na.rm = TRUE) # Mittel von b, wobei die NA nicht berücksichtigt werden
```

```
## [1] 8.6429
```

Wie bekommt man raus, ob eine Zahlenreihe NAs (not available) hat?

```
summary(b) # guter Überblick über einen Vektor
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs  
##      5.00   7.00   8.50   8.64  10.00   13.00      1
```

```
is.na(b)  # geht auch so, Antwort ist TRUE or FALSE
```

```
## [1] FALSE FALSE FALSE FALSE FALSE TRUE FALSE FALSE FALSE FALSE FALSE  
## [13] FALSE FALSE FALSE
```

Der Befehl `summary()` ist extrem nützlich, insbesondere bei der Analyse von quantitativen Daten.

Einlesen von Daten in R: Wir werden hier nur mit Dateien des Typs “csv” (comma separated values) arbeiten. Solche csv-Dateien lassen sich leicht aus Excel generieren (und dann als csv abspeichern).

Option 1: Einlesen einer csv-Datei direkt von **GitHub** (Internet-Verbindung nötig) mit

```
https://raw.githubusercontent.com/bodosturm/dataR/main/dateiname.csv
```

in Anführungszeichen und mit `read.csv()`.

```
# Ein Beispiel:
```

```
data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/patients.csv")  
data      # Ausgabe des Objektes data
```

```
##      fem age weight  
## 1     0  20     58  
## 2     1  66     63  
## 3     0  80     62  
## 4     1  44     59  
## 5     1  50     85  
## 6     0  55     90  
## 7     1  16     78
```

Option 2: Einlesen der csv-Datei aus einem Ordner auf Ihrem Rechner (Annahme: Alle Dateien aus dataR.zip liegen extrahiert in diesem Ordner). Hierbei sind die folgenden Schritte zu absolvieren:

- a. Wo ist das aktuelle **Arbeitsverzeichnis**? Der Befehl `getwd()` gibt das aktuelle Arbeitsverzeichnis aus.

```
getwd()      # Wo ist das Arbeitsverzeichnis (working directory = wd)?
```

```
## [1] "C:/Users/sturm/01_HTWK 20_Dez_2022/01_Vorlesungen/08 WS 2x2 SWS QMStatistikmitR GMM W873 BWM W5"
```

- b. Ändern des Arbeitsverzeichnisses über: Aktiviere Console => Datei => Verzeichnis Ändern ... Dann den Ordner aussuchen, der das Arbeitsverzeichnis sein soll, und OK klicken ODER mit `setwd()` das Arbeitsverzeichnis definieren. Wenn `setwd()` genutzt wird, muss der gesamte **Pfad** bis zum Arbeitsverzeichnis angegeben werden (in Anführungszeichen und mit / und nicht mit \).
- c. Einlesebefehl: `Objektnamen <- read.csv("Datei.csv")`

```
# Das Beispiel oben (hier auskommentiert):  
# setwd("C:/Users/sturm/Desktop/dataR")      # setze das Arbeitsverzeichnis  
# data <- read.csv("patients.csv")           # Einlesen der Datei, Objektdefinition  
# data                                         # Ausgabe des Objektes data
```

Der Befehl `read.csv()` ist nur ein Einlesebefehl. R gibt das Objekt nur aus, wenn man den Objektnamen (hier `data`) auch ausführt.

```
summary(data)      # Ein erster Überblick über data
```

```
##      fem      age      weight  
## Min.   :0.000   Min.   :16.0   Min.   :58.0  
## 1st Qu.:0.000   1st Qu.:32.0   1st Qu.:60.5  
## Median :1.000   Median :50.0   Median :63.0  
## Mean   :0.571   Mean   :47.3   Mean   :70.7  
## 3rd Qu.:1.000   3rd Qu.:60.5   3rd Qu.:81.5  
## Max.   :1.000   Max.   :80.0   Max.   :90.0
```

Die Bezeichnung des eingelesenen Objektes in R (hier `data`) ist beliebig. ABER: Objekte sollten NIE so genannt werden, wie Variablen in der einzulesenden Datei heißen. Nachdem ein Objekt in R definiert wurde, muss man auf die Variablen in diesem Objekt zugreifen.

Wir wollen nun auf einzelne Variablen im Objekt `data` zugreifen.

Methode 1: Zugriff mit `$`-Symbol:

```
names(data)      # Variablennamen im Objekt data
```

```
## [1] "fem"    "age"    "weight"
```

```
data$age         # Zugriff auf age mit $
```

```
## [1] 20 66 80 44 50 55 16
```

```
mean(data$age)   # z.B. Mittelwert von age
```

```
## [1] 47.286
```

Methode 2: Verwendung des Befehls `attach()`:

```
attach(data) # erklärt data zum "aktuellen" Objekt
weight      # Ausgabe der Variablen weight
```

```
## [1] 58 63 62 59 85 90 78
```

```
mean(age)    # Mittelwert von age
```

```
## [1] 47.286
```

```
detach(data) # macht attach() rückgängig
```

In diesem Dokument nutzen wir sowohl `attach()` als auch das `$` Zeichen, um auf Variablen zuzugreifen.
Ein paar nützliche Befehle für **Datentabellen** in R:

```
attach(data); length(age)
```

```
## [1] 7
```

```
data[4,2]     # 4. Zeile und 2. Spalte
```

```
## [1] 44
```

```
data[1:3,]    # die ersten 3 Zeilen der gesamten Datentabelle
```

```
##   fem age weight
## 1   0  20     58
## 2   1  66     63
## 3   0  80     62
```

```
data[3,]      # 3. Zeile
```

```
##   fem age weight
## 3   0  80     62
```

```
data[,c(2,3)] # Spalte 2 und 3
```

```
##   age weight
## 1  20     58
## 2  66     63
## 3  80     62
## 4  44     59
## 5  50     85
## 6  55     90
## 7  16     78
```

```
dim(data)      # Zahl Zeilen (7) und Zahl Spalten (3) von data
```

```
## [1] 7 3
```

```
detach(data)
```

Manchmal ist es sinnvoll, die Ausgabe zu runden. Das geht leicht mit `round()`.

```
x <- 1:4      # Definition x  
x/3
```

```
## [1] 0.33333 0.66667 1.00000 1.33333
```

```
round(x/3, 2) # Runde den Vektor x/3 auf zwei Kommastellen
```

```
## [1] 0.33 0.67 1.00 1.33
```

Wenn man Werte für X pro Zeitpunkt t hat, ist der Befehl `diff()` hilfreich. Der Befehl `diff()` berechnet $X_t - X_{t-1}$. Damit lässt sich dann leicht die Wachstumsrate in Prozent bestimmen mit $g_t = 100 * (X_t - X_{t-1}) / X_{t-1}$.

```
t <- 1:4; X <- c(10, 12, 14, 16) # Definition Werte für t und X  
tab <- data.frame(t, X); tab    # Erzeuge eine Datentabelle
```

```
##   t  X  
## 1 1 10  
## 2 2 12  
## 3 3 14  
## 4 4 16
```

```
delta <- diff(X); delta      # Differenzenbildung, hier nur 3 Werte
```

```
## [1] 2 2 2
```

```
g <- 100*diff(X)/X[1:3]; g    # Wachstumsrate g in Prozent
```

```
## [1] 20.000 16.667 14.286
```

```
g <- c(NA, g); g             # NA für t=1
```

```
## [1]      NA 20.000 16.667 14.286
```

```
tab <- cbind(tab, g); tab     # Schreibe g in die Datentabelle tab
```

```
##   t  X      g  
## 1 1 10     NA  
## 2 2 12 20.000  
## 3 3 14 16.667  
## 4 4 16 14.286
```

Manchmal will man die Zeilen einer Tabelle **sortieren** nach einer Variable.

```
age <- c(19, 22, 24, 46, 53)           # Alter in Jahre
Tn <- c("Pia", "Klaus", "Dieter", "Horst", "Uschi") # Namen der Tn
income <- c(25, 31, 17, 33, 67)       # Einkommen in 1000 Euro
tab <- data.frame(Tn, age, income); tab # Erzeuge eine Datentabelle
```

```
##      Tn age income
## 1   Pia  19     25
## 2 Klaus  22     31
## 3 Dieter 24     17
## 4 Horst 46     33
## 5 Uschi 53     67
```

```
# die 3 ältesten Tn
sorted_tab <- tab[order(tab$age, decreasing = TRUE), ]
top_3_age <- head(sorted_tab, 3); top_3_age
```

```
##      Tn age income
## 5 Uschi 53     67
## 4 Horst 46     33
## 3 Dieter 24     17
```

```
# die 3 ärmsten (in Einkommen) Tn
sorted_tab <- tab[order(tab$income, decreasing = FALSE), ]
top_3_inc <- head(sorted_tab, 3); top_3_inc
```

```
##      Tn age income
## 3 Dieter 24     17
## 1   Pia  19     25
## 2 Klaus  22     31
```

Last but not least: Die **Hilfe in R** wird mit `?Befehl` aufgerufen. Dies setzt voraus, dass man den Befehl kennt. Beispiele sind `?hist()` und `?mean()`.

Bedingte Auswertungen

Häufig will man eine bedingte Auswertung durchführen, z.B. für einen Datensatz mit Männern und Frauen das mittlere Alter aller Frauen und aller Männer getrennt voneinander bestimmen. R bietet hierfür mehrere Methoden an.

Methode über eine Bedingung in `[]`-Klammer:

```
data$age[data$fem == 1]           # alle Beobachtungen für Alter, wenn fem = 1
```

```
## [1] 66 44 50 16
```

```
mean(data$age[data$fem == 1])    # mittleres Alter aller Frauen
```

```
## [1] 44
```

```
mean(data$age[data$fem == 0]) # mittleres Alter aller Männer
```

```
## [1] 51.667
```

Methode über subset():

```
data_fem <- subset(data, data$fem == 1, ) # nur Frauen aus data und alle Spalten
data_fem
```

```
##   fem age weight
## 2   1  66     63
## 4   1  44     59
## 5   1  50     85
## 7   1  16     78
```

```
mean(data_fem$age)
```

```
## [1] 44
```

```
data_m <- subset(data, fem == 0, ) # nur Männer aus data und alle Spalten
data_m
```

```
##   fem age weight
## 1   0  20     58
## 3   0  80     62
## 6   0  55     90
```

```
mean(data_m$age)
```

```
## [1] 51.667
```

Man kann auch Bedingungen mit UND (&) oder ODER (|) verknüpfen. Zum Beispiel: Wir wollen alle Frauen, die älter sind als 50 Jahre, ausgeben lassen (vgl. Exkurs: Logische Bedingungen):

```
data_fem50 <- subset(data, data$fem == 1 & data$age > 50, ); data_fem50
```

```
##   fem age weight
## 2   1  66     63
```

```
data[data$fem == 1 & data$age > 50, ] # auch das geht mit []-Klammer
```

```
##   fem age weight
## 2   1  66     63
```

Generell kann man sich merken, dass runde Klammern () in R für Funktionen genutzt werden, z.B. bei subset() oder summary(). Eckige Klammern [] werden für bedingte Auswertungen oder Matrixangaben genutzt, z.B. bei data[1:3,].

Qualitative Daten (alle Module)

Häufigkeitstabelle

Für ein qualitatives Merkmal wird zunächst die absolute Häufigkeit n_i der $i = 1, \dots, m$ Merkmalsausprägungen bestimmt und mit einer Häufigkeitstabelle ausgegeben. In der Häufigkeitstabelle wird dann für jede Merkmalsausprägung i der Wert n_i angegeben. Es gilt $\sum_{i=1}^m n_i = n$.

Betrachten wir das folgende Beispiel:

```
setwd("C:/Users/sturm/Desktop/dataR")      # Definiere das Arbeitsverz.
data <- read.csv("profession.csv")          # Einlesen der Datei
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/profession.csv")
data[1:3,]                                  # Ausgabe Zeile 1 bis 3, alle Spalten
```

```
##   Gender   Sector           Degree
## 1 female education      university
## 2 female marketing vocational education
## 3   male education      university
```

```
attach(data)                                # Erkläre data zum aktuellen Objekt
```

Das Objekt `data` hat drei Merkmale bzw. Variablen (`Gender`, `Sector`, `Degree`), die alle qualitativ sind (nominal skaliert). Der Befehl `table()` liefert die absolute Häufigkeitstabelle für eine Variable.

```
table(Gender)    # Häufigkeitstabelle für Gender
```

```
## Gender
## female   male
##      14     16
```

```
sum(table(Gender))
```

```
## [1] 30
```

14 von 30 Befragten sind Frauen. Die Häufigkeitstabellen für `Sector` und `Degree` ergeben sich entsprechend.

```
table(Sector); table(Degree)
```

```
## Sector
## automobile education marketing transport
##           6         11           6           7
```

```
## Degree
##           none           university vocational education
##           6           13           11
```

Mit `table()` kann auch leicht ermittelt werden, wie viele Beobachtungen einer Reihe eine bestimmte Bedingung erfüllen. Betrachten wir die Zahlenreihe $\{3, 9, 1, 5, 6, 7, 10, 4, 2\}$. Wir wollen wissen, ob ein Element der Zahlenreihe kleiner oder gleich 4 ist. Das Ergebnis dieser Abfrage ist entweder `TRUE` oder `FALSE` und diese Ausprägungen können wieder leicht mit `table()` ausgewertet werden.

```
x <- c(3, 9, 1, 5, 6, 7, 10, 4, 2)
x <= 4
```

```
## [1] TRUE FALSE TRUE FALSE FALSE FALSE TRUE TRUE
```

```
table(x <= 4)
```

```
##
## FALSE TRUE
##      5    4
```

Eine absolute Häufigkeitsverteilung kann mit `prop.table()` in eine relative Häufigkeitsverteilung überführt werden. Die relative Häufigkeitsverteilung stellt die relativen Häufigkeiten $h_i = n_i/n$ für jede Merkmalsausprägung $i = 1, \dots, m$ dar. Es gilt $\sum_{i=1}^m h_i = 1$. Hier im Beispiel:

```
prop.table(table(Gender))      # greift auf table() zu
```

```
## Gender
## female   male
## 0.46667 0.53333
```

47% der Befragten sind Frauen, 53% sind Männer.

```
sum(prop.table(table(Gender))) # Summe der rel. Häufigkeiten muss 1 sein
```


```
## [1] 1
```

Barplot

Häufigkeitstabellen werden graphisch mit Hilfe eines Barplots (Säulendiagramm) dargestellt. Der Befehl für ein Säulendiagramm ist `barplot()`, wobei eine Häufigkeitstabelle als Argument der Funktion zu benutzen ist. Der Barplot für das Merkmal `Sector` ist hier:

```
barplot(prop.table(table(Sector)), main = "Abbildung 1", col = "green",
names.arg = c("Automobil", "Bildung", "Marketing", "Transport"),
xlab = "Sektor", ylab = "Anteil", ylim = c(0, 0.4))
```

Abbildung 1



Der Befehl wird ergänzt durch eine Überschrift (`main`), Farbe (`col`), Bezeichnung der Merkmalsausprägungen (`names.arg`), Achsenbezeichnungen für x- und y-Achse (`xlab` und `ylab`) und die Skalierung der y-Achse (`ylim`). Die y-Achse sollte so skaliert sein, dass der größte Wert der Skala (hier 0.4) größer ist als die größte relative Häufigkeit (hier ca. 0.37 für Bildung). Zahlenwerte könnten im Barplot mit `text()` ergänzt werden.

Die Ausprägung Bildung ist hier offensichtlich der **Modus**, d.h., der Sektor Bildung hat mit ca. 37% die größte relative Häufigkeit.

Kontingenztafel

Bislang haben wir eindimensionale qualitative Daten (also nur ein Merkmal) betrachtet. Nun gehen wir zu zweidimensionalen qualitativen Daten (zwei Merkmale) über. Zweidimensionale qualitative Daten werden mit einer Kontingenztafel dargestellt. Präziser: Eine Kontingenztafel stellt die gemeinsame Verteilung von zwei qualitativen Merkmalen dar. Der Wert n_{ij} (mit i als Zeile und j als Spalte) in der Tabelle stellt die gemeinsame absolute Häufigkeit für $X = X_i$ und $Y = Y_j$ dar, also $n_{ij} = \text{absH}(X = X_i \ \& \ Y = Y_j)$. Der Befehl für eine Kontingenztafel ist wieder `table()`, nur das jetzt zwei Merkmale angegeben werden.

```
table(Gender, Sector) # Kontingenztafel für Gender und Sector
```

```
##      Sector
## Gender  automobile education marketing transport
## female      1         8         2         3
## male        5         3         4         4
```

Üblicherweise werden Kontingenztabellen mit **Randverteilungen** dargestellt.

```
addmargins(table(Gender, Sector)) # mit Randverteilungen
```

```
##           Sector
## Gender  automobile education marketing transport Sum
##  female          1          8          2          3  14
##   male          5          3          4          4  16
##   Sum           6         11          6          7  30
```

In der Kontingenztabelle oben sind neben der gemeinsamen Verteilung auch die Randverteilungen für **Gender** und **Sector** mit `addmargins()` dargestellt. Aus der gemeinsamen Verteilung ist z.B. ersichtlich, dass 5 Befragte Männer sind und im Auto-Sektor arbeiten. 8 Befragte sind Frauen und arbeiten im Bildungssektor. Aus den Randverteilungen ergibt sich z.B., dass 11 Befragte im Bildungssektor arbeiten und 16 Männer an der Befragung teilgenommen haben.

Bislang war die Kontingenztabelle über die absoluten Häufigkeiten definiert. Wir können die Kontingenztabelle aber auch leicht mit `prop.table()` in relativen Häufigkeiten schreiben:

```
addmargins(prop.table(table(Gender, Sector))) # greift auf table() zu
```

```
##           Sector
## Gender  automobile education marketing transport      Sum
##  female  0.033333  0.266667  0.066667  0.100000 0.466667
##   male   0.166667  0.100000  0.133333  0.133333 0.533333
##   Sum    0.200000  0.366667  0.200000  0.233333 1.000000
```

Interpretation, z.B.: 10% aller Teilnehmer sind Männer und arbeiten im Bildungsbereich.

Bedingte relative Häufigkeiten

Häufig ist es notwendig, bedingte relative Häufigkeiten zu bestimmen. Wir schreiben für die relative Häufigkeit von A unter der Bedingung B: $\text{relH}(A|B)$. Zum Beispiel könnte von Interesse sein, wie viel Prozent aller Frauen im Bildungssektor arbeiten. Mit Blick auf die Kontingenztabelle oben ergibt sich: $\text{relH}(\text{education}|\text{female}) = 8/14 = 57\%$. Oder: Wie viel Prozent aller Mitarbeiter im Transportsektor sind Frauen? Hier: $\text{relH}(\text{female}|\text{transport}) = 3/7 = 43\%$. Wir können die bedingten relativen Häufigkeiten auch ausgeben lassen. Man muss dabei entscheiden, ob Zeile (hier: **Gender**) oder Spalte (hier: **Sector**) die Bedingung sein soll.

```
addmargins(prop.table(table(Gender, Sector), 1)) # 1 = Zeile als Bedingung
```

```
##           Sector
## Gender  automobile education marketing transport      Sum
##  female  0.071429  0.571429  0.142857  0.214286 1.000000
##   male   0.312500  0.187500  0.250000  0.250000 1.000000
##   Sum    0.383929  0.758929  0.392857  0.464286 2.000000
```

Die Summe der bedingten relativen Häufigkeiten ist 1. Interpretation, z.B.: 57% aller Frauen arbeiten im Bildungssektor, aber nur 7% der Frauen sind im Auto-Sektor tätig.


```
addmargins(prop.table(table(Gender, Sector), 2)) # 2 = Spalte als Bedingung
```

```
##          Sector
## Gender  automobile education marketing transport Sum
## female   0.16667   0.72727   0.33333   0.42857 1.65584
## male     0.83333   0.27273   0.66667   0.57143 2.34416
## Sum       1.00000   1.00000   1.00000   1.00000 4.00000
```

Interpretation, z.B.: 67% aller Beschäftigten im Marketing sind Männer, aber nur 33% aller Beschäftigten im Marketing sind Frauen. Wir stellen hier fest, dass sich die bedingten relativen Häufigkeiten z.T. deutlich unterscheiden. Dies deutet darauf hin, dass beide Merkmale (**Gender** und **Sector**) nicht unabhängig voneinander sind (vgl. Definition von statistischer Unabhängigkeit).

Exkurs: Abbildungen für Kontingenztabellen Üblicherweise stellt man auch die bedingten relativen Häufigkeiten mit einem Barplot (Säulendiagramm) dar. Betrachten wir das Beispiel mit **Gender** und **Sector**.

```
barplot(prop.table(table(Gender, Sector), 2), xlab = "Sector", ylab = "Proportion",
        ylim = c(0, 1), beside = TRUE, col = c("pink", "blue"),
        legend = row.names(table(Gender, Sector)))
```



Die Legende wird mit `legend` angegeben, wobei wir mit `row.names` auf die Zeilennamen der Kontingenztafel für **Gender** und **Sector** (vgl. oben) zugreifen. Die Säulen für die bedingten relativen Häufigkeiten werden nebeneinander (`beside`) dargestellt und nicht übereinander (das ist Geschmackssache). Für jede Ausprägung von **Sector** addieren sich die Säulen (relative Häufigkeiten) zu 100%. Offensichtlich unterscheiden sich die bedingten Verteilungen zwischen den Sektoren. Während im Auto-Sektor das Verhältnis von Männern zu Frauen ca. 80 zu 20 ist, ist es im Bildungssektor ca. 30 zu 70. Damit wird offensichtlich, dass **Gender** und **Sector** nicht unabhängig voneinander sind (also hier das Geschlecht einen Effekt auf die Berufswahl hat).

Quantitative Daten (alle Module)

In diesem Kapitel beschäftigen wir uns mit Verteilungen von quantitativen Daten und mit Lage- und Streuungsmaßen.

Darstellung von Verteilungen

Zur graphischen Darstellung der Verteilung eines quantitativen Merkmals werden Histogramm und Verteilungsfunktion genutzt.

Histogramm Für die Darstellung einer Verteilung im Histogramm werden Klassen der Breite Δ_i definiert. Pro Klasse $i = 1, \dots, k$ wird dann die absolute Häufigkeit n_i ("frequency") an Beobachtungen in dieser Klasse ausgegeben. Im Histogramm sind dann auf der x-Achse die Größenklassen des Merkmals (mit Breite Δ_i) und auf der y-Achse die Zahl der Beobachtungen pro Klasse (n_i) dargestellt. Es gilt $\sum_{i=1}^k n_i = n$.

Anhand des Histogramms kann die **Verteilung** analysiert werden hinsichtlich der Kriterien:

- Form wie Symmetrie bzw. Asymmetrie (z.B. links- oder rechtssteil)
- Modus (Klasse mit der größten relativen Häufigkeit)
- Ausreißer (auffällige Beobachtungen)

Betrachten wir ein Beispiel:

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
s.data <- read.csv("student.csv")
# s.data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/student.csv")
s.data[1:2, 1:8]; dim(s.data)
```

```
##   fem age height weight shoe sport veg_fruits income
## 1   0  20   175     58   41     3         0      300
## 2   1  20   168     63   39     1         5      700
```

```
## [1] 711 10
```

Bevor wir ein Histogramm erstellen, ist `summary()` nützlich. Dieser Befehl liefert sechs Werte (Min, Q_1 , Median, arithmetisches Mittel, Q_3 , Max) und zeigt an, ob es NAs (not available, fehlende Werte) gibt.


```
summary(s.data$age) # summary für age
```

```
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs
##   15.0   21.0   23.0   23.3   25.0   88.0       4
```

Offensichtlich gibt es hier Werte (15, 88), die vermutlich fehlerhafte Eingaben sind. Betrachten wir das Histogramm:


```
hist(s.data$age, xlab = "Age in years") # Standardhistogramm mit  $n_i$ 
```

Histogram of s.data\$age



Die Klassenbreite (hier $\Delta_i = 5$) wird automatisch gewählt. Eine Beobachtung in der letzten Klasse (85, 90] ist offensichtlich ein Fehler und sollte nicht weiter berücksichtigt werden (den Wert 15 in der ersten Klasse [15, 20] lassen wir dagegen zu).

```
hist(s.data$age[s.data$age < 50], xlab = "Age in years", ylim = c(0, 200)) # Histogramm für age < 50
```



Die Klassenbreite ist nun $\Delta_i = 2$. Die Verteilung ist nicht symmetrisch, sondern linkssteil (bzw. skewed to the right). Die modale Klasse ist (20, 22] Jahre. Es gibt zwei Ausreißer am rechten Rand der Verteilung (Alter > 35 Jahre).

R speichert eine Reihe von Informationen zu einem Histogramm ab, wenn man mit `hist()` ein Objekt definiert. Ein paar Informationen zum Histogramm von `age`:

```
H <- hist(s.data$age[s.data$age < 50], plot = FALSE) # Definiere Objekt, keine Darstellung
H$breaks      # Klassengrenzen mit (Untergrenze, Obergrenze], aber 1. Klasse mit []

## [1] 14 16 18 20 22 24 26 28 30 32 34 36 38 40

H$counts      # Ausgabe Beob. n_i pro Klasse i

## [1] 1 9 157 169 155 91 70 35 14 3 0 1 1

sum(H$counts) # Zahl der Beob.


## [1] 706

table(s.data$age[s.data$age < 50] > 20 & s.data$age[s.data$age < 50] <= 22) # Beob. in (20, 22]

##
## FALSE TRUE
## 537 169
```

Die Klassengrenzen des Histogramms können leicht geändert werden.

```
hist(s.data$age[s.data$age < 50], breaks = seq(10, 50, 5),  
     ylim = c(0, 400), xlab = "Age in years") # Klassengrenzen definieren
```




Wenn man die Klassengrenzen selbst definiert, ist darauf zu achten, dass alle Beobachtungen von den Klassen auf der x-Achse erfasst werden (sonst gibt es eine Fehlermeldung).

Ein weiteres Beispiel: Wir wollen 1000 Zufallszahlen aus der $N(0,1)$ -Verteilung (auch als Standardnormalverteilung bezeichnet) ziehen und die Verteilung mit Hilfe eines Histogramms graphisch darstellen. Der Zufallszug wird mit `rnorm()` durchgeführt. Dabei steht `r` für “random” und `norm` für “normal distribution”. Um diesen Zufallszug reproduzierbar zu machen, setzen wir vorab `set.seed()`. Dabei ist die im Befehl verwendete Zahl beliebig, es muss nur die gleiche sein wie im zu reproduzierenden Befehl (hier die 4).

```
set.seed(4) # sichert Reproduzierbarkeit des Zufallszugs  
x <- rnorm(1000, mean = 0, sd = 1) # 1000 Zufallszahlen aus N(0,1)  
x[1:5]     # die ersten 5 Werte von x
```

```
## [1]  0.21675 -0.54249  0.89114  0.59598  1.63562
```

```
hist(x)
```



```
summary(x)    # arithm. Mittel ist approx. 0
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## -2.8396 -0.6661 -0.0398 -0.0344  0.6350  3.1742
```

```
sd(x)         # Standardabweichung, sollte nah an 1 sein
```

```
## [1] 0.9693
```

Das Histogramm ist symmetrisch um Null (= Modus) und hat eine Glockenform. Es gibt keine Ausreißer.

Wenn eine Variable X einer Normalverteilung folgt, schreibt man dafür $X \sim N(\mu, \sigma)$ mit μ als arithmetisches Mittel und σ als Standardabweichung. Für die Standardnormalverteilung gilt dann $Z \sim N(0, 1)$. Die Standardabweichung ist ein Maß für die Streuung der Beobachtungen (vgl. unten).

Eine wichtige Regel für die Verteilung von Zufallsvariablen aus $N(\mu, \sigma)$ ist die **“Empirical Rule”**. Diese Regel besagt: Bei einer normalverteilten Zufallsvariablen liegen im Intervall $\mu \pm 2\sigma$ ca. 95% der Beobachtungen.

Wir betrachten hier unseren Vektor `x`. Die logische Abfrage und Auswertung erfolgt über `table()`.


```
prop.table(table((x <= 2) & (x >= -2))) # Abfrage einer Bedingung
```

```
##
## FALSE  TRUE
## 0.041 0.959
```

Eine solche logische Abfrage kann sehr nützlich sein. Wir erzeugen mit der Abfrage ein qualitatives Merkmal mit den Ausprägungen `TRUE` und `FALSE` und dieses wird mit `table()` ausgewertet.

Verteilungsfunktion Die Verteilungsfunktion der Variablen X , $F(x)$, ist definiert als $F(x) = \text{relH}(X \leq x)$. Sie gibt also für den Wert x der Variablen X an, wie viel Prozent der Beobachtungen von X kleiner oder gleich x sind. Betrachten wir die Verteilungsfunktion für den Vektor `x` (vgl. Zufallsexperiment oben). Der Befehl lautet `plot.ecdf()`, wobei `ecdf` für “empirical cumulative distribution function” steht.

```
plot.ecdf(x)  # Plot der ecdf
```



Betrachten wir $F(x)$ für einen bestimmten Wert von x . Es sei $x = -1$.

```
F_x <- ecdf(x) # Definition von F
F_x(-1)        # Abfrage des Funktionswertes von F
```

```
## [1] 0.162
```


```
prop.table(table(x <= -1)) # Alternative zur Berechnung von F
```

```
##
## FALSE  TRUE
## 0.838 0.162
```

Interpretation: 16.2% der Beobachtungen von X sind kleiner oder gleich -1 (das kann man auch oben in der Abbildung ablesen). Damit sind 83.8% der Beobachtungen von X größer als -1. Die Verteilungsfunktion wird häufig dann benutzt, wenn man mehrere Verteilungen vergleichen möchte.

Betrachten wir ein Beispiel.

```
setwd("C:/Users/sturm/Desktop/dataR")           # setze das Arbeitsverzeichnis
s.data <- read.csv("student.csv")
# s.data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/student.csv")
plot.ecdf(s.data$height[s.data$fem == 1], col = "red", xlab = "Größe in cm") # Frau = rot
F_weight_male <- ecdf(s.data$height[s.data$fem == 0])           # F für Mann
lines(F_weight_male, col = "blue")                             # plot F für Männer = blau
abline(v = 180, lty = 2)                                       # vertikale Linie bei 180
legend(250, 0.55, pch = c(16,16), col = c("red","blue"), c("Frauen","Männer")) # Legende
```



Im Plot oben wird zuerst die Verteilungsfunktion der Frauen gezeichnet mit `plot.ecdf()`. Dann wird die Verteilungsfunktion der Männer mit `ecdf()` erzeugt und zusätzlich mit `lines()` über den Plot für die Frauen gelegt. In der Legende mit `legend()` wird das Symbol mit `pch` definiert (hier 16 für einen Punkt). Da es zwei Ausprägungen gibt (für Frauen und Männer), werden die Angaben in der Legende mit Vektoren über `c()` definiert.

Offensichtlich ist eine Beobachtung bei den Frauen ein Fehler (den wir hier nicht korrigieren). Die Verteilungsfunktion der Männer liegt - im relevanten Bereich - unter der der Frauen. Für eine gegebene Größe in cm liegt der Anteil der Männer, die kleiner oder gleich dieser Größe sind, unter dem der Frauen. Zum Beispiel: Der Anteil der Männer (Frauen), die kleiner oder gleich 180 cm sind (vgl. die vertikale Linie), liegt bei etwa 40% (90%).

Quartile und Quantile Es gibt **drei Quartile**, Q_1 , Q_2 und Q_3 , die eine geordnete Reihe von Zahlen in vier möglichst gleich große Abschnitte aufteilen. Das zweite Quartil, Q_2 , ist die Zahl, für die gilt, dass 50% der Beobachtungen kleiner oder gleich Q_2 sind und 50% größer oder gleich Q_2 . Q_2 wird auch **Median** genannt. Entsprechend gilt für Q_1 (Q_3), dass 25% (75%) der Beobachtungen kleiner oder gleich Q_1 (Q_3) sind und 75% (25%) größer oder gleich Q_1 (Q_3).

Betrachten wir als Beispiel die Werte für die Körpergröße der Studierenden getrennt nach Frauen und Männern.

```
summary(s.data$height[s.data$fem == 1 & s.data$height < 250])
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs
##      150     163     168     167     171     189         4
```

```
summary(s.data$height[s.data$fem == 0 & s.data$height < 250])
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs
##      151     176     181     181     187     203         3
```

Interpretation: 25% aller Frauen sind 163 cm groß oder kleiner. Bei den Männern sind die 25% kleinsten 176 cm groß oder kleiner.

Man kann das Konzept der Quartile verallgemeinern zum Konzept der Quantile. Ein **q-Quantil** mit $0 < q < 1$ ist die Zahl $x_{[q]}$, für die gilt $q * 100 \leq x_{[q]}$ und $(1 - q) * 100 \geq x_{[q]}$. Zum Beispiel ist das 10%-Quantil der Variable X , $x_{[0.1]}$, die Zahl, für die gilt: 10% der Beobachtungen von X sind kleiner oder gleich $x_{[0.1]}$ und 90% der Beobachtungen von X sind größer oder gleich $x_{[0.1]}$. Der Befehl `quantile()` liefert in R die Quantile.

```
quantile(s.data$height[s.data$fem == 1 & s.data$height < 250], na.rm = TRUE) # NA raus, vgl. bei mean()
```

```
##      0%      25%      50%      75%     100%
## 150.00 163.00 168.00 171.25 189.00
```

```
quantile(s.data$height[s.data$fem == 1 & s.data$height < 250], seq(0, 1, 0.1), na.rm = TRUE)
```

```
##      0%      10%      20%      30%      40%      50%      60%      70%      80%      90%     100%
##      150      160      162      164      165      168      169      170      172      175      189
```

Interpretation, z.B.: 10% aller Frauen sind 160 cm groß oder kleiner. Die 10% größten Frauen sind mindestens 175 cm groß.

Lagemaße

Lagemaße geben Auskunft über die typische Beobachtung einer Verteilung. Die zwei bekanntesten Lagemaße sind das arithmetische Mittel und der Median.

Arithmetisches Mittel Das arithmetische Mittel ist das “klassische” Lagemaß (vgl. zu Eigenschaften das Lehrbuch). Es ist definiert als die Summe aller Merkmalsausprägungen geteilt durch die Zahl der Merkmalsausprägungen:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Als Beispiel betrachten wir die ganzen Zahlen von 1 bis 100.

```
x <- 1:100      # die ganzen Zahlen von 1 bis 100
sum(x)/length(x)
```

```
## [1] 50.5
```

```
mean(x)        # Funktion für das arithm. Mittel
```

```
## [1] 50.5
```

```
summary(x)     # weitere Lagemaße neben dem arithm. Mittel
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1.0   25.8   50.5   50.5   75.2   100.0
```

Wenn eine Zahlenreihe NAs enthält, müssen diese vor der Berechnung des arithmetischen Mittels mit `mean()` (mit `na.rm`) entfernt werden. Bei `summary()` ist dies nicht nötig. Der folgende Befehl liefert das arithmetische Mittel der Körpergröße für alle Frauen (mit und ohne den Aureißer bei 290 cm).

```
summary(s.data$height[s.data$fem == 1])
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NAs
##      150   163   168   168   172   290     4
```

```
mean(s.data$height[s.data$fem == 1 & s.data$height < 250], na.rm = TRUE)
```

```
## [1] 167.46
```

```
summary(s.data$height[s.data$fem == 1 & s.data$height < 250], na.rm = TRUE)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NAs
##      150   163   168   167   171   189     4
```

Median Der Median ist das 50%-Quantil (oder auch 2. Quartil, Q_2 oder $x_{[0.5]}$ genannt). In der geordneten Reihe der Beobachtungen liegt der Median genau in der Mitte. Er wird als Lagemaß bei nicht symmetrischen Verteilungen oder bei Verteilungen mit Ausreißern verwendet.

Betrachten wir die folgenden Beispiele:

```
x1 <- c(1:5, 10)      # definiere x1
x2 <- c(1:5, 1000)    # definiere x2
x3 <- c(1:6, 10)      # definiere x3
x4 <- c(1:6, 1000)    # definiere x4
median(x1); median(x2); median(x3); median(x4)
```

```
## [1] 3.5
```

```
## [1] 3.5
```


```
## [1] 4
```

```
## [1] 4
```

Ein Beispiel für eine linkssteile Verteilung (skewed to the right) ist die χ^2 -Verteilung (gesprochen “Chi-Quadrat”) mit 5 Freiheitsgraden (df). Hierfür werden 5 Zufallsvariablen aus der $N(0,1)$ -Verteilung quadriert und aufsummiert. Hier ist der Median deutlich kleiner als das arithmetische Mittel, welches nach rechts verzerrt ist.

```
set.seed(4)           # sichert Reproduzierbarkeit
chi <- rchisq(1000, 5) # 1000 Zufallszahlen aus der Chi2 mit df = 5
hist(chi)              # Histogramm von chi
```

Histogram of chi



```
summary(chi)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      0.15   2.63   4.20   4.89   6.47   25.35
```

Der Median ist robust bzgl. der Schiefe der Verteilung und der Existenz von Ausreißern. Das arithmetische Mittel wird hingegen stark von der Schiefe der Verteilung bzw. von der Existenz von Ausreißern beeinflusst. Für linkssteile Verteilungen (skewed to the right) gilt $\bar{x} > x_{[0.5]}$ und für rechtssteile (skewed to the left) Verteilungen $\bar{x} < x_{[0.5]}$.

Streuungsmaße

Streuungsmaße werden benutzt, um die Variabilität von Merkmalsausprägungen zu messen. Wir betrachten hier drei Streuungsmaße: (1) Interquartilsabstand ($IQR = \text{Interquartile Range}$), (2) Varianz und (3) Standardabweichung.

IQR Der IQR ist definiert als $IQR = Q_3 - Q_1$. Er gibt also die Breite des Intervalls an, in dem sich die mittleren 50% aller Beobachtungen befinden. Bei einem größeren IQR streuen die mittleren 50% der Daten stärker. Man kann den IQR z.B. über `summary()` bestimmen oder auch über `IQR()`. Durch Unterschiede bei der Approximation kann es hier zu leicht unterschiedlichen Angaben kommen.

```
summary(chi) # IQR = Q3 - Q1 = 6.47 - 2.63 = 3.84, leichte Abweichung zu IQR()
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      0.15   2.63   4.20   4.89   6.47   25.35
```


```
IQR(chi)      # leichte Abweichung zu summary()
```

```
## [1] 3.8389
```

Man kann den IQR auch graphisch mit Hilfe der Verteilungsfunktion darstellen.

```
plot.ecdf(chi, main = "F für Chi2 (df= 5)")      # Plot der ecdf von chi
abline(h = c(0.25, 0.75), lty = 2, col = "red")  # Hilfslinie horizontal
abline(v = c(2.6, 6.5), lty = 2, col = "red")    # Hilfslinie vertikal
arrows(2.6, 0.1, 6.5, 0.1, length = 0.15, code = 3) # Hilfslinie Pfeil
text(4.6, 0.18, "IQR")                          # Text
```

F für Chi2 (df= 5)



Varianz Die Varianz der Stichprobe, s^2 , ist die mittlere quadrierte Abweichung der n Elemente in der Stichprobe von ihrem arithmetischen Mittel $\bar{x}$, d.h.

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Die Varianz der Grundgesamtheit, σ^2 , ist die mittlere quadrierte Abweichung der N Elemente in der Grundgesamtheit von ihrem arithmetischen Mittel μ , d.h.

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

Üblicherweise ist σ^2 unbekannt.

Daher wird normalerweise die Varianz σ^2 geschätzt mit

$$\hat{\sigma}^2 = \frac{n}{n-1} s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Man kann zeigen, dass unter bestimmten Bedingungen $\hat{\sigma}^2$ eine erwartungstreue und konsistente Schätzung für σ^2 ist (vgl. Lehrbuch). Wir bezeichnen $\hat{\sigma}^2$ daher auch als geschätzte Varianz der Grundgesamtheit. Sie wird mit `var()` berechnet. R betrachtet also Daten immer als Stichprobeninformationen, mit denen man etwas über die Grundgesamtheit lernen möchte.

Betrachten wir ein einfaches Beispiel.

```
U <- c(1:10, 25, 40) # Definiere das Objekt U
var(U)                # geschätzte Varianz der Grundgesamtheit
```

```
## [1] 128.18
```

```
n <- length(U)
sum((U - mean(U))^2)/(n-1)
```

```
## [1] 128.18
```

Standardabweichung Die Standardabweichung der Grundgesamtheit, σ , ist die Wurzel der Varianz, d.h.

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

Da σ normalerweise unbekannt ist, wird diese Standardabweichung geschätzt mit

$$\hat{\sigma} = \sqrt{\left(\frac{n}{n-1}\right)s} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Wir bezeichnen $\hat{\sigma}$ auch als **geschätzte Standardabweichung der Grundgesamtheit**. $\hat{\sigma}$ ist unter bestimmten Bedingungen (vgl. Lehrbuch) ein erwartungstreuer und konsistenter Schätzwert für σ .

Für das Beispiel oben zur Varianz ist:

```
sd(U) # geschätzte Standardabweichung der Grundgesamtheit
```

```
## [1] 11.322
```

```
sqrt(sum((U - mean(U))^2)/(n-1))
```

```
## [1] 11.322
```

Boxplot


Ein Boxplot ist eine kompakte Methode, um die Verteilung eines quantitativen Merkmals darzustellen. Ein Boxplot beinhaltet folgende Informationen: Minimum, Q_1 , Median, Q_3 , Maximum und ggf. Ausreißer. Neben der Spannweite ($\text{range} = \text{max} - \text{min}$) wird damit auch der IQR dargestellt und man hat die Information, in welchem Intervall die mittleren 50% der Beobachtungen liegen und wie diese Werte verteilt sind. Außerdem liefert der Median eine Information über die Lage der Verteilung. Häufig werden Boxplots genutzt, um die Verteilung eines quantitativen Merkmals für unterschiedliche Ausprägungen eines qualitativen Merkmals darzustellen.

Ein Boxplot besteht zunächst aus einer “Box”, mit Q_1 als untere und Q_3 als obere Grenze. Dazu ist der Median als Linie eingezeichnet. Außerhalb der Box liegen die sog. “Whisker”, welche die kleinste bzw. größte Beobachtung, die keine Ausreißer sind, darstellen. Alle Beobachtungen, die jenseits der Whisker liegen, werden mit einem Punkt als Ausreißer dargestellt. Die Position der Whisker bestimmt sich folgendermaßen:

- Wenn: größte Beobachtung $> Q_3 + 1.5 * IQR$, dann liegt der obere Whisker bei der größten Beobachtung innerhalb von $Q_3 + 1.5 * IQR$. Wenn: größte Beobachtung $\leq Q_3 + 1.5 * IQR$, dann liegt der obere Whisker bei der größten Beobachtung.
- Wenn: kleinste Beobachtung $< Q_1 - 1.5 * IQR$, dann liegt der untere Whisker bei der kleinsten Beobachtung innerhalb von $Q_1 - 1.5 * IQR$. Wenn: kleinste Beobachtung $\geq Q_1 - 1.5 * IQR$, dann liegt der untere Whisker bei der kleinsten Beobachtung.


Der Befehl zur Erstellung eines Boxplots ist `boxplot()`. Betrachten wir für die Variable `height` (für Werte mit `height < 250`) oben den Boxplot:

```
boxplot(s.data$height[s.data$height < 250], ylab = "Größe in cm")
```



Offensichtlich ist es interessanter, die Verteilung von `height` für Männer und Frauen getrennt zu betrachten. Hierzu müssen wir das qualitative Merkmal `fem` mit dem `~`-Zeichen benutzen.

```
boxplot(s.data$height[s.data$height < 250] ~ s.data$fem[s.data$height < 250],  
        xlab = "Geschlecht", col = c("blue", "pink"),  
        names = c("Männer", "Frauen"), ylab = "Größe in cm")
```



Der Median der Männer liegt bei 181 cm und der Median der Frauen bei 168 cm. Hier ist der IQR bei Männern etwas größer als bei Frauen (ebenso die Spannweite = range = max - min). Beide Verteilungen sind in etwa symmetrisch. Auffällig sind vier Ausreißer bei den Männern und zwei bei den Frauen.

Häufig möchte man die Werte des Boxplots ausgeben. Der Befehl `boxplot.stats()` liefert diese Informationen. Unter `$stats` werden die Zahlenwerte für unterer Whisker, Q_1 , Median, Q_3 und oberer Whisker ausgegeben. Mit `$n` wird die Zahl der Beobachtungen und mit `out` werden die Zahlenwerte für die Ausreißer angegeben.

```
boxplot.stats(s.data$height[s.data$fem == 0 & s.data$height < 250], do.conf = FALSE) # ohne KI
```

```
## $stats
## [1] 162 176 181 187 203
##
## $n
## [1] 309
##
## $conf
## NULL
##
## $out
## [1] 155 158 154 151
```

```
boxplot.stats(s.data$height[s.data$fem == 1 & s.data$height < 250], do.conf = FALSE) # ohne KI
```

```
## $stats
```

```
## [1] 153.0 163.0 168.0 171.5 184.0
##
## $n
## [1] 396
##
## $conf
## NULL
##
## $out
## [1] 189 150
```

Assoziation und Korrelation (alle Module)

Ziel in diesem Kapitel ist herauszufinden, ob zwei Merkmale voneinander **abhängig** sind. Dabei wird berücksichtigt, welche Art von Daten (quantitativ oder qualitativ) vorliegt. Wir unterscheiden folgende Maßzahlen für die Abhängigkeit von zweidimensionalen Daten:

1. Pearson-Korrelationskoeffizient $r_{XY} \in [-1, 1]$ für quantitative Daten,
2. Spearman-Korrelationskoeffizient $\rho_{XY} \in [-1, 1]$ für qualitative Daten, die ordinal skaliert sind, und
3. Korrigierter Kontingenzkoeffizient $KK^* \in [0, 1]$ für qualitative Daten, die nominal skaliert sind.

Pearson-Korrelationskoeffizient

Streudiagramm In einem ersten Schritt der Analyse sollte die gemeinsame Verteilung zweidimensionaler quantitativer Daten, hier die Variablen X und Y , immer graphisch dargestellt werden. Hierfür nutzt man ein Streudiagramm. Betrachten wir ein Beispiel:

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
s.data <- read.csv("student.csv")
# s.data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/student.csv")
s.data[1:2, 1:8] # zeige einen Ausschnitt der Tabelle
```

```
##   fem age height weight shoe sport veg_fruits income
## 1   0  20   175    58   41     3         0      300
## 2   1  20   168    63   39     1         5      700
```

Wir interessieren uns für den Zusammenhang zwischen Größe (`height`) und Gewicht (`weight`).

```
summary(s.data$weight)
```


```
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs
##   42.0   57.9   65.0   67.9   77.0   200.0     23
```

```
summary(s.data$height)
```

```
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs
##   150   166   173   174   180   290      3
```

Der Befehl für ein Streudiagramm ist `plot()`. Mit `cex` wird die Größe der Datenpunkte definiert. Der Standard ist `cex = 1`.

```
plot(s.data$height, s.data$weight, cex = 1.2) # zwei Ausreißer fallen auf
```



Da offensichtlich zwei Datenpunkte auffällig sind, betrachten wir diese etwas näher. Hierfür nutzen wir `subset()`, mit dem eine Teilmenge von Beobachtungen ausgewählt werden kann.

```
subset(s.data, s.data$height > 240 | s.data$weight > 150, ) # logisches ODER "/"
```


```
##      fem age height weight shoe sport veg_fruits income food organic
## 329   1  15   290    60   36   20         0    50   10   never
## 330   1  88   170   200   45    5         0  3000 2999   never
```

Wir wollen beide Beobachtungen (und dazu noch einen Ausreißer bei `income`) aus dem Datensatz entfernen und arbeiten dann mit dem bereinigten Datensatz `data_oA` weiter.

```
data_oA <- subset(s.data, s.data$height < 240 & s.data$weight < 150 & s.data$income < 10000, )
```

Wir erstellen nun wieder das Streudiagramm für Größe und Gewicht. Wir tragen Hilfslinien für das mittlere Gewicht und die mittlere Größe ein.

```
plot(data_oA$height, data_oA$weight, cex = 1.2,
xlab = "Größe in cm", ylab = "Gewicht in kg")
abline(h = mean(data_oA$weight), lty = 2) # horizontale Hilfslinie
abline(v = mean(data_oA$height), lty = 2) # vertikale Hilfslinie
```



Wir erkennen, dass relativ viele Datenpunkte in den Sektoren Nordost und Südwest liegen. Die Datenpunkte formen eine Punktwolke, die näherungsweise **linear** ist und einen positiven Anstieg hat.

Kovarianz Die Kovarianz ist das mittlere Produkt der Abweichungen der Beobachtungen von ihrem eigenen arithmetischen Mittel. Sie ist ein Maß für den “**Datengleichklang**” der Beobachtungen.

Die Kovarianz $\widehat{cov}_{XY}$ ist definiert als:

$$\widehat{cov}_{XY} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Wir berechnen die Kovarianz mit `cov()`.

```
cov(data_oA$height, data_oA$weight)
```

```
## [1] 93.576
```

Das **Vorzeichen der Kovarianz** liefert eine wichtige Information. Ist $\widehat{cov}_{XY} > 0$, gehen relativ große Beobachtungen von X einher mit relativ großen Beobachtungen von Y und umgekehrt. Gilt dagegen $\widehat{cov}_{XY} < 0$, gehen relativ große Beobachtungen von X einher mit relativ kleinen Beobachtungen von Y und umgekehrt. Hier ist die Kovarianz positiv, was nach dem Streudiagramm zu erwarten war. Ist $\widehat{cov}_{XY} = 0$, gibt es keinen linearen Zusammenhang zwischen X und Y .

Ein Problem bei der Kovarianz ist, dass sie als Einheit das Produkt der Einheiten beider Variablen hat. Zudem ist die Kovarianz nicht beschränkt auf ein Intervall, was ihre Interpretation erschwert. Um ein Maß für die Stärke und Richtung eines linearen Zusammenhangs zu haben, wäre ein dimensionsloses Maß im Intervall $[-1,1]$ besser.

Berechnung und Interpretation Der Pearson-Korrelationskoeffizient r_{XY} ist definiert als:

$$r_{XY} = \frac{\widehat{cov}_{XY}}{\hat{\sigma}_X \hat{\sigma}_Y} \in [-1, 1]$$

Dabei ist $\widehat{cov}_{XY}$ die Kovarianz von X und Y , $\hat{\sigma}_X$ die Standardabweichung von X und $\hat{\sigma}_Y$ die Standardabweichung von Y .

Folgende Eigenschaften von r_{XY} sind besonders wichtig:

- r_{XY} misst die Stärke (durch den Betrag) und die Richtung (durch das Vorzeichen) des linearen Zusammenhangs zwischen X und Y ,
- r_{XY} liegt im Intervall $[-1, 1]$,
- r_{XY} ist dimensionslos.

Wir berechnen r_{XY} für unser Beispiel mit den Befehlen für Kovarianz und Standardabweichung und mit `cor()`:

```
rXY <- cov(data_oA$height, data_oA$weight)/(sd(data_oA$height)*sd(data_oA$weight)); rXY
```

```
## [1] 0.68775
```

```
cor(data_oA$height, data_oA$weight, method = "pearson")
```

```
## [1] 0.68775
```

Der Pearson-Korrelationskoeffizient ist $r_{XY} = 0.69$, d.h., es gibt einen relativ starken, positiven, linearen Zusammenhang zwischen Größe und Gewicht. Bei der Interpretation von r_{XY} ist die **Richtung** (Vorzeichen) und die **Stärke** (Absolutwert = Effektgröße) des linearen Zusammenhangs immer anzugeben.

Damit r_{XY} berechnet und sinnvoll interpretiert werden kann, müssen bestimmte **Bedingungen** erfüllt sein:


1. Es müssen quantitative Daten (Zahlen mit Einheiten) vorliegen.
2. Es muss ein linearer Zusammenhang vorliegen (zu prüfen über ein Streudiagramm).
3. Ausreißer können r_{XY} stark beeinflussen. Ggf. sind Ausreißer zu entfernen oder es sind zwei Berechnungen durchzuführen (mit und ohne Ausreißer).

Betrachten wir ein weiteres Beispiel aus dem oben eingelesenen Datensatz:

```
names(data_oA)
```

```
## [1] "fem"      "age"      "height"   "weight"   "shoe"
## [6] "sport"    "veg_fruits" "income"   "food"     "organic"
```

```
plot(data_oA$income, data_oA$food, cex = 1.2,
      xlab = "Einkommen im Monat (in Euro)",
      ylab = "Ausgaben für Lebensmittel im Monat (in Euro)")
```



```
summary(data_oA$income)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##         0     400     600    614    750   3500
```

```
summary(data_oA$food)
```

Achtung: es gibt NAs bei food

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NAs
##         0      90     120     147    200    1000    158
```

Die Berechnung von r_{XY} verlangt paarweise vollständige Beobachtungen. Dies lässt sich als Argument in `cor()` einfügen.

```
cor(data_oA$income, data_oA$food, method = "pearson") # method = "pearson" ist der Standard
```

```
## [1] NA
```

```
cor(data_oA$income, data_oA$food, use = "pairwise.complete.obs") # wichtig ist "use = "
```

```
## [1] 0.5091
```

Es gibt einen mittelstarken, positiven, linearen Zusammenhang zwischen Einkommen und Ausgaben für Lebensmittel. Achtung: Wir treffen hier noch **keine Aussage über Kausalität**. Dazu später mehr im Kapitel "Regression".

Spearman-Korrelationskoeffizient

Spearman's ρ ("roh") wird für qualitative Daten, die ordinal skaliert sind, berechnet. Typische Anwendungsfälle sind Noten, Punkte oder Zustimmung zu einer Aussage mit Antworten wie {"absolute Zustimmung", "mir egal", "bin dagegen"}.


Berechnung und Interpretation Wir betrachten hier ein Beispiel, in dem Noten für Mathematik und Statistik vorliegen (Beispiel 4.4 im Lehrbuch, S. 75). Die ordinal skalierten Merkmale liegen also bereits als Zahl vor. Wenn dies nicht der Fall ist, müssen die Ausprägungen umkodiert werden (vgl. Exkurs unten).

Wir lesen zunächst die Noten für Mathematik (NoteM) und Statistik (NoteS) ein.

```
NoteM <- c(1.3, 4, 5, 2.3, 1, 1.7, 1, 3, 3.7, 2.7)
NoteS <- c(2, 3.7, 3.3, 2.7, 1.3, 1, 1.7, 2.3, 3, 3)
```

Bevor wir die Ränge der Ausprägungen bestimmen, ist auch hier ein Streudiagramm sinnvoll.

```
plot(NoteM, NoteS, xlab = "Note in Mathematik", ylab = "Note in Statistik", cex = 1.2)
abline(h = mean(NoteS), lty = 2) # horizontale Hilfslinie
abline(v = mean(NoteM), lty = 2) # vertikale Hilfslinie
```



Offensichtlich gibt es einen relativ starken, positiven, linearen Zusammenhang zwischen den Noten für Mathematik und Statistik. Auf Grund der Ordinalskala können wir aber die Abstände zwischen den Ausprägungen nicht so interpretieren wie bei quantitativen Daten. Zum Beispiel ist der Abstand von einer 1 zu einer 2 nicht gleichwertig wie der Abstand von einer 2 zu einer 3. Bei ordinal skalierten Merkmalen müssen daher **Ränge**

gebildet werden. Diese Ränge werden dann als quantitative Maßzahl interpretiert und zur Berechnung der Korrelation herangezogen.

Der Spearman-Korrelationskoeffizient ρ_{XY} ist gleich dem Pearson-Korrelationskoeffizienten der Ränge (rg) und definiert als:

$$\rho_{XY} = \frac{\widehat{cov}_{rg(X)rg(Y)}}{\widehat{\sigma}_{rg(X)}\widehat{\sigma}_{rg(Y)}} \in [-1, 1]$$

Dabei ist $\widehat{cov}_{rg(X)rg(Y)}$ die Kovarianz der Ränge von X und Y , $\widehat{\sigma}_{rg(X)}$ die Standardabweichung des Ranges von X und $\widehat{\sigma}_{rg(Y)}$ die Standardabweichung des Ranges von Y .

Wir bestimmen zunächst die Ränge der Noten für Mathematik und Statistik mit `rank()`.

```
NoteM; rank(NoteM)
```

```
## [1] 1.3 4.0 5.0 2.3 1.0 1.7 1.0 3.0 3.7 2.7
```

```
## [1] 3.0 9.0 10.0 5.0 1.5 4.0 1.5 7.0 8.0 6.0
```

```
NoteS; rank(NoteS)
```

```
## [1] 2.0 3.7 3.3 2.7 1.3 1.0 1.7 2.3 3.0 3.0
```

```
## [1] 4.0 10.0 9.0 6.0 2.0 1.0 3.0 5.0 7.5 7.5
```

Zur Berechnung: Die Ränge werden aufsteigend (von klein zu groß) vergeben. Bei gleichen Ausprägungen wird das arithmetische Mittel der zu vergebenen Ränge zugewiesen. Zum Beispiel bei `NoteM`: Die 1.0 bei Mathematik gibt es zwei Mal, daher wird das arithmetische Mittel der Ränge 1 und 2, hier $(1+2)/2 = 1.5$, vergeben. Die 1.3 erhält dann den Rang 3.

Die Ränge können als quantitatives Merkmal interpretiert werden. Wir berechnen daher von diesen Rängen die Kovarianz und die Standardabweichungen. Wir berechnen dann ρ_{XY} mit

```
cov(rank(NoteM), rank(NoteS))/(sd(rank(NoteM))*sd(rank(NoteS)))
```

```
## [1] 0.86585
```

Natürlich geht es auch einfacher mit `cor()` und `method = "spearman"`.

```
cor(NoteM, NoteS, method = "spearman")
```

```
## [1] 0.86585
```

Der Spearman-Korrelationskoeffizient liegt bei $\rho_{XY} = 0.87$, d.h., es gibt einen starken, positiven, linearen Zusammenhang zwischen den Rängen der Noten für Mathematik und Statistik.

Exkurs: Umkodieren von Kategorie zu Zahl Beispiel: Es liegen Ausprägungen für Fragen der Art “Wie sinnvoll finden Sie diese Veranstaltung?” mit {total sinnvoll, mittel, Blödsinn} vor. In diesem Fall ist ein Umkodieren von Kategorie zu Zahl nötig. Dies ist hier möglich, da sich die Merkmalsausprägungen ordnen lassen.

Zunächst erzeugen wir uns einen Datensatz. Wir definieren die Merkmale `Bewertung` und `Alter` und erstellen mit `data.frame()` eine Datentabelle.

```
Tab <- data.frame(Bewertung = c("total sinnvoll", "mittel", "total sinnvoll", "Blödsinn",
                               "Blödsinn", "total sinnvoll", "mittel", "total sinnvoll"),
                  Alter = c(19, 27, 18, 22, 19, 26, 30, 27))
Tab[1:5, ]
```

```
##      Bewertung Alter
## 1 total sinnvoll  19
## 2      mittel    27
## 3 total sinnvoll  18
## 4      Blödsinn  22
## 5      Blödsinn  19
```

Das Umkodieren des Merkmals `Bewertung` in geordnete und zahlenmäßige Ausprägungen ist dann mit `ifelse()` möglich. Wir ergänzen eine neue Spalte in `Tab`.

```
Bewertung_Zahl <- ifelse(Tab[,1] == "total sinnvoll", 1, ifelse(Tab[,1] == "mittel", 2, 3))
cbind(Tab, Bewertung_Zahl) [1:5, ] # cbind() bindet Spalten (columns) aneinander
```

```
##      Bewertung Alter Bewertung_Zahl
## 1 total sinnvoll  19              1
## 2      mittel    27              2
## 3 total sinnvoll  18              1
## 4      Blödsinn  22              3
## 5      Blödsinn  19              3
```

Korrigierter Kontingenzkoeffizient

Ziel ist hier zu untersuchen, wie stark zwei nominal skalierte Merkmale voneinander abhängig sind.

Kontingenztabelle Eine Kontingenztabelle stellt die gemeinsame Verteilung von zwei nominal skalierten Merkmalen dar.

Betrachten wir hierzu ein Beispiel:

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("Bsp._2.1.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/Bsp._2.1.csv")
attach(data)
addmargins(table(Journal, Gender))
```

```
##      Gender
## Journal Female Male Sum
## Cosmopolitan    45    5  50
## Economist        5   10  15
## Sports Illustrated 10   25  35
## Sum             60   40 100
```

Die Idee ist: Wir wollen die Stärke der Abhängigkeit zwischen beiden Merkmalen im Intervall $[0, 1]$ messen. Hierzu ermitteln wir die bedingten relativen Häufigkeiten. Hier im Beispiel: die relativen Häufigkeiten von `Journal` für Männer und für Frauen.

```
prop.table(table(Journal, Gender), 2) # 2 = Spalte ist Bedingung
```

```
##                               Gender
## Journal                      Female   Male
##   Cosmopolitan                0.750000 0.125000
##   Economist                   0.083333 0.250000
##   Sports Illustrated           0.166667 0.625000
```

Offensichtlich unterscheidet sich die Verteilung von **Journal** für Männer deutlich von der Verteilung von **Journal** für Frauen. Der Modus von `relH(Journal|Female)` ist **Cosmopolitan** mit 75%. Der Modus von `relH(Journal|Male)` ist **Sports Illustrated** mit 62.5%. Wir können daraus schließen, dass die Merkmale **Journal** und **Gender** nicht unabhängig voneinander sind. Mit anderen Worten: Es besteht eine Abhängigkeit zwischen **Journal** und **Gender**. Wir wollen nun diese Abhängigkeit quantifizieren.

Berechnung und Interpretation Ausgangspunkt der Überlegungen ist die **Definition von statistischer Unabhängigkeit**. Wir betrachten zwei Merkmale X und Y . Die Randverteilung von X , mit $i = 1, \dots, k$ Zeilen in der Kontingenztabelle, ist $h_{i\bullet}$. Die Randverteilung von Y , mit $j = 1, \dots, l$ Spalten in der Kontingenztabelle, ist $h_{\bullet j}$. Die bedingte Verteilung von X für eine Ausprägung von Y ist $h_{i|j} = \frac{h_{ij}}{h_{\bullet j}}$.

Die Merkmale X und Y sind unabhängig, wenn gilt:

$$h_{i|j} = h_{i\bullet}$$

Zwei Merkmale X und Y sind also unabhängig voneinander, wenn die bedingten relativen Häufigkeiten von X für unterschiedliche Ausprägungen von Y konstant und gleich der Randverteilung von X sind.

Aus der Definition von Unabhängigkeit lassen sich die erwarteten relativen Häufigkeiten bei Unabhängigkeit herleiten mit:

$$h_{ij} = h_{i\bullet} h_{\bullet j}$$

und die erwarteten absoluten Häufigkeiten bei Unabhängigkeit mit:

$$E_{ij} = n h_{i\bullet} h_{\bullet j} = \frac{n_{i\bullet} n_{\bullet j}}{n} = \frac{n_{\text{Zeile } i} n_{\text{Spalte } j}}{n}$$

Um nun das Ausmaß der Abhängigkeit zu quantifizieren, betrachten wir die Differenz $n_{ij} - E_{ij}$, quadrieren diese Abweichung und setzen den Wert $(n_{ij} - E_{ij})^2$ in Relation zu E_{ij} . Die resultierenden Werte werden über alle k Zeilen und l Spalten aufsummiert. Wir erhalten die **quadratische Kontingenz QK**:

$$QK = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{ij} - E_{ij})^2}{E_{ij}}$$

Je größer QK , umso größer ist die Abhängigkeit zwischen X und Y . Im Fall statistischer Unabhängigkeit ist $QK = 0$. Für perfekte Abhängigkeit ist $QK \rightarrow \infty$.

Die erwarteten absoluten Werte bei Unabhängigkeit ergeben sich mit `chisq.test()`.

```
chi <- chisq.test(table(Journal, Gender)) # Definiere Objekt chi
chi$expected                               # erwartete abs. Häufigkeiten bei Unabhängigkeit
```

```
##                               Gender
## Journal                      Female Male
##   Cosmopolitan                30    20
##   Economist                   9     6
##   Sports Illustrated           21    14
```

Man beachte: In der Tabelle `chi$expected` sind die bedingten relativen Häufigkeiten identisch, d.h. $\text{relH}(\text{Journal}|\text{Female}) = \text{relH}(\text{Journal}|\text{Male})$.

Die Berechnung von QK erfolgt folgendermaßen:

```
QK <- sum((table(Journal, Gender) - chi$expected)^2/chi$expected); QK
```

```
## [1] 37.599
```

Schließlich wollen wir ein im Intervall $[0, 1]$ normiertes Maß für die **Stärke der Abhängigkeit** nutzen. Dieses Maß ist der korrigierte Kontingenzkoeffizient (KK^*), der sich folgendermaßen berechnet:

$$KK^* = \sqrt{\frac{QK \cdot m}{(QK + n)(m - 1)}} \in [0, 1]$$

Hier ist QK die quadratische Kontingenz, n ist die Zahl der Beobachtungen in der Kontingenztabelle und m ist $\min(k, l)$, also die kleinere Zahl von Spalten- und Zeilenzahl in der Kontingenztabelle. Wie man sieht: Wenn $QK \rightarrow \infty$: $KK^* = 1$ und $QK \rightarrow 0$: $KK^* = 0$.

```
n <- 100; m <- 2
KK_stern <- sqrt( QK*m / ((QK + n)*(m - 1)) ); round(KK_stern, 3)
```

```
## [1] 0.739
```

Der Wert $KK^* = 0.74$ zeigt, dass die beiden Merkmale **Journal** und **Gender** relativ stark voneinander abhängig sind. Es ist aber basierend auf KK^* keine Aussage zur Richtung des Zusammenhangs bzw. zur Kausalität möglich.

$KK^* \in [0, 1]$ ist ein deskriptives Maß zur Messung der Stärke der Abhängigkeit (Effektgröße) zwischen zwei nominal skalierten Merkmalen in einer Stichprobe. Die Frage, ob eine solche Abhängigkeit zufällig bei der Stichprobenziehung zustandegekommen ist oder es diese Abhängigkeit in der Grundgesamtheit tatsächlich gibt ($\Leftrightarrow$ statistische Signifikanz), kann erst durch einen Test auf Unabhängigkeit (vgl. unten) beantwortet werden.

Exkurs: Liniendiagramm Der folgende Code zeigt ein einfaches Liniendiagramm. Mit `plot()` kann eine Kombination von Variablen dargestellt werden. Mit `lines()` können dann beliebig viele Kombinationen zusätzlich dargestellt werden.

```
x <- 1:200; x[1:10] # Definition x
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```


```
y <- 20*x^2 - 0.1*x^3; y[1:10] # Definition y
```

```
## [1] 19.9 79.2 177.3 313.6 487.5 698.4 945.7 1228.8 1547.1 1900.0
```

```
y2 <- 2*x^2; y2[1:10]
```

```
## [1] 2 8 18 32 50 72 98 128 162 200
```


```
# Liniendiagramm, type = "l" mit l wie lachen:)
plot(x, y, type = "l", ylim = c(0, 170000), col = "red", lwd = 3)
abline(h = 0, col = "grey")      # Hilfslinie
abline(v = 0, col = "grey")      # Hilfslinie
lines(x, y2, lwd = 3, col = "blue")
legend(4, 170000, col = c("red", "blue"),
      lwd = c(3, 3), c("Funktion y", "Funktion y2"))
```



Mit `legend()` wird die Legende über den Plot gelegt. Für die Position der Legende sind passende x-y-Koordinaten zu wählen.

Eine alternative Darstellung einer Funktion ist mit `curve()` möglich. Der Befehl `curve()` verlangt dabei die Definition einer Funktion mit dem Argument `x`. Mit `add = TRUE` können mehrere Funktionen dargestellt werden. Anbei ein Beispiel:

```
curve(20*x^2 - 0.1*x^3, xlim = c(-200, 300), ylab = "f(x)")
curve(40*x^2 - 0.4*x^3, xlim = c(-200, 300), lty = 2, add = TRUE)
legend(10, 1400000, lty = c(1,2), c("20*x^2 - 0.1*x^3", "40*x^2 - 0.4*x^3"))
```




Ein weiteres Beispiel, welches die Entwicklung des Ölpreises zeigt.

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("oilprices.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/oilprices.csv")
data[1:2, ]; attach(data)
```

```
##   Year currentUSD USD2020
## 1 1960         1.63    8.51
## 2 1961         1.57    8.05
```

```
plot(Year, currentUSD, xlab = "Year", ylab = "USD per barrel", type = "l", cex.axis = 0.8,
     lwd = 1.5, ylim = c(0, 120))
lines(Year, USD2020, col = "blue", lwd = 1.5)
legend(1960, 120, lty = c(1,1), c("nominal price", "price in USD 2020"),
     col = c("black", "blue"), lwd = c(1.5, 1.5))
```



Man kann gut die Preisspitzen in den Ölkrisen der 1970er Jahre erkennen. Ab 2000 ist der Ölpreis wieder deutlich angestiegen, dann aber ab 2015 wieder gesunken. Zugleich kann man erkennen, dass der Ölpreis inflationsbereinigt (also in Gütereinheiten gemessen) bereits relativ hoch in der Vergangenheit war.

Regression (nur W501 und W873)

Wir wollen nun die Abhängigkeit einer Variablen Y von einer Variablen X beschreiben. Dabei konzentrieren wir uns zunächst auf eine **lineare Abhängigkeit** (lineare Einfachregression, auch “lineares Modell”). Später erweitern wir die Betrachtung auf nicht-lineare Zusammenhänge, die wir durch eine geeignete Transformation in einen linearen Zusammenhang überführen (log-Transformation).

Lineare Einfachregression

Theorie Wir nehmen an, dass es einen linearen Zusammenhang zwischen X und Y gibt. Wir bezeichnen X als unabhängige bzw. erklärende und Y als abhängige bzw. zu erklärende Variable. Ziel ist es, eine Regressionsgerade so zu schätzen, dass diese den linearen Zusammenhang zwischen X und Y bestmöglich beschreibt.

Die Regressionsgerade sei bezeichnet mit

$$\hat{y} = \beta_0 + \beta_1 x$$

Der Parameter β_0 ist der Achsenabschnitt, d.h. $\hat{y}(x = 0) = \beta_0$, und β_1 ist der Anstiegparameter, d.h. $d\hat{y}/dx = \beta_1$.

Wir unterstellen keinen perfekten linearen Zusammenhang zwischen X und Y , sondern es gibt “Abweichungen” u (auch “Fehlerterme” oder “Residuen” genannt) vom linearen Zusammenhang in der y -Dimension, so

dass gilt

$$y = \beta_0 + \beta_1 x + u$$

Damit gelten folgende Definitionen:

$\hat{y}$ = Werte auf der Regressionsgeraden bzw. Prognose der Regressionsgeraden ("predicted")

y = beobachtete Werte für Y ("observed")

x = beobachtete Werte für X

$u = y - \hat{y}$ = Fehlerterm = Beobachtung für Y – Prognose für Y = observed – predicted

Die Methode zur Bestimmung der Regressionsgeraden ist relativ einfach. Man minimiert die Summe der quadrierten Fehlerterme. Aus dieser **Minimierung** ergibt sich eine algebraische Lösung für β_0 und β_1 .

Mit anderen Worten, man bestimmt (für $i = 1, \dots, n$ Beobachtungspaare)

$$\sum u^2(\beta_0, \beta_1) \rightarrow \min!$$

mit

$$\sum u^2(\beta_0, \beta_1) = \sum (y - \hat{y})^2 = \sum (y - \beta_0 - \beta_1 x)^2$$

Mit etwas Rechenaufwand (vgl. Lehrbuch) lässt sich zeigen, dass gilt

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

und


$$\beta_1 = \frac{\widehat{cov_{XY}}}{\widehat{\sigma_x^2}}$$

Beispiel I Wir betrachten das folgende Beispiel mit den Variablen `totalcost` und `output`. Der Output wird in Mengeneinheiten (ME) angegeben, die Gesamtkosten in 1000 Euro.

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("Bsp._5.2.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/Bsp._5.2.csv")
attach(data); data[1:2, ]
```


```
##  output totalcost
## 1      20      25.1
## 2      21      25.2
```

```
plot(output, totalcost, cex = 1.2,
xlab = "Output in ME", ylab = "Gesamtkosten in 1000 Euro")
```



Wie wir sehen, gibt es einen relativ starken, positiven, **linearen Zusammenhang** zwischen `totalcost` und `output`. Wir können das Streudiagramm etwas erweitern und die Regressionsgerade einzeichnen. Die Berechnung der Regressionsgeraden erfolgt mit `lm(y ~ x)`, wobei `y` die abhängige bzw. zu erklärende Variable ist und `x` die unabhängige bzw. erklärende Variable. Wir können dann diese Regressionsgerade zu einem Streudiagramm hinzufügen mit `abline(lm(y ~ x))`.

```
plot(output, totalcost, cex = 1.2, xlab = "Output in ME",
     ylab = "Gesamtkosten in 1000 Euro", xlim = c(0,30), ylim = c(0,35))
abline(lm(totalcost ~ output))
abline(h = mean(totalcost), lty = 2)
abline(v = mean(output), lty = 2)
abline(h = 0, col = "grey50"); abline(v = 0, col = "grey50")
```



Die Regressionsgerade geht durch den Schwerpunkt ($\text{mean}(x)$, $\text{mean}(y)$) des Streudiagramms. Wir können zunächst die Werte für β_0 und β_1 graphisch ablesen:

β_0 = ca. 5000 Euro als fixe Kosten

β_1 = ca. 800 Euro/ME als variable Kosten bzw. Grenzkosten

Um die Regressionsgeraden zu berechnen, nutzen wir `lm(y ~ x)` mit x als unabhängige Variable X und y als abhängige Variable Y und definieren ein Objekt (hier `ols`). Dieses geben wir dann aus.

```
ols <- lm(totalcost ~ output) # ols = ordinary least squares
ols
```

```
##
## Call:
## lm(formula = totalcost ~ output)
##
## Coefficients:
## (Intercept)      output
##      5.658         0.892
```

Man kann hier auch `summary(ols)` ausführen, wenn man Hypothesentests für Anstiegparameter und Achsenabschnitt durchführen möchte (vgl. Lehrbuch, Kap. 12, oder das entsprechende Kapitel in diesem Skript).

Mit den Formeln für β_0 und β_1 erhalten wir analog

```
b1 <- cov(output, totalcost)/var(output); b1
```

```
## [1] 0.8925
```

```
b0 <- mean(totalcost) - b1*mean(output); b0
```

```
## [1] 5.6578
```

Zur Interpretation: Das Modell prognostiziert fixe Kosten der Produktion in Höhe von 5658 Euro und Grenzkosten der Produktion in Höhe von 892.5 Euro/ME.

Generell ist die **Prognose** eine wichtige Anwendung der Regression. Man kann z.B. einen beliebigen Wert für `output` nehmen und für diesen Wert mit Hilfe der Regressionsgleichung den Wert der abhängigen Variablen, hier `totalcost`, prognostizieren. Dabei ist natürlich der Kontext des Modells zu beachten.

```
pred_35 <- b0 + b1*35 # Prognose für totalcost(output = 35)
pred_35
```

```
## [1] 36.895
```

Wichtige **Eigenschaften der Regressionsgeraden** sind:


- Die Regressionsgerade geht durch den Schwerpunkt des Streudiagramms, also den Punkt $(\bar{x}, \bar{y})$.
- Die Summe der Fehlerterme ist Null, d.h. $\sum u = 0$. Damit ist auch das arithmetische Mittel der Fehler Null ($\bar{u} = 0$).
- Die Varianz der abhängigen Variablen, $\hat{\sigma}_Y^2$, kann in zwei Teile zerlegt werden mit: $\hat{\sigma}_Y^2 = \hat{\sigma}_Y^2 + \hat{\sigma}_U^2$. Dabei ist $\hat{\sigma}_Y^2$ die Varianz der Werte auf der Regressionsgeraden (der “fitted values”) und $\hat{\sigma}_U^2$ die Varianz der Fehlerterme.

Das Modell der linearen Regression ist nur dann sinnvoll zu nutzen, wenn bestimmte **Annahmen** gültig sind (zu prüfen über entsprechende Bedingungen):

1. Es müssen quantitative Daten (Zahlen mit Einheiten) vorliegen.
2. Der Zusammenhang muss linear sein (zu prüfen über ein Streudiagramm). Ggf. müssen die Daten in Teilgruppen unterteilt oder transformiert werden.
3. Ausreißer können einen starken Effekt auf die Regressionsgerade haben und müssen ggf. eliminiert werden.
4. Die Fehlerterme sollten eine konstante Streuung aufweisen (“Homoskedastizität”). Bei Verletzung dieser Annahme liegt “Heteroskedastizität” vor. Dies ist durch ein Streudiagramm der Residuen u und der vorhergesagten Werte für Y , $\hat{y}$, zu prüfen. In diesem Streudiagramm sollten keinerlei Strukturen oder Muster enthalten sein.

Betrachten wir zunächst ein Beispiel zur Bedeutung von Ausreißern:

```
x <- 1:5; y <- c(3, 6, 4, 7, 8)
x2 <- 1:6; y2 <- c(3, 6, 4, 7, 8, 0)
plot(x, y, cex = 1.2, xlim = c(0, 15), ylim = c(0, 15))
abline(lm(y ~ x))
points(x2[6], y2[6], cex = 1.2, pch = 2)
abline(lm(y2 ~ x2), lty = 2)
legend(9, 10, lty = c(1,2), c("ohne Ausreißer", "mit Ausreißer"))
```




Bereits ein Wert, hier (6, 0) weit weg vom allgemeinen Trend, kann die Lage der Regressionsgeraden stark beeinflussen. Für die ersten fünf Paare (x, y) ist der Anstieg positiv, mit dem 6. Paar (6, 0) wird der Anstieg jedoch negativ. Der Grund dafür, dass die Regressionsgerade so empfindlich auf Ausreißer in der y-Dimension reagiert, liegt in der Methode der Bestimmung der Regressionsgeraden. Minimiert wird die **Summe der quadrierten Fehlerterme**. Beobachtungen weit weg vom Trend (d.h., mit großem Fehlerterm und großer Abweichung zum arithmetischen Mittel von x) erhalten durch die Quadrierung ein besonders großes Gewicht bei der Bestimmung der Regressionsparameter und “verzerren” somit die Regression.

Residuen Die Fehlerterme (auch “Residuen” genannt) sind der Teil des Regressionsmodells, der nicht erklärt wird. Die Residuen sind definiert als:

$$u = y - \hat{y} = \text{Beobachtung} - \text{Vorhersage} = \text{observed} - \text{predicted}$$

In den Residuen darf keinerlei systematische Information enthalten sein. Dies lässt sich am besten durch ein Streudiagramm mit der Vorhersage ($\hat{y}$) auf der Abszisse und den Residuen (u) auf der Ordinate erkennen. Betrachten wir dieses Streudiagramm für das Beispiel I (Objekt `ols`) oben:

```
plot(ols$fitted.values, ols$residuals, main = "Kontrollplot", cex = 1.2)
abline(h = 0, lty = 2)
```



In dem Streudiagramm für $\hat{y}$ und u (auch “Kontrollplot” genannt) ist keinerlei systematische Information zu erkennen. Man beachte, dass das arithmetische Mittel der Residuen Null ist.

Bestimmtheitsmaß Um zu bewerten, wie gut ein Regressionsmodell den Zusammenhang zwischen X und Y abbildet, nutzt man die Information über die Streuung der Werte auf der Regressionsgeraden (“erklärte Varianz”, $\hat{\sigma}_Y^2$) und die Streuung der Werte der abhängigen Variablen (“zu erklärende Varianz”, $\hat{\sigma}_Y^2$).

Das Verhältnis der von der linearen Regression erklärten Varianz, $\hat{\sigma}_Y^2$, zur Varianz der abhängigen Variablen, $\hat{\sigma}_Y^2$, heißt “Bestimmtheitsmaß” und wird mit R^2 bezeichnet:

$$R^2 = \frac{\hat{\sigma}_Y^2}{\hat{\sigma}_Y^2} = \frac{\frac{1}{n-1} \sum (\hat{y} - \bar{y})^2}{\frac{1}{n-1} \sum (y - \bar{y})^2} = \frac{\sum (\hat{y} - \bar{y})^2}{\sum (y - \bar{y})^2}$$

R^2 misst also den Anteil der von der Regressionsgleichung erklärten Varianz an der Varianz der abhängigen Variablen (man beachte: $\hat{\bar{y}} = \bar{y}$). Man kann zeigen, dass $0 \leq R^2 \leq 1$ gilt. Für die lineare Einfachregression gilt zudem, dass R^2 gleich dem Quadrat des Pearson-Korrelationskoeffizienten r_{XY} ist, also $R^2 = (r_{XY})^2$.

Wir berechnen R^2 für Beispiel I

```
var(ols$fitted.values)
```

```
## [1] 5.6228
```

```
var(ols$residuals)
```

```
## [1] 4.6085
```

```
R2 <- var(ols$fitted.values)/var(totalcost); R2
```

```
## [1] 0.54957
```

```
cor(output, totalcost)^2
```

```
## [1] 0.54957
```

Interpretation: Der Anteil der vom Modell erklärten Varianz an der Varianz der abhängigen Variablen beträgt 55%. Mit anderen Worten: Die unabhängige Variable `output` kann 55% der Streuung von `totalcost` erklären.

Beispiel II Wir betrachten das folgende Beispiel mit den Variablen P und Q :


```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("Elasticity.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/Elasticity.csv")
data[1:2, ]; attach(data)
```

```
##   P      Q
## 1 1 220.0
## 2 1 196.2
```

Die Menge Q wird in Mengeneinheiten (ME) angegeben, der Preis P in Euro. Ziel ist, eine Nachfragefunktion $Q(P)$ zu schätzen. Wir schätzen das lineare Modell $\hat{Q} = \beta_0 + \beta_1 P$.

```
plot(data$P, data$Q, cex = 1.2, xlab = "Preis P in Euro", ylab = "Menge Q in ME",
     main = "Lineares Modell", xlim = c(0, 10))
abline(lm(data$Q ~ data$P), lwd = 2)
```

Lineares Modell




```
ols1 <- lm(data$Q ~ data$P); ols1
```

```
##  
## Call:  
## lm(formula = data$Q ~ data$P)  
##  
## Coefficients:  
## (Intercept)      data$P  
##      172.3         -12.7
```

Interpretation: Gemäß der Prognose des Modells geht im Mittel die Nachfrage um 12.75 ME zurück, wenn der Preis um 1 Euro steigt. Offensichtlich ist aber die Annahme eines linearen Zusammenhangs verletzt. Auch das Streudiagramm der Residuen und der vorhergesagten Werte zeigt, dass das lineare Modell die Abhängigkeit zwischen P und Q nicht richtig abbildet.

```
plot(ols1$fitted.values, ols1$residuals, cex = 1.2)  
abline(h = 0, lty = 2)
```



In diesem Plot ist eine deutliche **Struktur** erkennbar. Die Bedingung der Linearität ist verletzt und es liegt **Heteroskedastizität** vor: Die Streuung der Residuen ist nicht konstant. Wir müssen die Daten geeignet transformieren, um den Zusammenhang zu linearisieren.

log-Transformation

In der Praxis liegen häufig **nicht-lineare Zusammenhänge** vor. Die lineare Einfachregression kann dann nicht angewendet werden. Durch eine geeignete Transformation lassen sich nicht-lineare Zusammenhänge aber häufig in lineare Zusammenhänge umwandeln. Das Konzept der linearen Einfachregression ist dann wieder anwendbar, allerdings ändert sich die Interpretation der Parameter des Regressionsmodells.


Exkurs: Logarithmus Als Logarithmus x einer Zahl y bezeichnet man den Exponenten, mit dem eine vorher festgelegte Zahl, die Basis, potenziert werden muss, um die gegebene Zahl y zu erhalten. Wird als Basis $e = 2.71828$, die Eulersche Zahl, gewählt, so erhält man den natürlichen Logarithmus.

$$y = e^x \Rightarrow x = \log_e y = \ln y$$

In R wird der natürliche Log durch `log()` berechnet.

```
x <- seq(0, 30, 0.1)
y <- log(x)
plot(x, y, ylab = "log(x)", main = "natürlicher Logarithmus")
```

natürlicher Logarithmus



Offensichtlich ist der natürliche Log eine nicht-lineare Funktion. Daher kann der natürliche Log auch verwendet werden, um bestimmte nicht-lineare Zusammenhänge zu linearisieren. Weiterhin hat der natürliche Log eine nützliche Eigenschaft: die logarithmierte Differenz einer Variablen misst näherungsweise die relative Änderung der ursprünglichen Variablen.

```
1.05/1 - 1           # Wachstumsrate = 5%
```

```
## [1] 0.05
```

```
log(1.05) - log(1)    # Differenz der Logs = ca. 5%
```

```
## [1] 0.04879
```

Theorie Ausgehend von einem linearen Modell $\hat{y} = \beta_0 + \beta_1 x$ unterscheiden wir drei Arten der **log-Transformation**: (1) das log-linear Modell, (2) das linear-log Modell, und (3) das log-log Modell (vgl. folgende Tabelle).

Beim **log-linear Modell** (Beispiel: Stundenlohn und Bildung) wird nur die abhängige Variable einer log-Transformation unterzogen:

$$\widehat{\log(y)} = \beta_0 + \beta_1 x$$

Beim **linear-log Modell** (Beispiel: Lebenserwartung und p.c. GDP) wird nur die unabhängige Variable einer log-Transformation unterzogen:

$$\hat{y} = \beta_0 + \beta_1 \log(x)$$

Beim **log-log Modell** (Beispiel: Q und P) werden beide Variablen logarithmiert und es gibt einen linearen Zusammenhang zwischen den Logs:

$$\widehat{\log(y)} = \beta_0 + \beta_1 \log(x)$$

Das log-log Modell ist vor allem deshalb so wichtig, weil es zum **Schätzen von Elastizitäten** verwendet wird (vgl. unten).

Table 1: Interpretation des Anstiegsparameters β_1

	x	$\log(x)$
$\hat{y}$	$\beta_1 = d\hat{y}/dx$	$\beta_1 = d\hat{y}/(dx/x)$
$\widehat{\log(y)}$	$\beta_1 = (d\hat{y}/\hat{y})/dx$	$\beta_1 = (d\hat{y}/\hat{y})/(dx/x)$

Interpretation:

linear: $\beta_1 = d\hat{y}/dx \Rightarrow$ Wenn x um 1 Einheit steigt, steigt $\hat{y}$ um β_1 Einheiten

log-linear: $\beta_1 = (d\hat{y}/\hat{y})/dx \Rightarrow$ wenn x um 1 Einheit steigt, erhöht sich $\hat{y}$ um $\beta_1 \cdot 100\%$


linear-log: $\beta_1 = d\hat{y}/(dx/x) \Rightarrow$ wenn x um 1% steigt, erhöht sich $\hat{y}$ um $\beta_1/100$ Einheiten

log-log: $\beta_1 = (d\hat{y}/\hat{y})/(dx/x) \Rightarrow$ wenn x um 1% steigt, erhöht sich $\hat{y}$ um $\beta_1\%$

Beispiel II mit log-Transformation Betrachten wir ein Beispiel für das log-log Modell $\widehat{\log(y)} = \beta_0 + \beta_1 \log(x)$. Wir nutzen die Daten für P und Q aus Beispiel II oben:

```
plot(log(data$P), log(data$Q), cex = 1.2, xlab = "log(Preis P in Euro)",
     ylab = "log(Menge Q in ME)", main = "Log-log Modell",
     xlim = c(0, 2.5))
abline(lm(log(data$Q) ~ log(data$P)), lwd = 2)
```

Log-log Modell



In diesem Streudiagramm ist ein starker, negativer, linearer Zusammenhang zwischen den Logs zu erkennen. Die Ausgabe der Modellparameter β_0 und β_1 erfolgt folgendermaßen:


```
ols2 <- lm(log(data$Q) ~ log(data$P)); ols2
```

```
##
## Call:
## lm(formula = log(data$Q) ~ log(data$P))
##
## Coefficients:
## (Intercept) log(data$P)
##      5.317      -0.502
```

Der Anstiegsparameter im log-log Modell kann als konstante **Elastizität** interpretiert werden. Hier ist die Prognose des Modells: Steigt der Preis um 1%, dann reduziert sich die Menge um 0.5%. Es liegt also eine unelastische Nachfrage vor.

Betrachten wir das Streudiagramm zwischen u und $\hat{y}$ ("Kontrollplot").

```
plot(ols2$fitted.values, ols2$residuals, main = "Kontrollplot", cex = 1.2)
abline(h = 0, lty = 2)
```



Die Verteilung der Werte ist relativ unauffällig (zumindest aber besser als vor der Transformation).

```
cor(log(data$Q), log(data$P), method = "pearson")^2
```

```
## [1] 0.98238
```


Das R^2 ist relativ hoch mit 98%. Der natürliche Log von P kann 98% der Streuung des natürlichen Logs von Q erklären.

Die Rücktransformation und grafische Darstellung im Plot für P und Q erfolgt folgendermaßen:

```
log(2.718) # Der Log der Eulerschen Zahl e muss 1 sein
```

```
## [1] 0.9999
```

```
P_ols <- seq(0, 10, 0.01)
Q_ols <- 2.718^(5.317 - 0.502*log(P_ols))
plot(data$P, data$Q, cex = 1.2, ylab = "Menge Q in ME", xlab = "Preis P in Euro")
lines(P_ols, Q_ols, lwd = 2, col = "red")
legend(5, 200, pch = c(1, NA), c("Beobachtungen", "Regressionsmodell (log-log)", lwd = c(NA, 2),
col = c("black", "red"), cex = 0.8)
```



```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("GDPpc_pm_live.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/GDPpc_pm_live.csv")
data[1:2, ]; attach(data); dim(data)
```

Beispiel III

```
##   code GDPpc   pm   live
## 1  AFG  496.6 58.331 62.941
## 2  AGO 2189.9 24.599 63.051


## [1] 186  4
```

```
data <- subset(data, live > 40, ); attach(data); dim(data) # Hier ohne den Ausreißer
```

```
## [1] 185  4
```

Wir interessieren uns für die Variablen `GDPpc` (pro-Kopf GDP in USD) und `live` (Lebenserwartung bei Geburt in Jahre). Die Daten wurden von der Weltbank für 2019 erhoben (vollständig für 186 Länder).

```
plot(GDPpc/1000, live, xlab = "GDP p.c. in 1000 USD",
     ylab = "Lebenserwartung bei Geburt in Jahre", main = "GDP p.c. und Lebenserwartung")
```




Wie wir sehen, gibt es einen positiven Zusammenhang zwischen GDP p.c. und Lebenserwartung. Allerdings ist dieser positive Zusammenhang nicht linear. Für geringe GDP p.c. Werte führt ein höheres Einkommen zu drastischen Zugewinnen bei der Lebenserwartung, bei höheren GDP p.c. Werten sind die Zugewinne nur noch relativ klein.

Wenn wir GDP p.c. logarithmieren, ändert sich das Bild.

```
plot(log(GDPpc/1000), live, xlab = "log(GDP p.c. in 1000 USD)",
     ylim = c(50, 90),
     main = "Linear-log Modell",
     ylab = "Lebenserwartung bei Geburt in Jahre")
abline(lm(live ~ log(GDPpc/1000)))
```

Linear-log Modell



Es gibt einen relativ starken, positiven, linearen Zusammenhang zwischen $\log(\text{GDPpc}/1000)$ und live . Wir schätzen ein linear-log Modell.

```
ols <- lm(live ~ log(GDPpc/1000)); ols
```


```
##
## Call:
## lm(formula = live ~ log(GDPpc/1000))
##
## Coefficients:
##      (Intercept)    log(GDPpc/1000)
##           64.5             4.4
```

Das geschätzte Modell (linear-log) ist: $\widehat{\text{live}} = 64.5 + 4.4 * \log(\text{GDPpc}/1000)$. Der Anstiegsparameter dieses Modells ist folgendermaßen zu interpretieren: Eine Erhöhung des GDP p.c. um 1% führt gemäß Modellprognose zu einer um 0.044 Jahre höheren Lebenserwartung. Oder: Eine Erhöhung des GDP p.c. um 10% führt gemäß Modellprognose zu einer um ca. 0.44 Jahre höheren Lebenserwartung.

Wir betrachten nochmal die ursprünglichen Daten mit dem geschätzten Modell.

```
gdp <- seq(1, 200, 0.1)
le <- 64.5 + 4.4*log(gdp)
plot(GDPpc/1000, live, xlab = "GDP p.c. in 1000 USD",
     ylab = "Lebenserwartung bei Geburt in Jahre",
     main = "GDP p.c. und Lebenserwartung")
lines(gdp, le, lwd = 2, col = "red")
```

```
legend(100, 60, pch = c(1,NA), c("Beobachtungen","Regressionsmodell (linear-log)",
    lwd = c(NA,2), col = c("black","red"), cex = 0.8)
```



Wir prüfen das Modell: Bei einem GDP p.c. von 5000 USD prognostiziert das Modell eine Lebenserwartung von 71.56 Jahre. Steigt das GDP p.c. auf 5500 USD (+10%), so prognostiziert das Modell eine Lebenserwartung von 71.98 (ein Plus von 0.42 Jahre). Auf eine Diskussion der Modellannahmen verzichten wir hier aus Platzgründen.

```
64.474 + 4.403*log(5); 64.474 + 4.403*log(5.5)
```

```
## [1] 71.56
```

```
## [1] 71.98
```

Um die Varianzzerlegung zu illustrieren, können auch die Varianzen ausgeben lassen.

```
var(live); var(ols$residuals); var(ols$fitted.values)
```

```
## [1] 55.937
```

```
## [1] 15.489
```

```
## [1] 40.448
```


Beispiel IV Betrachten wir ein Beispiel für das log-linear Modell $\widehat{\log(y)} = \beta_0 + \beta_1 x$.

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("Bsp._5.4.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/Bsp._5.4.csv")
data[1:2, ]; attach(data)
```

```
##   educ wage male
## 1    8  5.1    0
## 2    9  7.9    1
```


Wir betrachten das Streudiagramm für die Variablen `wage` und `educ`:

```
plot(educ, wage, xlab = "Jahre in Bildung", ylab = "Stundenlohn in USD", cex = 1.2)
```



Offensichtlich ist der Zusammenhang nicht linear. Mit zunehmender Bildung steigt der Stundenlohn stärker. Außerdem scheint für das lineare Modell die Streuung der Fehlerterme nicht konstant zu sein. Wenn wir `wage` logarithmieren, ist der Zusammenhang deutlich stärker linear (auch das R^2 ist höher).

```
plot(educ, log(wage), xlab = "Jahre in Bildung", ylab = "log(Stundenlohn in USD)", cex = 1.2)
abline(lm(log(wage) ~ educ))
```



Wir lassen uns den Anstiegsparameter ausgeben:


```
ols3 <- lm(log(wage) ~ educ); ols3
```

```
##
## Call:
## lm(formula = log(wage) ~ educ)
##
## Coefficients:
## (Intercept)      educ
##      -0.290      0.236
```

Interpretation (vgl. Tabelle oben): Das Modell prognostiziert, dass ein Jahr mehr Bildung im Mittel den Stundenlohn um 23.6% erhöht. Der Anstiegsparameter im log-linear Modell ist also eine konstante relative Größe.

Betrachten wir das Streudiagramm zwischen u und $\hat{y}$.

```
plot(ols3$fitted.values, ols3$residuals, main = "Kontrollplot", cex = 1.2)
abline(h = 0, lty = 2)
```



Die Verteilung der Werte ist relativ unauffällig.

```
cor(educ, log(wage), method = "pearson")^2
```

```
## [1] 0.85156
```


Das R^2 ist relativ hoch mit 85%. Die Variable `educ` kann 85% der Streuung des natürlichen Logs von `wage` erklären.

Die Rücktransformation und grafische Darstellung im Plot für `educ` und `wage` erfolgt folgendermaßen:

```
log(2.718) # Der Log der Eulerschen Zahl e muss 1 sein
```

```
## [1] 0.9999
```

```
educ_ols <- seq(0, 18, 0.01)
wage_ols <- 2.718^(-0.290 + 0.236*educ_ols)
plot(data$educ, data$wage, cex = 1.2, ylab = "Stundenlohn in USD", xlab = "Jahre in Bildung")
lines(educ_ols, wage_ols, lwd = 2, col = "red")
legend(8, 40, pch = c(1, NA), c("Beobachtungen", "Regressionsmodell (log-linear)"), lwd = c(NA, 2),
col = c("black", "red"), cex = 0.8)
```



Wir sehen in der Abbildung oben, dass ein konstanter relativer Anstieg (ca. +24% pro Jahr) zu einem absolut zunehmenden Effekt von `educ` auf `wage` führt. Wenn `educ` = 10 führt ein Jahr mehr in Bildung zu ca. 2 USD mehr Stundenlohn (ca. +27%). Wenn `educ` = 15 führt ein Jahr mehr in Bildung zu ca. 7 USD mehr Stundenlohn (ca. +27%). Die Abweichungen zum Modell ergeben sich u.a. dadurch, dass wir einen stetigen Zusammenhang diskret (+1 Jahr) interpretieren.

```
Eff10_11 <- 2.718^(-0.290 + 0.236*11) - 2.718^(-0.290 + 0.236*10); Eff10_11 # von 10 auf 11 Jahre
```

```
## [1] 2.1087
```

```
100*Eff10_11/(2.718^(-0.290 + 0.236*10)) # Anstieg in Prozent
```

```
## [1] 26.614
```

```
Eff15_16 <- 2.718^(-0.290 + 0.236*16) - 2.718^(-0.290 + 0.236*15); Eff15_16 # von 15 auf 16 Jahre
```

```
## [1] 6.8616
```

```
100*Eff15_16/(2.718^(-0.290 + 0.236*15)) # Anstieg in Prozent
```

```
## [1] 26.614
```

Es stellt sich abschließend die Frage, welche Transformation bei einem nicht-linearen Zusammenhang zu wählen ist. Ziel muss es zunächst sein, die **Bedingungen der linearen Regression** bestmöglich zu erfüllen. Aus den Modellen, die die Bedingungen erfüllen, ist dann das Modell zu wählen, welches die größte Erklärungskraft (also das höchste R^2) hat. Zugleich sollte das Modell möglichst einfach zu interpretieren sein.

Zufallsvariablen und zentraler Grenzwertsatz (alle Module)

In diesem Abschnitt werden wir uns mit ausgewählten Verteilungen von Zufallsvariablen und dem zentralen Grenzwertsatz (Central Limit Theorem, CLT) beschäftigen.

Folgende Verteilungen stetiger Zufallsvariablen werden behandelt:

- Normalverteilung $X \sim N(\mu, \sigma)$ und Standardnormalverteilung $Z \sim N(0, 1)$
- Gleichverteilung (Rechteckverteilung)
- χ^2 -Verteilung
- t-Verteilung

Dabei behandeln wir u.a. folgende Punkte:


- Zufallsvariablen generieren
- Bestimmung von Quantilen $x_{[q]}$ mit $q \in [0, 1]$ und $q = P(X \leq x_{[q]})$
- Berechnung von Wahrscheinlichkeiten mit der Verteilungsfunktion $F(x) = P(X \leq x)$
- Bestimmung von Wahrscheinlichkeiten als Fläche unter der Dichte $f(x) = F'(x)$
- Darstellung von F und f mit `curve()`
- Prüfung auf Normalverteilung mit `qqnorm()`

Normalverteilung und Standardnormalverteilung

Notation Die Notation für eine normalverteilte Zufallsvariable X ist $X \sim N(\mu, \sigma)$ mit μ als Mittelwert bzw. Erwartungswert und σ als Standardabweichung. Mit `rnorm()` lassen sich Zufallszahlen (`r` steht für “random”, `norm` für “normal distribution”) aus der Normalverteilung erzeugen. Im Folgenden wollen wir 1000 Zufallszahlen aus $N(2, 6)$ ziehen und die Werte als Histogramm darstellen. Das Problem: Jeder Rechner wird hier unterschiedliche Ergebnisse erhalten, da auf jedem Rechner ein Zufallsprozess läuft. Daher benötigen wir einen Befehl, um die Reproduzierbarkeit der Ergebnisse sicherzustellen. Mit `set.seed()` und der Angabe einer einheitlichen Zahl kann ein Zufallsexperiment durchgeführt werden, so dass die Ergebnisse auf unterschiedlichen Rechnern identisch sind.


```
set.seed(5); hist(rnorm(1000, mean = 2, sd = 6)) # set.seed() hier mit Zahl = 5
```

Histogram of rnorm(1000, mean = 2, sd = 6)



Die Notation für die standardnormalverteilte Zufallsvariable Z ist $Z \sim N(0,1)$. Wir wollen hier 1000 Zufallsvariablen aus $N(0,1)$ erzeugen und die Verteilung mit einem Histogramm darstellen.

```
set.seed(5); z <- rnorm(1000, mean = 0, sd = 1)
hist(z); summary(z); sd(z)
```



```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## -3.4981 -0.6556   0.0223   0.0174  0.6919   3.4019

## [1] 1.012
```

Standardisierung Jede normalverteilte Zufallsvariable $X \sim N(\mu, \sigma)$ kann durch Standardisieren in eine standardnormalverteilte Zufallsvariable $Z \sim N(0, 1)$ überführt werden. Es gilt

$$Z = \frac{X - \mu}{\sigma}.$$

Der Vorteil der Standardisierung liegt allgemein darin, dass man von der Variablenausprägung direkt auf die Abweichungen zum Mittelwert in Einheiten der Standardabweichung schließen kann (unabhängig davon, ob eine Normalverteilung vorliegt oder nicht). Beispiel: $X \sim N(4, 2)$. Der Wert $x = 0$ liegt 2 Standardabweichungen unter dem Mittelwert. Standardisiert ergibt sich $z = (0 - 4)/2 = -2$. Der Wert $x = 7$ liegt 1.5 Standardabweichungen über dem Mittelwert. Standardisiert ergibt sich $z = (7 - 4)/2 = 1.5$. Außerdem kann man nach der Standardisierung von $X \sim N(\mu, \sigma)$ mit den (tabellierten) z -Werten für $N(0, 1)$ rechnen und über die Tabelle der Verteilungsfunktion F_{St} für $N(0, 1)$ Eintrittswahrscheinlichkeiten bestimmen (vgl. Lehrbuch).

Empirical Rule Zur Interpretation der Normalverteilung wird die “Empirical Rule” verwendet: Bei einer normalverteilten Zufallsvariable $X \sim N(\mu, \sigma)$ liegen im Intervall $\mu + / - 2\sigma$ ca. 95% aller Beobachtungen. Wir zeigen hier die Gültigkeit der Empirical Rule für $Z \sim N(0, 1)$ mit verschiedenen Methoden, die allesamt nützlich sind, um Informationen über beliebige Verteilungen zu erhalten.

Methode 1: **Quantile.** Ein Quantil $x_{[q]}$ ist eine Zahl x mit $q \in [0, 1]$, für die gilt, dass der Anteil q aller Beobachtungen kleiner oder gleich x ist, d.h. $q = P(X \leq x_{[q]})$. Wir suchen also hier die Quantile $z_{[0.025]}$ und $z_{[0.975]}$. Zwischen diesen Werten liegen ca. 95% aller Beobachtungen von Z .

```
set.seed(5); z <- rnorm(1000, mean = 0, sd = 1)
quantile(z, probs = c(0.025, 0.975)) # 2.5%- und 97.5%-Quantil
```

```
##      2.5%    97.5%
## -2.0010   2.0073
```

Der genaue Wert ist $z_{[0.975]} = 1.96$. 97.5% aller Werte von Z sind also kleiner oder gleich 1.96. Die Zahl **1.96** - das 97.5%-Quantil der Standardnormalverteilung - ist **die wichtigste Zahl in der Statistik**. Wir benötigen diesen Wert bei der Berechnung von 95%-Konfidenzintervallen und als kritischen Wert für den zweiseitigen Hypothesentest zum Signifikanzniveau $\alpha = 0.05$ (vgl. weiter unten zu Inferenzstatistik).

Die exakten Quantile von $N(\mu, \sigma)$ lassen sich mit `qnorm()` ausgeben.

```
qnorm(0.975, mean = 0, sd = 1) # 97.5%-Quantil von  $N(0,1)$  =  $z[0.975] = 1.96$ 
```

```
## [1] 1.96
```

```
qnorm(0.025, mean = 0, sd = 1) # 2.5%-Quantil von  $N(0,1)$  =  $z[0.025] = -1.96$ 
```

```
## [1] -1.96
```

Methode 2: Logische Abfrage mit “und” (oder alternativ mit “oder”). Wir suchen die relative Häufigkeit für $-2 \leq z \leq 2$.

```
set.seed(5); z <- rnorm(1000, mean = 0, sd = 1)
prop.table(table((z >= -1.96) & (z <= 1.96))) # logisches UND
```

```
##
## FALSE  TRUE
##  0.06  0.94
```

Exkurs: Logische Bedingungen Mit logischen Bedingungen lassen sich Abfragen leicht durchführen und dann mit `table()` auswerten (vgl. folgende Tabelle).

Table 2: Logische Bedingungen

Operator in R	Interpretation
<code>==</code>	gleich
<code>></code>	größer
<code><</code>	kleiner
<code>!=</code>	ungleich
<code>&</code>	und
<code>>=</code>	größer gleich
<code><=</code>	kleiner gleich
<code> </code>	oder

```
# ein Beispiel für die Anwendung logischer Bedingungen
X <- 1:10; Y <- 16:25
Z <- c(rep("Yes", 4), rep("No", 6))
data.frame(X, Y, Z)
```

```
##      X  Y   Z
## 1    1 16 Yes
## 2    2 17 Yes
## 3    3 18 Yes
## 4    4 19 Yes
## 5    5 20 No
## 6    6 21 No
## 7    7 22 No
## 8    8 23 No
## 9    9 24 No
## 10  10 25 No
```

```
table(X <= 2 & Z == "Yes")
```

```
##
## FALSE  TRUE
##      8      2
```

```
table(X <= 2 | Z == "Yes")
```

```
##
## FALSE  TRUE
##      6      4
```

```
X > 8 & Y != 24 & Z == "No"
```

```
## [1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE TRUE
```

```
table(X > 8 & Y != 24 & Z == "No")
```


```
##
## FALSE  TRUE
##      9      1
```

Methode 3: **Verteilungsfunktion.** Die Verteilungsfunktion der Variablen X , $F(x)$, ist eine Funktion, für die gilt $F(x) = P(X \leq x)$. F ist eine kompakte Darstellung für die Verteilung einer Zufallsvariablen und häufig tabelliert (z.B. F_{St} für $N(0,1)$, vgl. Lehrbuch).

Hier zunächst nur die graphische Darstellung von F für z (1000 Zufallszahlen aus $N(0,1)$):

```
plot.ecdf(z, xlab = "z", ylab = "F(z)", main= "Verteilungsfunktion F(z)")
abline(v = c(-1.96, 0, 1.96), lty = 2)
```

Verteilungsfunktion $F(z)$



Wir schreiben für die Verteilungsfunktion von $N(0, 1)$ auch F_{St} . Oben war $z_{[0.025]} = -1.96$. Dies ist mit der Abbildung von F_{St} konsistent, da $F_{St}(-1.96) = 0.025$. Analog gilt $F_{St}(1.96) = 0.975$. Die Quantile lassen sich also aus der Verteilungsfunktion ablesen. Es gilt: $q = F(x_{[q]})$ und $x_{[q]} = F^{-1}(q)$. Quantile $x_{[q]}$ lassen sich also über die Umkehrfunktion der Verteilungsfunktion $F^{-1}(q)$ bestimmen.

Die exakten Werte für F von $N(\mu, \sigma)$ lassen sich mit `pnorm()` ausgeben. Zum Beispiel für $N(0, 1)$:

```
pnorm(0, mean = 0, sd = 1)      # 0 ist das 50%-Quantil von N(0,1)
```

```
## [1] 0.5
```

```
pnorm(1.645, mean = 0, sd = 1)  # 1.645 ist das 95%-Quantil von N(0,1)
```

```
## [1] 0.95002
```

```
pnorm(1.96, mean = 0, sd = 1)   # 1.96 ist das 97.5%-Quantil von N(0,1)
```

```
## [1] 0.975
```

Die **Dichtefunktion** einer Zufallsvariablen X , f , ist die 1. Ableitung von F . Kurz: $F' = f$. Mit Hilfe der Umkehroperation zur 1. Ableitung gilt: $F(x) = \int_{-\infty}^x f dx$. Wir können also $F(x) = P(X \leq x)$ aus der Dichte f ablesen als Fläche unter der Dichte f von $-\infty$ bis x .

Die exakten Werte für die Dichte von $N(\mu, \sigma)$ lassen sich mit `dnorm()` ausgeben. Zum Beispiel für $N(0, 1)$:

```
dnorm(0, mean = 0, sd = 1)  # maximale Dichte bei  $z = 0$ 
```

```
## [1] 0.39894
```

```
dnorm(1, mean = 0, sd = 1)  # positive Dichte bei  $z = 1$ 
```

```
## [1] 0.24197
```

```
dnorm(-1, mean = 0, sd = 1)  # Symmetrie
```

```
## [1] 0.24197
```

```
dnorm(5, mean = 0, sd = 1)  # Dichte ist praktisch Null für  $z > 3$ 
```


```
## [1] 1.4867e-06
```

Wenn wir die **Wahrscheinlichkeit** $P(X \leq x)$ suchen, gibt es also zwei Optionen:

- 1) Berechnung über den Funktionswert von F . Es gilt $P(X \leq x) = F(x)$.
- 2) Berechnung als Fläche unter der Dichte f . Es gilt $P(X \leq x) = \int_{-\infty}^x f dx$.


Darstellung von Funktionen mit `curve()` Mit `curve()` können wir u.a. die Dichte f von $N(\mu, \sigma)$ darstellen. Man kann auch mehrere Kurven mit `curve()` darstellen, nur muss man dann `add = TRUE` ergänzen. Hier:

```
curve(dnorm(x, mean = 2, sd = 6), xlim = c(-35, 30), ylab = "dnorm(x)")  
abline(v = 2, lty = 2)  
curve(dnorm(x, mean = 2, sd = 7), lty = 2, col = "red", add = TRUE)  
legend(-35, 0.06, lty = c(2,1), col = c("red", "black"), c("N(2, 7)", "N(2, 6)"))
```



Berechnung von Wahrscheinlichkeiten Wir wollen nun Eintrittswahrscheinlichkeiten für normalverteilte Zufallsvariablen bestimmen. Betrachten wir ein Beispiel zu $N(\mu, \sigma)$: Gegeben $X \sim N(100, 20)$ und man soll (1) $P(X > 110)$ und (2) $P(100 < X \leq 130)$ bestimmen.

```
curve(dnorm(x, mean = 100, sd = 20), xlim = c(0, 200))
abline(h = 0, col = "grey")
abline(v = 110, lty = 2, col = "blue", lwd = 2)
abline(v = c(100, 130), lty = 2, col = "green", lwd = 2)
```



Die Berechnung der gesuchten Wahrscheinlichkeit (1), gleich der Fläche unter der Dichte rechts von der blauen vertikalen Linie, ist damit folgendermaßen möglich:

(1) Direkt über `pnorm()`

```
1 - pnorm(110, mean = 100, sd = 20)
```

```
## [1] 0.30854
```

(2) Mit Standardisierung und über $N(0,1)$

Der gesuchte z-Wert ist hier 0.5, da

$$P(X > 110) = P((X - \mu)/\sigma > (110 - 100)/20) = P(Z > 0.5) = 1 - P(Z \leq 0.5) = 1 - F_{St}(0.5)$$

```
1 - pnorm(0.5, mean = 0, sd = 1)
```

```
## [1] 0.30854
```

Die Wahrscheinlichkeit (2), gleich der Fläche unter der Dichte zwischen den beiden grünen vertikalen Linien, berechnet sich entsprechend.


```
pnorm(130, mean = 100, sd = 20) - pnorm(100, mean = 100, sd = 20)
```

```
## [1] 0.43319
```

Exkurs: Definition von Funktionen und Integration Mit R lassen sich Funktionen definieren und bestimmte Integrale berechnen. Man kann also die Fläche unter einer Funktion numerisch bestimmen. Im folgenden Beispiel definieren wir eine Funktion, stellen diese grafisch dar und lassen uns einen Funktionswert ausgeben. Dann berechnen wir zwei bestimmte Integrale für diese Funktion.

```
my_function <- function(x) {      # Generiert eine Funktion my_function
  y <- 2*x + 3*x^2 - 0.5*x^3 + 100
  return(y)
}

curve(my_function, xlim = c(0, 10), ylim = c(-100, 150)); grid(); abline(h = 0)
```



```
my_function(x=6)      # my_function für x = 6
```

```
## [1] 112
```

```
integrate(my_function, 0, 2)  # Integral über my_function im Intervall [0, 2]
```

```
## 210 with absolute error < 2.3e-12
```

```
integrate(my_function, 2, 4)    # Integral über my_function im Intervall [2, 4]
```

```
## 238 with absolute error < 2.6e-12
```

Man kann auch über in R definierte Funktionen wie `dnorm()` oder `dunif()` integrieren.

```
# Dichte unter  $N(0,1)$  im Intervall  $[-\text{Inf}, -1.96]$   
integrate(dnorm, mean = 0, sd = 1, -Inf, -1.96)
```

```
## 0.024998 with absolute error < 0.000019
```

```
# Dichte unter  $N(0,1)$  im Intervall  $[-1.96, 1.96]$   
integrate(dnorm, mean = 0, sd = 1, -1.96, 1.96)
```


```
## 0.95 with absolute error < 1e-11
```

```
# Dichte unter der Rechteckverteilung mit  $\min = 1$  und  $\max = 9$  im Intervall  $[1, 4]$   
integrate(dunif, min = 1, max = 9, 1, 4)
```


```
## 0.375 with absolute error < 4.2e-15
```

qq-Plot Man will häufig wissen, ob ein Vektor von Zahlen einer $N(\mu, \sigma)$ -Verteilung folgt. Das Quantile-Quantile-Plot (“qq-Plot”) stellt die Quantile der $N(0, 1)$ -Verteilung auf der Abszisse gegen die Quantile der beobachteten Variable auf der Ordinate dar. Wenn das qq-Plot näherungsweise eine **Gerade** zeigt, liegt eine $N(\mu, \sigma)$ -Verteilung vor.

```
set.seed(5); U <- rnorm(100, mean = 2, sd = 6)  
hist(U)
```



```
qqnorm(U)
qqline(U)  # ergänzt die 45-Grad-Linie
```



Exkurs: Shapiro-Wilk-Test auf Normalverteilung Mit diesem Hypothesentest (vgl. weiter unten zu Inferenzstatistik) kann man anhand einer Stichprobe untersuchen, ob die zugrundeliegende Grundgesamtheit einer Normalverteilung folgt. Die Nullhypothese besagt bei diesem Test, dass in der Grundgesamtheit eine Normalverteilung vorliegt. Die Alternativhypothese besagt, dass in der Grundgesamtheit keine Normalverteilung vorliegt. Das bedeutet: Kann bei diesem Test statistische Signifikanz ($p\text{-value} < 0.05$) festgestellt werden, so müssen wir die Nullhypothese verwerfen und davon ausgehen, dass in der Grundgesamtheit keine Normalverteilung vorliegt. Ist das Testergebnis statistisch insignifikant ($p\text{-value} \geq 0.05$), so können wir die Nullhypothese nicht verwerfen (und können weiter mit der Hypothese der Normalverteilung arbeiten).

Wir betrachten das folgende Beispiel mit zwei Stichproben x und y :

```
x <- c(1,1,2,2,1,1)
set.seed(4); y <- rnorm(6, mean = 4, sd = 2)
shapiro.test(x)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  x
## W = 0.64, p-value = 0.0014
```

```
shapiro.test(y)
```

```
##
```

```
## Shapiro-Wilk normality test
##
## data: y
## W = 0.976, p-value = 0.93
```

Für die erste Variable (x) können wir die Nullhypothese, nach der eine Normalverteilung in der Grundgesamtheit vorliegt, verwerfen. Der p-value liegt unter 5%, dem üblichen Signifikanzniveau. Für die zweite Variable (y) können wir die Nullhypothese, nach der eine Normalverteilung in der Grundgesamtheit vorliegt, nicht verwerfen und behalten sie bei.

Auf Grund der Bedeutung der bisher betrachteten Konzepte erläutern wir diese nochmal am Beispiel der $N(0, 1)$ - und der $N(2, 2)$ -Verteilung: (1) Zufallsvariablen, (2) Quantile, (3) Werte der Dichte f und (4) Werte der Verteilungsfunktion F .

(1) Zufallsvariablen (r für “random”)

```
set.seed(3); rnorm(5) # 5 Zufallszahlen aus N(0,1)
```

```
## [1] -0.96193 -0.29253 0.25879 -1.15213 0.19578
```

```
set.seed(3); rnorm(5, mean = 2, sd = 2) # aus N(2,2)
```

```
## [1] 0.076133 1.414949 2.517576 -0.304264 2.391566
```

(2) Quantile (q für “Quantil”)

```
qnorm(0.5) # 0.5-Quantil (auch "50%-Quantil") für N(0,1)
```

```
## [1] 0
```

```
qnorm(0.975) # 0.975-Quantil (auch "97.5%-Quantil") für N(0,1)
```

```
## [1] 1.96
```

```
qnorm(0.5, mean = 2, sd = 2) # 0.5-Quantil für N(2,2)
```


```
## [1] 2
```

```
qnorm(0.975, mean = 2, sd = 2) # 0.975-Quantil für N(2,2)
```

```
## [1] 5.9199
```


(3) Werte der Dichte f (d für “density”)

```
curve(dnorm(x), xlim = c(-4, 6)) # Dichte f für N(0,1)
curve(dnorm(x, mean = 2, sd = 2), add = TRUE, lty = 2) # Dichte f für N(2,2)
legend(3, 0.35, c("N(0,1)", "N(2,2)"), lty = c(1,2))
```




(4) Werte der Verteilungsfunktion F (p für “probability”)

```
curve(pnorm(x), xlim = c(-4, 6)) # F für N(0,1)
curve(pnorm(x, mean = 2, sd = 2), add = TRUE, lty = 2) # F für N(2,2)
legend(3, 0.45, c("N(0,1)", "N(2,2)"), lty = c(1,2))
```




Exkurs: Flächen unter der Dichte Allgemein lassen sich Flächen in einem Plot mit `polygon()` darstellen. Dabei sind x- und y-Koordinaten für die Fläche zu definieren. Betrachten wir das folgende Beispiel:

```
plot(0, cex = 1.2, xlim = c(0, 5), type = "n",
     ylim = c(0, 5), xlab = "x", ylab = "y")
x.coord1 <- c(1, 2, 2, 1) # x für Viereck
y.coord1 <- c(3, 3, 2, 2) # y für Viereck
x.coord2 <- c(2.5, 2.5, 3.0, 4.0, 4.5, 4.5, 4.0, 3.0) # Achteck
y.coord2 <- c(1.0, 2.0, 2.5, 2.5, 2.0, 1.0, 0.5, 0.5)
x.coord3 <- c(3, 4, 5) # Dreieck
y.coord3 <- c(3, 4, 3)
polygon(x.coord1, y.coord1, lty = 2, border = "blue", lwd = 2)
polygon(x.coord2, y.coord2, lty = 3, lwd = 2, col = "red")
polygon(x.coord3, y.coord3, lty = 1, lwd = 2, col = "orange")
```



Mit `polygon()` lassen sich auch Flächen unter der Dichte darstellen.

```
cord.x1 <- c(-4,seq(-4,-1,0.01),-1)
cord.y1 <- c(0,dnorm(seq(-4,-1,0.01)),0)
cord.x2 <- c(1,seq(1,2,0.01),2)
cord.y2 <- c(0,dnorm(seq(1,2,0.01)),0)
curve(dnorm(x),xlim=c(-4,4), ylim = c(0, 0.5), lwd = 2,
      cex.lab = 1.1, cex.axis = 1.1, ylab = "f(z)", xlab = "z")
polygon(cord.x1,cord.y1,col='gray33')
polygon(cord.x2,cord.y2,col='gray67')
text(-2.8, 0.4, "p = 0.1587", cex = 1.1)
text(3.0, 0.4, "p = 0.1359", cex = 1.1)
arrows(-3, 0.35, -2, 0.1); arrows(3, 0.35, 1.8, 0.12)
```




In der Abbildung oben ist $P(Z \leq -1) = F_{St}(-1)$ und $P(1 < Z \leq 2) = F_{St}(2) - F_{St}(1)$ dargestellt.

Rechteckverteilung


Wir betrachten nun die Rechteckverteilung **unif** (auch “Gleichverteilung” genannt). Die stetige Rechteckverteilung ist durch eine konstante Dichte im Intervall $[a, b]$ mit $a < b$ charakterisiert.

(1) Zufallsvariablen mit **r**

```
set.seed(5); G <- runif(100, min = 2, max = 6)
hist(G)
```



```
qqnorm(G); qqline(G) # starke Abweichung von  $N(\mu, \sigma)$ 
```



(2) Quantile mit `q`

```
qunif(0.5, min = 2, max = 6) # Median
```


```
## [1] 4
```

```
qunif(0.25, min = 2, max = 6) # Q1
```

```
## [1] 3
```

(3) Dichte f mit `d`

```
curve(dunif(x, min = 2, max = 6), xlim = c(0, 8))
```




```
dunif(0.5, min = 2, max = 6); dunif(3.5, min = 2, max = 6)
```

```
## [1] 0
```

```
## [1] 0.25
```

(4) Verteilungsfunktion F mit p

```
curve(punif(x, min = 2, max = 6), xlim = c(0, 8))
```



```
punif(1, min = 2, max = 6); punif(5, min = 2, max = 6)
```

```
## [1] 0
```

```
## [1] 0.75
```

χ^2 -Verteilung

Die χ^2 -Verteilung ist eine stetige Verteilung, die insbesondere beim Testen von Hypothesen mit qualitativen Merkmalen benötigt wird. Eine χ^2 -Zufallsvariable mit n Freiheitsgraden (df = degrees of freedom) ergibt sich, wenn die Quadrate von n $N(0, 1)$ -verteilten Zufallsvariablen addiert werden.

Wenn also $Z_1, Z_2, \dots, Z_n$ $N(0, 1)$ -verteilte und unabhängige Zufallsvariablen sind, dann heißt die Zufallsvariable

$$\chi_n^2 = Z_1^2 + Z_2^2 + \dots + Z_n^2$$

χ^2 -verteilt mit n Freiheitsgraden (df).


Die χ^2 -Verteilungen haben damit immer eine positive Dichte im Intervall $[0, +\infty]$. Für kleine df ist die Dichte **linkssteil**. Für große df konvergiert die χ^2 -Verteilung gegen eine Normalverteilung. Der **Modus** liegt bei $df - 2$ für $df \geq 2$. Das Kürzel in R für die χ^2 -Verteilung ist **chisq**. Die Kürzel **r**, **d**, **q**, **p** werden wie bei anderen Verteilungen auch genutzt.

Der Plot der Dichte für $\chi^2(df = 4)$, $\chi^2(df = 10)$ und $\chi^2(df = 30)$ ist:

```

curve(dchisq(x, df = 4), xlim = c(0, 60), ylab = "density")
curve(dchisq(x, df = 10), lty = 2, add = TRUE)
curve(dchisq(x, df = 30), lty = 3, add = TRUE)
legend(35, 0.17, c("Chi2(df=4)", "Chi2(df=10)", "Chi2(df=30)"), lty = c(1,2,3))

```



Die Quantile der χ^2 -Verteilung sind positiv. Betrachten wir die 95%-Quantile der χ^2 -Verteilungen in der Abbildung oben:

```

qchisq(0.95, df = 4); qchisq(0.95, df = 10); qchisq(0.95, df = 30)

```

```
## [1] 9.4877
```

```
## [1] 18.307
```

```
## [1] 43.773
```

Das 95%-Quantil wird mit der Zahl der Freiheitsgrade df größer.

t-Verteilung

Gegeben sei die χ^2 -verteilte Zufallsvariable χ_n^2 und die $N(0, 1)$ -verteilte Zufallsvariable Z . Beide Zufallsvariablen seien stochastisch unabhängig voneinander.

Dann heißt die Zufallsvariable


$$T_n = \frac{Z}{\sqrt{\frac{\chi_n^2}{n}}}$$

t-verteilt mit n Freiheitsgraden (df). Die t-Verteilung ist eine um Null symmetrische, stetige Verteilung mit $df > 1$. Im Vergleich zur $N(0,1)$ -Verteilung ist die Dichte der t-Verteilung um Null kleiner und an den Rändern größer. Die t-Verteilung konvergiert für zunehmende df gegen $N(0,1)$. Für $df = 30$ und größer können die t-Quantile praktisch durch $N(0,1)$ -Quantile approximiert werden. Die t-Verteilung ist bedeutsam insbesondere für das Testen von Hypothesen über den wahren Mittelwert und für die Berechnung von entsprechenden Konfidenzintervallen (vgl. Kapitel “Inferenz für quantitative Daten”). Sie geht zurück auf William Sealy Gosset, der unter dem Pseudonym “Student” die Idee dieser Verteilung 1908 zum ersten Mal tabellierte (daher wird diese Verteilung auch Student’s t genannt).

Das Kürzel in R für die t-Verteilung ist `t`. Die Kürzel `r`, `d`, `q`, `p` werden wie bei anderen Verteilungen auch genutzt.

Der Plot der Dichte für $N(0,1)$, $t(df = 2)$ und $t(df = 20)$ ist:

```
curve(dnorm(x), xlim = c(-5, 6))
curve(dt(x, df = 2), lty = 2, add = TRUE)
curve(dt(x, df = 20), lty = 3, add = TRUE)
legend(2.2, 0.3, c("N(0,1)", "t(df = 2)", "t(df = 20)"), lty = c(1, 2, 3))
```



Die Quantile der t-Verteilung sind betragsmäßig **immer größer** als die korrespondierenden Quantile von $N(0,1)$. Der Unterschied wird aber für zunehmende df kleiner.

```
qt(0.975, df = 2) # 97.5%-Quantil der t-Verteilung mit df = 2
```

```
## [1] 4.3027
```

```
qt(0.975, df = 20) # 97.5%-Quantil der t-Verteilung mit df = 20
```

```
## [1] 2.086
```

```
qt(0.975, df = 50) # 97.5%-Quantil der t-Verteilung mit df = 50
```

```
## [1] 2.0086
```

Central Limit Theorem (CLT)

Qualitative Daten Unter bestimmten Annahmen (vgl. unten) gilt für den Stichprobenanteilstwert:

$$H \sim N(p, \sqrt{\frac{p(1-p)}{n}})$$

Für den standardisierten Stichprobenanteilstwert gilt dann:

$$\frac{H-p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1)$$

mit p als wahrer Anteilswert in der Grundgesamtheit.

Annahmen des CLT: 1) Unabhängigkeit, 2) große Stichprobe.

Die Gültigkeit der Annahmen wird mit drei **Bedingungen** geprüft: 1) Zufallsstichprobe (sichert Unabhängigkeit), 2) beim Ziehen ohne Zurücklegen muss ein kleiner Auswahlsatz mit $n/N \leq 0.05$ vorliegen (sichert Unabhängigkeit, weil h konstant, vgl. Exkurs), 3) große Stichprobe: $np \geq 10$ und $n(1-p) \geq 10$.

Quantitative Daten Unter bestimmten Annahmen (vgl. unten) gilt für den Stichprobenmittelwert:

$$\bar{X} \sim N(\mu, \frac{\sigma}{\sqrt{n}})$$

Für den standardisierten Stichprobenmittelwert gilt dann:

$$\frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

mit μ als wahrer Mittelwert der Grundgesamtheit und σ als wahre Standardabweichung der Grundgesamtheit.

Dies gilt **unabhängig von der Verteilung des Merkmals** in der Grundgesamtheit.


Die Bedingungen und Annahmen sind wie oben, nur für die Stichprobengröße gilt nun $n > 30$. Später sind Modifikationen nötig, wenn σ unbekannt ist und geschätzt werden muss.

Betrachten wir ein Beispiel zur Anwendung des CLT für qualitative Daten. Der wahre Anteil für die Zustimmung zu einem Projekt in der Grundgesamtheit sei $p = 0.4$. Wir ziehen eine Zufallsstichprobe der Größe $n = 800$. Wie groß sind die Wahrscheinlichkeiten: a) $P(h < 0.35)$ und b) $P(0.37 < h < 0.43)$? Wir können hier Stetigkeit unterstellen, d.h., die Punktwahrscheinlichkeit ist näherungsweise Null.

Lösung a): Wir wissen, dass gemäß CLT der Stichprobenanteil einer $N(0.4, \sqrt{0.24/800})$ -Verteilung folgt.

Der Plot der Dichte ist:

```
curve(dnorm(x, mean = 0.4, sd = sqrt(0.24/800)), xlim = c(0.3, 0.5))
abline(v = 0.35, lty = 2, lwd = 2, col = "blue")
abline(v = c(0.37, 0.43), lty = 2, lwd = 2, col = "green")
```



Wir suchen für a) die Fläche unterhalb der Dichte f links der vertikalen blauen Linie. Die Berechnung über die Verteilungsfunktion F ist:

```
pnorm(0.35, mean = 0.4, sd = sqrt(0.24/800))
```

```
## [1] 0.0019462
```

Damit ist die gesuchte Wahrscheinlichkeit 0.195%.

Wir können für b) von der gleichen Verteilungsannahme wie in a) ausgehen. Wir suchen für b) die Fläche unterhalb der Dichte f zwischen den vertikalen grünen Linien.

Berechnung über die Verteilungsfunktion F :

```
pnorm(0.43, mean = 0.4, sd = sqrt(0.24/800)) - pnorm(0.37, mean = 0.4, sd = sqrt(0.24/800))
```

```
## [1] 0.91674
```

Die gesuchte Wahrscheinlichkeit ist 91.7%.

Exkurs: Stochastische Unabhängigkeit Stochastische Unabhängigkeit für zwei Ereignisse A und B ist definiert als $P(A|B) = P(A)$. Das bedeutet, dass die Wahrscheinlichkeit für A unter der Bedingung, dass B eingetreten ist, gleich der unbedingten Wahrscheinlichkeit für A ist. Mit anderen Worten: Ob B eintritt oder nicht, hat keinen Einfluss auf A . Die Eintrittswahrscheinlichkeit für A ist also unabhängig von B und damit

konstant. Dieses Konzept wird nun bei der Ziehung von Stichproben aus einer Grundgesamtheit genutzt. Hierbei wird das Ziehen **mit Zurücklegen** und **ohne Zurücklegen** unterschieden.

Wir betrachten eine kleine Grundgesamtheit ($N = 10$) mit fünf roten (R) und fünf schwarzen (S) Kugeln. Wir ziehen eine Zufallsstichprobe vom Umfang $n = 3$. Mit Zurücklegen gilt stochastische Unabhängigkeit und die Wahrscheinlichkeit für „rot“ beim 1., 2. und 3. Zug ist $P(R_1) = P(R_2) = P(R_3) = 0.5$. Die Wahrscheinlichkeit für „rot“ ist also konstant und unbeeinflusst von Ereignissen vor dem Zufallszug. Ohne Zurücklegen ist dies nicht der Fall, denn die Eintrittswahrscheinlichkeiten im 2. und 3. Zug sind abhängig von den Ereignissen davor. So gilt z.B. für die Wahrscheinlichkeit, „rot“ beim 2. Zug zu beobachten, wenn beim 1. Zug bereits „rot“ beobachtet wurde: $P(R_2|R_1) = 4/9$. Entsprechend gilt $P(R_3|R_1 \cap R_2) = 3/8$. In diesem Fall ist der Auswahlatz relativ groß ($n/N = 0.3$), so dass wir nicht davon ausgehen können, dass Ziehen ohne Zurücklegen näherungsweise die gleichen Ergebnisse bringt wie Ziehen mit Zurücklegen. Betrachten wir nun eine große Grundgesamtheit mit $N = 10000$ mit 5000 roten und 5000 schwarzen Kugeln. Wir ziehen wieder eine Stichprobe vom Umfang $n = 3$. Im Fall ohne Zurücklegen sind jetzt die Eintrittswahrscheinlichkeiten im 2. und 3. Zug praktisch unabhängig von den Ereignissen davor, d.h., hier ist Unabhängigkeit gegeben. So gilt z.B. $P(R_2|R_1) = 4999/9999 \approx 0.5$ und $P(R_3|R_1 \cap R_2) = 4998/9998 \approx 0.5$. In diesem Fall ist der Auswahlatz relativ klein ($n/N = 0.0003$), so dass wir davon ausgehen können, dass auch beim Ziehen ohne Zurücklegen näherungsweise stochastische Unabhängigkeit gilt.

Stochastische Unabhängigkeit der Beobachtungen ist für die induktive Statistik (auch Inferenzstatistik) von großer Bedeutung. Da in der Praxis Stichproben i.d.R. ohne Zurücklegen gewonnen werden, ist es üblich durch die Wahl eines kleinen Auswahlatzes die stochastische Unabhängigkeit und damit die Konstanz der Eintrittswahrscheinlichkeit sicherzustellen.

Exkurs: Simulationen zur Veranschaulichung des CLT Unter einer Simulation verstehen wir die kontrollierte Wiederholung eines Zufallsexperiments. Benötigt wird hier der Befehl `sample()` zur Ziehung von Stichproben mit einer bestimmten Zahl an Elementen (`size`) aus `x` mit oder ohne Zurücklegen (`replace`). Betrachten wir als Beispiel: 6 Mal Würfeln ohne und mit Zurücklegen.

```
set.seed(4); sample(1:6, size = 6, replace = FALSE) # 6 Mal Würfeln ohne Zurücklegen
```

```
## [1] 3 6 5 4 2 1
```

```
set.seed(4); sample(1:6, size = 6, replace = TRUE) # 6 Mal Würfeln mit Zurücklegen
```

```
## [1] 3 3 3 4 3 6
```

Nun wollen wir uns den CLT für qualitative Daten veranschaulichen. Wir nehmen $p = 0.4$ (wahrer Anteilswert in der Grundgesamtheit) an. Zunächst definieren wir uns eine Grundgesamtheit (GG) mit $N = 1$ Mio.

```
rep(1, 10) # Wiederholung von Werten => Die "1" wird 10 Mal wiederholt
```

```
## [1] 1 1 1 1 1 1 1 1 1 1
```

```
GG <- c(rep(1, 400000), rep(0, 600000)); table(GG)
```

```
## GG
```

```
##      0      1
```

```
## 600000 400000
```

Wir ziehen mit Stichprobengröße $n = 100$ eine Zufallsstichprobe aus GG und berechnet den Stichprobenanteils wert.

```
set.seed(4); mean(sample(GG, size = 100, replace = TRUE))
```

```
## [1] 0.44
```

Das o.g. Zufallsexperiment wollen wir nun 1000 Mal durchführen.


```
TEST = c() # Definiere leere Variable TEST
```

Wir erzeugen mit `for()` einen “Loop” (Schleife).

```
for(i in 1:1000) {set.seed(i); TEST[i] = mean(sample(GG, size = 100, replace = TRUE))}  
TEST[1:6] # die ersten 6 Werte für den Stichprobenanteil
```


```
## [1] 0.38 0.47 0.39 0.44 0.41 0.45
```

```
hist(TEST)
```



```
qqnorm(TEST); qqline(TEST)
```

Normal Q-Q Plot



Mit der Darstellung von f und F können wir zeigen, dass der Stichprobenanteilstwert näherungsweise einer Normalverteilung nach CLT folgt. Man sieht im Plot von F aber auch, dass bestimmte Werte häufiger beobachtet werden als andere. Wir prüfen Lage- und Streuungsmaß:

```
mean(TEST) # sollte p = 0.4 sein
```

```
## [1] 0.40119
```

```
sd(TEST) # sollte sqrt(pq/n) = sqrt(0.4*0.6/100) = 0.049 sein
```

```
## [1] 0.048425
```

Betrachten wir das Beispiel zur Anwendung des CLT für qualitative Daten a) oben. Hier war $p = 0.4$ und $n = 800$. Gesucht ist die Wahrscheinlichkeit $P(h < 0.35)$. Die Vorgehensweise ist analog zu oben (nur die GG ist größer und wir wiederholen den Zufallszug 100000 Mal). Das Resultat ist OK.

```
GG <- c(rep(1, 4000000), rep(0, 6000000))
TEST = c() # Definiere leere Variable TEST
for(i in 1:100000) {set.seed(i); TEST[i] = mean(sample(GG, size = 800, replace = TRUE))}
TEST[1:6] # die ersten 6 Werte für den Stichprobenanteil
```

```
## [1] 0.39000 0.39250 0.37375 0.42000 0.38000 0.40250
```

```
prop.table(table(TEST < 0.35)) # sollte approx. 0.00195 sein
```


```
##  
## FALSE TRUE  
## 0.9982 0.0018
```

Nun wollen wir uns den CLT für quantitative Daten veranschaulichen. Wir generieren wieder eine Grundgesamtheit (GGq) mit 1 Mio. Werten. Vorab: Wir ziehen 10 Zufallszahlen aus dem Intervall [2,8].

```
runif(10, min = 2, max = 8) # ziehe 10 Mal aus [2,8]
```

```
## [1] 5.1546 6.6073 4.5036 6.4950 4.6107 3.9574 2.1220 7.3524 2.6687 6.1147
```

```
set.seed(4); GGq <- runif(1000000, min = 2, max = 8) # Erzeuge GGq  
hist(GGq)
```



```
mean(GGq); sd(GGq) # wahre Lage- und Streuungsmaße GGq ( $\mu$ ,  $\sigma$ )
```

```
## [1] 4.999
```

```
## [1] 1.7321
```

Aus dieser GGq ziehen wir jetzt wieder eine Zufallsstichprobe mit $n = 100$ und berechnen den Stichprobenmittelwert.


```
mean(sample(GGq, size = 100, replace = TRUE)) # eine Zufallsstichprobe
```

```
## [1] 4.8205
```


```
TEST2 <- c()
for(i in 1:1000) {set.seed(i); TEST2[i] <- mean(sample(GGq, size = 100, replace = TRUE))}
TEST2[1:3] # die ersten drei Stichprobenmittelwerte
```

```
## [1] 5.4339 5.1072 4.6206
```

```
hist(TEST2)
```



```
qqnorm(TEST2); qqline(TEST2)
```



Wir betrachten Mittelwert und Standardabweichung von TEST2. Der Mittelwert sollte sein 4.999038 (vgl. oben).

```
mean(TEST2) # nah am wahren Wert
```

```
## [1] 5.0027
```

Die Standardabweichung des Stichprobenmittels sollte sein $\sigma/\sqrt{n}$, wobei σ die wahre Standardabweichung in der Grundgesamtheit ist und n die Stichprobengröße. Wir sollten also erhalten $1.732097/10 = 0.1732097$.

```
sd(TEST2) # nah am wahren Wert
```

```
## [1] 0.17074
```

Inferenz für qualitative Daten (alle Module)

In diesem Abschnitt werden wir uns mit Methoden der Inferenzstatistik (auch induktive Statistik) für qualitative Daten beschäftigen. Dabei geht es zunächst darum, was wir aus den Stichprobenbeobachtungen über den unbekannten wahren Anteilswert p in der Grundgesamtheit schließen können. Im Anschluss wird erläutert, wie man testen kann, ob in einer Grundgesamtheit ein qualitatives Merkmal einer bestimmten Verteilung folgt und ob zwei qualitative Merkmale unabhängig voneinander sind.

Konfidenzintervall (KI) für p

Herleitung Nach dem CLT gilt näherungsweise:

$$H \sim N(p, \sqrt{\frac{p(1-p)}{n}}) \text{ und } \frac{H-p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1)$$

Wir können also für den standardisierten Stichprobenanteilswert näherungsweise die Wahrscheinlichkeit definieren, dass dieser Wert in ein um 0 symmetrisches Intervall $[-z, +z]$ fällt. Diese Wahrscheinlichkeit ist:

$$P(-z < \frac{H-p}{\sqrt{\frac{p(1-p)}{n}}} < +z) \approx F_{St}(+z) - F_{St}(-z)$$

Wir treffen nun folgende Annahmen:

- (1) Wir verwenden den Standardfehler (Standard Error) $SE = \sqrt{\frac{h(1-h)}{n}}$ als Näherung für $\sqrt{\frac{p(1-p)}{n}}$, wenn die Stichprobe hinreichend groß ist (vgl. unten).
- (2) Die Wahrscheinlichkeit, mit der der standardisierte Stichprobenanteil in das Intervall $[-z, +z]$ fällt, sei $1 - \alpha$ und wird "Vertrauenswahrscheinlichkeit" (confidence level) genannt.
- (3) $z_{[\alpha/2]} = -z_{[1-\alpha/2]}$ wegen Symmetrie der $N(0, 1)$ -Verteilung.


Die Wahrscheinlichkeitsaussage ist dann

$$P(z_{[\alpha/2]} < \frac{H-p}{SE} < z_{[1-\alpha/2]}) \approx 1 - \alpha$$

Graphisch lässt sich diese Wahrscheinlichkeitsaussage folgendermaßen darstellen.

```
cord.x4 <- c(-4, seq(-4, -1.96, 0.01), -1.96)
cord.y4 <- c(0, dnorm(seq(-4, -1.96, 0.01)), 0)
cord.x5 <- c(1.96, seq(1.96, 4, 0.01), 4)
cord.y5 <- c(0, dnorm(seq(1.96, 4, 0.01)), 0)
curve(dnorm(x), xlim=c(-4, 4), ylim = c(-0.01, 0.5), axes = F,
      main = "Verteilung von h", cex.main = 1.1,
      xlab = "", ylab = "", lwd = 2, cex.lab = 1.1)
polygon(cord.x4, cord.y4, col='red')
polygon(cord.x5, cord.y5, col='red')
segments(-4, 0, 4, 0)
segments(0, -0.01, 0, 0.01)
text(2.8, 0.09, expression(frac(alpha, 2)), cex = 1.1)
text(-2.8, 0.09, expression(frac(alpha, 2)), cex = 1.1)
text(0, 0.04, expression(p), cex = 1.1)
text(0, 0.15, expression(1 - alpha), cex = 1.3)
text(0.75, 0.4, expression(paste("f(", h, ")")), cex = 1.1)
text(4.2, 0.003, expression(h), cex = 1.1)
segments(2.5, 0.07, 2.1, 0.03)
segments(-2.5, 0.07, -2.1, 0.03)
```

Verteilung von h



Die Residualwahrscheinlichkeit α (auch als “Irrtumswahrscheinlichkeit” bezeichnet) teilt sich zu gleichen Teilen mit $\alpha/2$ auf den rechten und linken Rand der symmetrischen Verteilung auf.

Wir können dann die Wahrscheinlichkeitsaussage oben so umformen, dass der wahre Anteilswert p in der Mitte der Wahrscheinlichkeitsaussage steht. Anstelle des Stichprobenanteils als Variable (H) schreiben wir nun für den beobachteten Stichprobenanteil h . Die Idee des Intervalls ist: Wenn wir - basierend auf dem CLT - von p etwas über h lernen können, dann können wir das Ganze auch umdrehen und von h etwas über p lernen. Die umgeformte Wahrscheinlichkeitsaussage ist dann:

$$P(h - z_{[1-\alpha/2]}SE < p < h + z_{[1-\alpha/2]}SE) \approx 1 - \alpha$$

Das $(1 - \alpha)$ -**Konfidenzintervall** für das wahre p in der Grundgesamtheit ist dann:

$$KI(1 - \alpha)_p = h \pm z_{[1-\alpha/2]}SE = h \pm ME$$

mit $ME = z_{[1-\alpha/2]}SE$ und $SE = \sqrt{\frac{h(1-h)}{n}}$

Der Term ME wird als “absoluter Fehler” oder “Margin of Error” bezeichnet. Der ME beträgt die Hälfte der Länge des KIs.

Die **Annahmen** zur Anwendung des KI sind: (1) Unabhängigkeit und (2) große Stichprobe.

Bedingungen für (1):

- Zufallsstichprobe
- bei Ziehen ohne Zurücklegen muss ein kleiner Auswahlsatz vorliegen mit $n/N \leq 0.05$

und für (2):

- $nh \geq 10$ und $n(1 - h) \geq 10$

Diese Annahmen und Bedingungen sind - leicht modifiziert - auch beim Hypothesentest für p (vgl. unten) zu prüfen.

Beispiele Betrachten wir zunächst Bsp. 9.10 im Lehrbuch (S. 201). Ein Industrieunternehmen produziert ein Massenprodukt. Aus einer Grundgesamtheit von 50000 Einheiten des Produkts wurde eine Zufallsstichprobe vom Umfang $n = 600$ gezogen. In der Stichprobe befanden sich 68 unbrauchbare Produkte.

```
n <- 600      # Stichprobengröße
h <- 68/600   # Ausschussanteil in der Stichprobe
```

Wir wollen ein 90%-KI für den wahren Ausschussanteil in der Grundgesamtheit berechnen.

1. Methode: “per Hand” mit Hilfe der Formel oben.

```
z <- qnorm(0.95); z      # z-Wert für alpha = 0.1

## [1] 1.6449

SE <- sqrt(h*(1 - h)/n); SE  # SE

## [1] 0.012941

CI_low <- h - z*SE; CI_up <- h + z*SE
CI_low; CI_up             # untere und obere Grenze des KI

## [1] 0.092047

## [1] 0.13462

ME <- (CI_up - CI_low)/2; ME  # Margin of Error (abs. Fehler)

## [1] 0.021287
```

Häufig findet man folgende Interpretation des KI: Mit einer Wahrscheinlichkeit von 90% liegt der wahre, aber unbekannte Anteilswert für Ausschuss zwischen 9.2% und 13.5%. Das Problem ist aber, dass es nur **einen** wahren Anteilswert p gibt. Daher ist es nicht richtig, eine Wahrscheinlichkeitsaussage für ein einzelnes KI zu formulieren. Entweder p liegt im KI oder eben nicht.

Die richtige Interpretation ist: Wenn man 100 Stichproben nach dieser Methode ziehen würde, würde man 100 unterschiedliche KIs erhalten. Von diesen 100 KIs werden im Mittel 90 den wahren Anteilswert beinhalten und 10 nicht. Unser KI, [9.2%, 13.5%], ist eines dieser 100 KIs. Das **Vertrauen** (“confidence”) bezieht sich also nicht auf das einzelne KI, sondern auf die **Methode**, solche Intervalle zu konstruieren.

Kürzer: Wir können zu 90% darauf vertrauen, dass ein nach dieser Methode erzeugtes Intervall den wahren Ausschussanteil in der Grundgesamtheit beinhaltet. Unser KI, [9.2%, 13.5%], ist ein solches Intervall.

2. Methode: mit `prop.test()`

```
prop.test(68, 600, conf.level = 0.90) # [0.0930, 0.1373], ME = 0.02215
```

```
##
## 1-sample proportions test with continuity correction
##
## data: 68 out of 600, null probability 0.5
## X-squared = 357, df = 1, p-value <2e-16
## alternative hypothesis: true p is not equal to 0.5
## 90 percent confidence interval:
## 0.092997 0.137276
## sample estimates:
## p
## 0.11333
```

Die Ausgabe enthält einige Informationen, die uns (noch) nicht interessieren. Hier ist relevant die Ausgabe des KI (90 percent confidence interval) und der Punktschätzung für p (sample estimates, Stichprobenanteilstwert h). Es gibt eine kleine (und vernachlässigbare) Abweichung zum Ergebnis oben, da R zusätzlich noch mit einer Stetigkeitskorrektur rechnet.

Trade-off zwischen Präzision und Sicherheit Wovon ist die Breite des KIs, also die Präzision der Aussage, abhängig? Aus der Formel zur Berechnung des KI ergibt sich, dass es zwei Optionen gibt, zu einer präziseren Aussage (also zu einem schmalen KI) zu gelangen:

- (1) Reduzierung der Vertrauenswahrscheinlichkeit: Ein kleineres $1 - \alpha$ führt zu einem schmalen KI, da mit steigendem α der Wert $z_{[1-\alpha/2]}$ sinkt. So ist z.B. für $1 - \alpha = 0.90$ der z-Wert $z_{[0.95]} = 1.645$ und für $1 - \alpha = 0.95$ ist der z-Wert $z_{[0.975]} = 1.96$. Werte unter 90% für die Vertrauenswahrscheinlichkeit sind unüblich.
- (2) Größere Stichprobe: Ein höheres n reduziert den Standardfehler und damit auch den Margin of Error.

Betrachten wir zu (2) Bsp. 9.10 und verdoppeln die Stichprobe von 600 zu 1200. Um einen sinnvollen Vergleich zu ermöglichen, muss auch die Zahl der Erfolge verdoppelt werden (von 68 zu 136). Wir nutzen wieder `prop.test()`.

```
prop.test(2*68, 2*600, conf.level = 0.90) # [0.0988, 0.1297], ME = 0.01545
```

```
##
## 1-sample proportions test with continuity correction
##
## data: 2 * 68 out of 2 * 600, null probability 0.5
## X-squared = 716, df = 1, p-value <2e-16
## alternative hypothesis: true p is not equal to 0.5
## 90 percent confidence interval:
## 0.098751 0.129703
## sample estimates:
## p
## 0.11333
```

Das KI wird schmaler (der ME wird um ca. 30% kleiner), aber der Effekt ist relativ klein (immerhin wurde n verdoppelt). Dies liegt daran, dass die Quadratwurzel im SE den Effekt der Vergrößerung von n "bremst" (eine Verdopplung von n reduziert den ME auf das $1/\sqrt{2}$ -fache).

Punkt (1) oben macht deutlich: Es gibt einen **trade-off** (auch “Abwägen” oder “Zielkonflikt”) zwischen der **Präzision** der Aussage (Breite des KI) und der **Sicherheit** der Aussage (Vertrauen in das KI). Eine höhere Sicherheit bzgl. der Aussage über p geht einher mit geringerer Präzision und umgekehrt. Mit anderen Worten: Wir müssen also einen “Preis” (geringeres Präzision) für höhere Sicherheit zahlen. Das ist das fundamentale Problem der schließenden Statistik. Glücklicherweise können wir oft mit Aussagen ausreichend präzise (z.B. $ME < 0.05$) und zugleich relativ sicher (z.B. mit $1 - \alpha = 0.95$) sein.

Im Beispiel oben erhöhen wir $1 - \alpha$ auf 99%.

```
prop.test(68, 600, conf.level = 0.99) # relativ breites KI
```

```
##
## 1-sample proportions test with continuity correction
##
## data: 68 out of 600, null probability 0.5
## X-squared = 357, df = 1, p-value <2e-16
## alternative hypothesis: true p is not equal to 0.5
## 99 percent confidence interval:
## 0.083422 0.151911
## sample estimates:
## p
## 0.11333
```

Zurück zur Aufgabe oben: In einer Pressemitteilung würde das o.g. KI folgendermaßen dargestellt werden: Der Ausschussanteil ist 11.3% +/- 2.1% bei $n = 600$. Man gibt also den Stichprobenanteilswert h und den Margin of Error sowie n an. Aus diesen Angaben kann mit der Formel für das KI auch (näherungsweise) der $z_{[1-\alpha/2]}$ -Wert berechnet werden und damit ist klar, dass bei $z_{[1-\alpha/2]} = z_{[0.95]} = 1.645$ ein 90%-KI berechnet wurde.

```
ME <- 0.021 # Margin of Error ist 2.1%
z <- ME/sqrt(0.113*(1 - 0.113)/600) # Berechnung von z
z # z ist approx. 1.645 => z[0.95] => 1 - alpha = 0.9
```

```
## [1] 1.6248
```

Hypothesentest für p

Schrittfolge Wir wollen eine Hypothese über den unbekannten Anteilswert p in der Grundgesamtheit testen. Dazu nehmen wir die Hypothese als **wahr** an und vergleichen die Stichprobeninformation mit dem, was man unter Gültigkeit der Hypothese erwarten kann. Gibt es einen großen Unterschied zwischen der Erwartung basierend auf der Hypothese und Stichprobeninformation, verwerfen wir die Hypothese.

Wir werden im Folgenden mit folgender Schrittfolge für einen Hypothesentest arbeiten:

1) *Hypothesen aufstellen und Signifikanzniveau (maximale Wahrscheinlichkeit für Fehler 1. Art, α) festlegen.* Die Ausgangshypothese wird als **Nullhypothese** H_0 bezeichnet. H_0 wird als wahr angenommen. Das eigentlich interessante Ergebnis wird i.d.R. in der **Alternativhypothese** H_A “versteckt”. Ziel ist letztlich die Ablehnung der Nullhypothese und die Akzeptanz der Alternative. Die Ablehnung von H_0 ist aber nur möglich, wenn wir “begründete Zweifel” an der Nullhypothese haben. Ein Hypothesentest stellt quasi Regeln auf, um zu überprüfen, ob solche begründeten Zweifel vorliegen oder nicht.

Es werden zweiseitige und einseitige Tests unterschieden (je nach Richtung der H_A):

- zweiseitig: $H_0: p = p_0$ vs. $H_A: p \neq p_0$ (Abweichung von p_0 in beide Richtungen möglich)

- oberseitig: $H_0 : p = p_0$ vs. $H_A : p > p_0$ (Abweichung von p_0 nur nach oben möglich)
- unterseitig: $H_0 : p = p_0$ vs. $H_A : p < p_0$ (Abweichung von p_0 nur nach unten möglich)

Bei einem Hypothesentest sind zwei Fehler möglich (vgl. folgende Tabelle). Man kann eine wahre Nullhypothese verwerfen (Fehler 1. Art, auch als α -Fehler oder “false positive” bezeichnet) oder eine falsche Nullhypothese nicht verwerfen (Fehler 2. Art, β -Fehler, “false negative”).

Table 3: Fehler beim Hypothesentest

	H_0 ist wahr	H_0 ist nicht wahr
verwerfe H_0	Fehler 1. Art (α -Fehler)	richtige Entscheidung
verwerfe H_0 nicht	richtige Entscheidung	Fehler 2. Art (β -Fehler)

Betrachten wir als Beispiel eine Gerichtsverhandlung. Die Nullhypothese ist hier “der Angeklagte ist unschuldig”. Wenn die Nullhypothese wahr ist und der Angeklagte wird verurteilt, begeht man einen Fehler 1. Art. Wird dagegen ein eigentlich Schuldiger nicht verurteilt, liegt ein Fehler 2. Art vor. Welcher Fehler ist wichtiger?

In der Medizin ist die Nullhypothese i.d.R. “der Wirkstoff hat keinen Effekt”. Wenn die Nullhypothese wahr ist und man kommt dennoch zum Ergebnis, dass es einen Effekt des Wirkstoffs gibt, begeht man einen Fehler 1. Art (daher “false positive”). Wird dagegen ein eigentlich existierender Effekt nicht entdeckt, liegt ein Fehler 2. Art vor (daher “false negative”).

Beim Hypothesentest in der Praxis liegt der Fokus auf dem **Fehler 1. Art**. Dieser soll ein bestimmtes Niveau α (auch “Signifikanzniveau” genannt, i.d.R. 0.05) nicht überschreiten. Man beachte, dass man den Fehler 1. Art sehr wohl auf Null minimieren könnte (wenn H_0 nie verworfen wird), dann aber der Fehler 2. Art 1 bzw. 100% werden würde, wenn H_0 falsch ist. Dies wäre keine sinnvolle Teststrategie. Man wird also nicht ohne Fehler 1. und 2. Art auskommen.

Stattdessen geht man folgendermaßen vor: In der Zufallsstichprobe wird ein Stichprobenanteil h beobachtet. Wir lehnen dann H_0 nur ab, wenn die Abweichung zwischen h und dem als wahr angenommenen Wert aus der Null, p_0 , bedeutsam (“statistisch signifikant”) ist. Der Fehler 1. Art soll dabei ein bestimmtes Signifikanzniveau nicht überschreiten. Das typische Signifikanzniveau ist $\alpha = 0.05$ (seltener 0.01 oder 0.10).

Die exakte Wahrscheinlichkeit für den Fehler 1. Art kann bestimmt werden, weil wir gemäß CLT die Verteilung von h kennen (gegeben die Annahme: H_0 ist wahr). Die Berechnung des Fehlers 2. Art ist i.d.R. deutlich schwieriger, weil es viele denkbare falsche H_0 -Werte gibt (vgl. Exkurs bzw. Lehrbuch).

2) *Festlegung der Testvariable (Z) und Testverteilung.* Gemäß CLT folgt H einer $N(p_0, \sqrt{\frac{p_0(1-p_0)}{n}})$ -Verteilung, denn H_0 wurde als wahr angenommen. Damit folgt $\frac{H-p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$ einer $N(0, 1)$ -Verteilung und Z (standardnormalverteilte Zufallsvariable) kann als **Testvariable** verwendet werden. Wenn der empirische Wert von Z (mit z bzw. als “Prüfgröße” bezeichnet) weit weg von Null liegt, gibt es eine bedeutsame bzw. “statistisch signifikante” Abweichung zwischen h und p_0 . Die Annahmen und Bedingungen (diese sind identisch zum $(1 - \alpha)$ -KI für p mit einer Ausnahme: für eine große Stichprobe muss gelten: $np_0 \geq 10$ und $n(1 - p_0) \geq 10$) sind zuvor zu prüfen.

3) *Berechnung der Prüfgröße z und des p-value.* Der Wert der **Prüfgröße** z (so wird der empirische Wert der Testvariable Z bezeichnet) berechnet sich folgendermaßen:

$$z = \frac{h-p_0}{\sigma} \text{ mit } \sigma = \sqrt{\frac{p_0(1-p_0)}{n}}$$

Achtung: σ ist hier kein Standardfehler, sondern eine Standardabweichung, da wir H_0 als gültig und somit als wahr unterstellen.

Um zu einer Entscheidung über H_0 zu kommen, wird dann der sog. **p-value** berechnet. Der p-value ist die Wahrscheinlichkeit, Daten wie in der Stichprobe oder extremer zu beobachten, wenn H_0 wahr ist. Wenn

der p-value sehr gering und kleiner als das Signifikanzniveau α ist, verwerfen wir H_0 , weil unser Misstrauen gegenüber dieser Hypothese zu groß ist.

Der p-value berechnet sich hier folgendermaßen:

- zweiseitig: $\text{p-value} = 2(1 - F_{St}(|z|))$
- oberseitig: $\text{p-value} = 1 - F_{St}(z)$
- unterseitig: $\text{p-value} = F_{St}(z) = 1 - F_{St}(|z|)$

mit $F_{St}(z)$ als Verteilungsfunktion von $N(0, 1)$.

Ist der p-value hinreichend klein ($< \alpha$) haben wir kein Vertrauen in H_0 . Wir lehnen dann H_0 ab und nehmen H_A an. Mit der Ablehnung von H_0 (und damit mit der Akzeptanz von H_A) haben wir jedoch nicht gezeigt, dass H_0 falsch ist (Sicherheit darüber kann nur eine Totalerhebung bringen). Wir haben nur unsere “begründeten Zweifel” an H_0 zum Ausdruck gebracht. Wir haben bei Nicht-Ablehnung von H_0 auch nicht gezeigt, dass H_0 wahr ist (wir hatten schließlich angenommen, dass die Nullhypothese wahr ist). Man hat dann nur gezeigt, dass man H_0 nicht verwerfen kann (und üblicherweise arbeitet man dann weiter mit der Nullhypothese).

4) *Entscheidung und Interpretation.* Die Entscheidung basierend auf dem p-value erfolgt nach der Regel: Ablehnung von H_0 , wenn $\text{p-value} < \alpha$. Alternativ wäre auch eine Entscheidung über den Vergleich der Prüfgröße mit einem, aus dem Signifikanzniveau abgeleiteten, kritischen Wert der Testverteilung möglich (vgl. Lehrbuch). Die Interpretation der Entscheidung über H_0 hat im Kontext zu erfolgen (ebenso wie die Interpretation des p-value). Der p-value kann dabei als Indikator für die **Glaubwürdigkeit** von H_0 interpretiert werden: Dieser Wert gibt schließlich die Wahrscheinlichkeit an, dass das Stichprobenergebnis oder extremere Werte rein zufällig zustande gekommen sein können, wenn H_0 wahr ist. Wenn diese Wahrscheinlichkeit sehr klein ist, spricht das gegen H_0 und wir verwerfen.

Der hier erläuterte Test wird auch **Einstichproben-z-Test** (one proportion z-test) genannt.

Beispiele Beispiel 1: Aus früheren Untersuchungen sei bekannt, dass die Kundenzufriedenheit bei 30% liegt. Nach einer “Charmeoffensive” werden 500 zufällig ausgewählte Kunden nach ihrer Zufriedenheit befragt. 35% geben an “zufrieden” zu sein. Hat die “Charmeoffensive” etwas gebracht? Das Signifikanzniveau sei 0.05.

Wir testen hier oberseitig $H_0 : p = 0.3$ vs. $H_A : p > 0.3$, da wir daran interessiert sind zu zeigen, dass die Charmeoffensive einen positiven Effekt hatte. Bevor wir mit den Berechnungen beginnen, prüfen wir, ob die Bedingungen für die Anwendung eines Hypothesentests erfüllt sind: (1) Zufallsstichprobe, (2) kleiner Auswahlatz mit $n/N \leq 0.05$ und (3) $np_0 \geq 10$ und $n(1 - p_0) \geq 10$.

```
h <- 0.35; n = 500; p0 <- 0.3
SD <- sqrt((p0*(1-p0))/n); SD
```

```
## [1] 0.020494
```

```
z <- (h - p0)/SD; z # Wert der Prüfgröße
```

```
## [1] 2.4398
```

Der Wert der Prüfgröße ist also hier $z = 2.4$. Der p-value berechnet sich mit

```
1 - pnorm(2.4) # p-value für oberseitigen Test
```

```
## [1] 0.0081975
```

```
prop.test(0.35*500, 500, p = 0.3, alternative = c("greater"))
```

```
##  
## 1-sample proportions test with continuity correction  
##  
## data: 0.35 * 500 out of 500, null probability 0.3  
## X-squared = 5.72, df = 1, p-value = 0.0084  
## alternative hypothesis: true p is greater than 0.3  
## 95 percent confidence interval:  
## 0.31484 1.00000  
## sample estimates:  
## p  
## 0.35
```

Wenn die Kundenzufriedenheit in der Grundgesamtheit tatsächlich bei 30% liegt, ist die Wahrscheinlichkeit, bei einer Zufallsstichprobe von $n = 500$ einen Anteilswert von 35% oder größer zu beobachten, gleich 0.8%. Auf Grund der Tatsache, dass der p-value unter dem Signifikanzniveau α (dem max. zulässigen Fehler 1. Art, hier 0.05) liegt, verwerfen wir die Nullhypothese und nehmen die Alternative an. Es gibt also einen statistisch signifikanten, positiven Effekt der Charmeoffensive auf die Kundenzufriedenheit.

Ist der Effekt auch ökonomisch bedeutsam? Die Frage der ökonomischen Signifikanz ist kontextabhängig (vgl. zur Unterscheidung zwischen statistischer und ökonomischer Signifikanz unten), allerdings kann eine Effektgröße von 5 Prozentpunkten als relativ stark bezeichnet werden.

Beispiel 2 (Bsp. 10.7 aus dem Lehrbuch, S. 236): Bei einer Befragung in den USA werden 2336 Wahlberechtigte nach ihrer Einschätzung der wirtschaftlichen Lage befragt. Von den Befragten geben 33% an, die wirtschaftliche Lage sei “schlecht”. In der Vorperiode lag der wahre Anteil derjenigen, die die wirtschaftliche Lage als “schlecht” einstufen, bei 30%. Hat sich der Anteil geändert? Das Signifikanzniveau sei 0.05.

Auch hier gehen wir nach den oben erläuterten Schritten vor: Wir testen zweiseitig, da wir keine Erwartung hinsichtlich der Richtung der Abweichung haben, und stellen die Hypothesen auf mit $H_0 : p = 0.3$ vs. $H_A : p \neq 0.3$. Wir können den CLT anwenden und Z als Testvariable verwenden. Die Bedingungen zur Anwendung des Einstichproben-z-Tests sind erfüllt.

Die Standardabweichung und der Wert der Prüfgröße berechnen sich mit

```
sigma <- sqrt(0.3*0.7/2336); sigma
```

```
## [1] 0.0094814
```

```
z <- abs((0.33 - 0.3)/sigma); z # Wert der Prüfgröße
```

```
## [1] 3.1641
```

Es gilt “pie-mal-Daumen”: Alle Werte für $|z| > 2$ sind “überraschend” groß und implizieren einen kleinen p-value und damit ein Ablehnen der Nullhypothese bei einem zweiseitigen Test mit $\alpha = 0.05$.

```
pvalue <- 2*(1- pnorm(z)); pvalue # p-value bei zweiseitigem Test
```

```
## [1] 0.0015557
```

Die Umsetzung mit `prop.test()` ist

```
prop.test(0.33*2336, 2336, p = 0.3, alternative = c("two.sided"))
```

```
##
## 1-sample proportions test with continuity correction
##
## data: 0.33 * 2336 out of 2336, null probability 0.3
## X-squared = 9.87, df = 1, p-value = 0.0017
## alternative hypothesis: true p is not equal to 0.3
## 95 percent confidence interval:
## 0.31101 0.34955
## sample estimates:
## p
## 0.33
```

Auch hier gibt es eine zu vernachlässigende Abweichung (vgl. die Werte der p-values) zwischen beiden Methoden.

Der p-value ist mit 0.002 oder 0.2% kleiner als das gewählte Signifikanzniveau $\alpha = 0.05$. Daher lehnen wir H_0 ab und nehmen H_A an. Die Interpretation des p-value ist: Wenn in der Grundgesamtheit 30% der US-Amerikaner der Meinung sind, die wirtschaftliche Lage sei "schlecht", dann ist bei einer Zufallsstichprobe von $n = 2336$ die Wahrscheinlichkeit, eine Abweichung von 3%-Punkten oder extremer zu beobachten, gleich 0.2%. Auf Grund dieser geringen Wahrscheinlichkeit verwerfen wir die Nullhypothese und müssen davon ausgehen, dass sich der Anteil geändert hat.

Beispiel 3 (Bsp. 10.9 aus dem Lehrbuch, S. 237): Ein Hersteller von Smartphones hat eine Ausschussquote von 20%. Eine Untersuchung zu einem neuen Produkt zeigt, dass 92 und damit 17.8% von 517 zufällig ausgewählten Geräten ausfielen. Gibt es damit empirische Evidenz, dass die Ausschussquote für das neue Modell unter den 20% früherer Modelle liegt? Das Signifikanzniveau sei 0.05.

Die Hypothesen sind: $H_0 : p = 0.2$ vs. $H_A : p < 0.2$. Wir testen also unterseitig zu $\alpha = 0.05$. Unterseitig, weil wir daran interessiert sind zu zeigen, dass eine Verbesserung der Produktion (= Verringerung der Ausschussquote) erreicht werden konnte. Z ist die Testvariable, weil die Bedingungen zur Anwendung der Normalverteilung erfüllt sind (die Annahmen sind zu nennen und die Bedingungen zu prüfen).

Der Wert der Prüfgröße (= empirischer Wert der Testvariable) bzw. der p-value können folgendermaßen berechnet werden:

```
h <- 92/517; h # Stichprobenanteil
```

```
## [1] 0.17795
```

```
sigma <- sqrt(0.2*0.8/517) # Standardabweichung
z <- (h - 0.2)/sigma; z # Wert der Prüfgröße
```

```
## [1] -1.2534
```

```
pvalue <- pnorm(z); pvalue # p-value
```

```
## [1] 0.10502
```

```
prop.test(x = 92, n = 517, p = 0.2, alternative = c("less"))
```

```
##
## 1-sample proportions test with continuity correction
##
## data: 92 out of 517, null probability 0.2
## X-squared = 1.44, df = 1, p-value = 0.12
## alternative hypothesis: true p is less than 0.2
## 95 percent confidence interval:
## 0.000000 0.20829
## sample estimates:
## p
## 0.17795
```


Entscheidung: Da der p-value deutlich > 0.05 ist, können wir H_0 nicht verwerfen. Interpretation des p-value: Wenn in der Grundgesamtheit der Ausschussanteil 20% ist, liegt die Wahrscheinlichkeit bei einer Zufallsstichprobe von $n = 517$ einen Ausschussanteil von 17.8% oder weniger zu beobachten, bei ca. 10%. Diese Wahrscheinlichkeit ist relativ groß, daher lehnen wir die Nullhypothese nicht ab. Wir können also keine statistisch signifikante Reduzierung der Ausschussrate feststellen. In einer Präsentation würde man schreiben: In einer Stichprobe von $n = 517$ wurde ein Ausschussanteil von 17.8% beobachtet. Dieser Wert ist nicht statistisch signifikant kleiner als der Referenzwert 20% ($z = -1.25$, p-value = 0.105). Hier liegt also keine statistische Signifikanz vor, allerdings könnte die Effektgröße von 2.2 Prozentpunkten durchaus ökonomisch signifikant sein. Dies ist kontextabhängig (vgl. zur Unterscheidung zwischen statistischer und ökonomischer Signifikanz unten).

Wie oben erläutert, haben wir bei p-value $\geq \alpha$ **nicht** gezeigt, dass H_0 wahr ist, sondern nur, dass wir nicht in der Lage waren, H_0 zu verwerfen.

Der p-value lässt sich für das Beispiel graphisch folgendermaßen zeigen:

```
cord.x1 <- c(-4, seq(-4, -1.25, 0.01), -1.25)
cord.y1 <- c(0, dnorm(seq(-4, -1.25, 0.01)), 0)
curve(dnorm(x), xlim=c(-4, 4), ylim = c(0, 0.5), lwd = 2,
      main = "N(0,1) und 5%-Quantil",
      cex.lab = 1.1, cex.axis = 1.1, ylab = "f(z)", xlab = "z")
polygon(cord.x1, cord.y1, col='red')
text(-3.2, 0.38, "p = 0.105", cex = 1.1)
arrows(-3, 0.35, -2, 0.1)
abline(v = qnorm(0.05), lty = 1.5, lwd = 2) # kritischer z-Wert
```

N(0,1) und 5%-Quantil



Ab welchem Stichprobenanteilstwert hätte man H_0 bei $\alpha = 0.05$ abgelehnt? In der Ausgangssituation hatten wir 92 defekte Teile.

```
prop.test(x = 87, n = 517, p = 0.2, alternative = c("less"))
```

```
##
## 1-sample proportions test with continuity correction
##
## data: 87 out of 517, null probability 0.2
## X-squared = 3.06, df = 1, p-value = 0.04
## alternative hypothesis: true p is less than 0.2
## 95 percent confidence interval:
## 0.00000 0.19808
## sample estimates:
## p
## 0.16828
```

Bei 87 defekten Teilen oder weniger hätten wir H_0 zu einem p-value < 0.05 abgelehnt. Also bei einem Stichprobenanteil von $87/517 = 16.8\%$ oder weniger.

Statistische vs. ökonomische Signifikanz Der Wert der Prüfgröße z ($\Leftrightarrow$ p-value) ist der Indikator für **statistische Signifikanz** und damit für die Frage, ob ein bestimmtes Stichprobenergebnis oder extremere Werte sich zufällig ergeben haben können. Ist z betragsmäßig groß (und damit der p-value klein, d.h. $< \alpha$) spricht man von einem “statistisch signifikanten” Resultat. In diesem Fall können wir also davon ausgehen,

dass das beobachtete Stichprobenergebnis **nicht zufällig** zustandegekommen ist. Es gibt also “begründete Zweifel” an der Nullhypothese: H_0 wird verworfen und H_A angenommen.

Die Effektgröße $|h - p_0|$ (also der Betrag des Zählers von z) ist hingegen der Indikator für **ökonomische Signifikanz**, also für die Abweichung zwischen dem beobachteten Stichprobenwert und dem als wahr angenommenen Wert in der Null. Was hier “ökonomisch bedeutsam” ist, ist i.d.R. kontextabhängig (es gibt für den Einstichproben-z-Test auch Maßzahlen, die hier aber nicht betrachtet werden). Unter sonst gleichen Bedingungen erhöht sich mit zunehmender Effektgröße auch die statistische Signifikanz, da $z = (h - p_0)/\sigma$ mit $\sigma = \sqrt{p_0(1 - p_0)/n}$. Das Problem ist aber: Es gibt ökonomisch signifikante Effekte, die nicht statistisch signifikant sind und umgekehrt. Dabei ist die **Stichprobengröße** n von zentraler Bedeutung. Wenn n klein ist, ist σ groß, und z ist dann selbst bei einer relativ großen Effektgröße ($\Leftrightarrow$ ökonomisch bedeutender Effekt) klein und es liegt keine statistische Signifikanz vor. Ist hingegen n groß, kann auch eine relativ kleine Effektgröße ($\Leftrightarrow$ ökonomisch unbedeutender Effekt) statistisch signifikant werden. Mit anderen Worten: Jede noch so kleine Effektgröße kann durch ein hinreichend großes n “statistisch signifikant” werden. Ziel ist also, mit relativ geringem n statistisch signifikante Effekte zu zeigen. Man sollte daher bei der Präsentation von Testergebnissen immer Effektgröße, Prüfgröße, n und den p-value angeben. So kann man sich leicht selbst ein Bild machen, ob eine statistische Signifikanz durch eine relativ große Stichprobe verursacht wurde, aber der beobachtete Effekt ökonomisch eher unbedeutend ist.

Beispiel: Es sei $H_0 : p = 0.2$ vs. $H_A : p \neq 0.2$. Wir testen also zweiseitig. Eine relativ “kleine” Effektgröße von 1%-Punkt, ist bei einem zweiseitigen Test zu $\alpha = 0.05$ “statistisch signifikant”, wenn $n = 10000$, aber “statistisch insignifikant” bei $n = 1000$. Zur Erinnerung: Der kritische Wert der Prüfgröße bei einem zweiseitigen Test und $\alpha = 0.05$ ist $z_{[0.975]} = 1.96$.

```
z1 <- abs((0.19 - 0.2)/sqrt(0.2*0.8/10000)); z1 # großer z-Wert
```

```
## [1] 2.5
```

```
z2 <- abs((0.19 - 0.2)/sqrt(0.2*0.8/1000)); z2 # kleiner z-Wert
```

```
## [1] 0.79057
```

Normalerweise liegt n für einen one-proportion z-Test im Intervall $[800, 1500]$.

Exkurs: p-value und Fehler 1. Art In diesem Exkurs soll gezeigt werden, dass wir mit der Festlegung des Signifikanzniveaus α letztlich die maximal akzeptable Wahrscheinlichkeit für den Fehler 1. Art festlegen.

Wir definieren eine große Grundgesamtheit (**pop**) mit einem wahren Anteil von $p = 0.3$.

```
pop <- c(rep(1, 300000), rep(0, 700000))
length(pop); prop.table(table(pop))
```

```
## [1] 1000000
```

```
## pop
## 0 1
## 0.7 0.3
```

Wir ziehen aus dieser Grundgesamtheit nun eine Stichprobe mit $n = 800$ und testen $H_0: p = 0.3$ vs. $H_A: p \neq 0.3$ zu einem Signifikanzniveau von $\alpha = 0.05$. Wir wiederholen dies 1000 Mal und generieren somit 1000 Zufallsstichproben mit $n = 800$ und können 1000 Mal einen z-Wert und einen p-value berechnen. Von den 1000 p-values liegen 49 (4.9%) unter 5%, d.h., in diesen Fällen verwerfen wir H_0 , obwohl diese Hypothese richtig ist (= Fehler 1. Art).

```
TEST = c() # empty variable TEST
for(i in 1:1000) {set.seed(i); TEST[i] = mean(sample(pop, 800, replace = T))}
TEST[1]    # 1st sample proportion
```

```
## [1] 0.30375
```

```
TEST[31]   # 31st sample proportion
```

```
## [1] 0.34875
```

```
SD <- sqrt(0.3*0.7/800)
z <- (TEST - 0.3)/SD
(TEST[1] - 0.3)/SD # 1st z-score
```

```
## [1] 0.23146
```

```
(TEST[31] - 0.3)/SD # 31st z-score
```

```
## [1] 3.0089
```

```
p.value <- 2*(1 - pnorm(abs(z)))
2*(1 - pnorm(abs((TEST[1] - 0.3)/SD))) # 1st p-value
```

```
## [1] 0.81696
```


```
2*(1 - pnorm(abs((TEST[31] - 0.3)/SD))) # 31st p-value
```

```
## [1] 0.0026218
```


```
prop.table(table(p.value < 0.05))
```

```
##
## FALSE TRUE
## 0.951 0.049
```

```
hist(z); qqnorm(z)
```



Normal Q-Q Plot



Hier werden exemplarisch zwei Stichproben dargestellt: Die 1. ($h = 0.3038$, relativ geringe Abweichung von 0.3, keine Ablehnung von H_0 , p-value = 0.817) und die 31. ($h = 0.3488$, relativ große Abweichung von 0.3, Ablehnung von H_0 , p-value = 0.003). In der Praxis haben wir natürlich nur **eine Stichprobe** und kennen den wahren Anteilswert in der Grundgesamtheit nicht. Durch die Festlegung auf das Signifikanzniveau α können wir aber darauf vertrauen, dass wir die wahre Nullhypothese höchstens in $\alpha * 100\%$ der Fälle verwerfen. Damit wird der Fehler 1. Art auf max. 0.05 (5%) begrenzt.

Wie gemäß CLT zu erwarten, folgen die 1000 z-Werte einer $N(0,1)$ -Verteilung.

Konfidenzintervalle vs. p-value Konfidenzintervalle und der aus dem Hypothesentest resultierende p-value sind wichtige Konzepte der Inferenzstatistik. Der p-value ermöglicht in Studien eine Entscheidung über das Verwerfen oder Beibehalten einer vorab formulierten Nullhypothese. In explorativen Studien lässt er statistisch auffällige (also statistisch signifikante bzw. nicht durch Zufall bedingte) Ergebnisse erkennen. Konfidenzintervalle liefern Informationen über einen Bereich, in dem der wahre Wert mit einer gewissen Wahrscheinlichkeit liegt sowie über Effektrichtung und -stärke. Durch die Angabe des Konfidenzintervalls wird die Bandbreite der Effektgröße also in einer leicht nachvollziehbaren Form kommuniziert, ohne dass man auf die Information zur statistischen Signifikanz verzichten muss. Damit werden Aussagen zur statistischen Signifikanz und zur ökonomischen Signifikanz der Studienergebnisse möglich. Die Angabe beider statistischen Maße in wissenschaftlichen Artikeln ist oft sinnvoll, da sie einander ergänzende Informationen enthalten. Diese Überlegungen gelten sowohl für den Anteilswert als auch für den Mittelwert einer Grundgesamtheit (vgl. unten).

Diese Überlegungen werden durch das folgende Beispiel illustriert:

```
prop.test(77, 1000, p = 0.1, alt = "two.sided")
```

```
##
```

```
## 1-sample proportions test with continuity correction
##
## data: 77 out of 1000, null probability 0.1
## X-squared = 5.62, df = 1, p-value = 0.018
## alternative hypothesis: true p is not equal to 0.1
## 95 percent confidence interval:
## 0.061599 0.095736
## sample estimates:
## p
## 0.077
```

Es wird ein zweiseitiger Hypothesentest zu $\alpha = 0.05$ durchgeführt ($H_0 : p_0 = 0.1$) und ein 95%-KI berechnet. Der Stichprobenanteilswert ist $h = 0.077$ bei $n = 1000$. Ergebnis des Hypothesentests ist, dass es eine statistisch signifikante Veränderung des Anteilswerts im Vergleich zum Referenzwert 0.1 gibt ($p\text{-value} = 0.02 < 0.05$). Das 95%-KI für den wahren Anteilswert ist $[0.062, 0.096]$. Der Referenzwert (0.1) ist nicht eingeschlossen, daher kommt das KI zum gleichen Ergebnis wie der Hypothesentest: Wir können davon ausgehen, dass der wahre Anteilswert nicht 0.1 ist.

Allgemein gilt (wie hier im Beispiel): Ein zweiseitiger Hypothesentest zu einem Signifikanzniveau α kommt i.d.R. zur gleichen Schlussfolgerung wie ein (zweiseitiges) Konfidenzintervall zur Vertrauenswahrscheinlichkeit $1 - \alpha$.

Exkurs: Fehler 2. Art In diesem Exkurs soll gezeigt werden, wie der Fehler 2. Art berechnet werden kann. Der Fehler 1. Art (α) besteht darin, H_0 zu verwerfen, obwohl diese Hypothese wahr ist. Der Fehler 2. Art (β) besteht darin, H_0 zu nicht verwerfen, obwohl diese Hypothese falsch ist. Mit $1 - \beta$ wird die **Power** (Teststärke) eines Hypothesentests bezeichnet. Die Power gibt an, mit welcher Wahrscheinlichkeit man eine falsche H_0 richtigerweise verwirft. Mit anderen Worten: Die Power gibt an, wie gut ein Test einen echten Effekt findet.

Beispiel 1: Wir berechnen die Power für einen Einstichproben-z-Test mit $H_0 : p = 0.5$ vs. $H_A : p > 0.5$ (oberseitig, $\alpha = 0.05$). Der wahre Anteilswert in der Grundgesamtheit sei $p = 0.6$ (hier mit p_1 bezeichnet, mit p_0 wird hingegen der Anteilswert unter H_0 bezeichnet). Wie wir sehen, ist in diesem Fall die Nullhypothese falsch.

```
# Wir installieren und laden zwei Pakete.
library(EnvStats) # Das Paket muss installiert sein.
library(stats)     # Das Paket muss installiert sein.
```

Zunächst müssen wir klären, wo der Ablehnungsbereich für diesen Test liegt.

```
# 95%-Quantil für N(0.5, sqrt(0.5*0.5/200))
pnorm(0.558, 0.5, sqrt(0.5*0.5/200))
```

```
## [1] 0.94955
```


Der Wert $h = 0.558$ ist das 95%-Quantil der Normalverteilung unter H_0 . Also wird H_0 verworfen ($\Leftrightarrow$ Ablehnungsbereich), wenn $h > 0.558$. Man kann den Ablehnungsbereich auch über $N(0,1)$ berechnen. Es gilt $z = (x - \mu)/\sigma$. Hier ist $z = 1.645$ (95%-Quantil von $N(0,1)$), $\mu = 0.5$ und $\sigma = \sqrt{(0.5 * 0.5/200)} = 0.0354$. Dann ist $x = 1.645 * 0.0354 + 0.5 = 0.558$.

Das Problem kann dann graphisch folgendermaßen dargestellt werden.

```
# Koordinaten für polygon() unten
cord.x1 <- c(0.558, seq(0.558, 0.8, 0.001), 0.8)
cord.y1 <- c(0, dnorm(seq(0.558, 0.8, 0.001), 0.6, sqrt(0.6*0.4/200)), 0)

curve(dnorm(x, 0.5, sqrt(0.5*0.5/200)), xlab = "Stichprobenanteil h", lwd = 2,
main= "p0 = 0.5, p1 = 0.6, alpha = 0.05, oberseitig",
ylab = "Dichte",
xlim = c(0.3, 0.8), ylim = c(0, 15))
abline(v = 0.558, lty = 2)
curve(dnorm(x, 0.6, sqrt(0.6*0.4/200)), xlim = c(0.3, 0.8), add = TRUE,
lty = 2, lwd = 2)
text(0.65, 13.2, "Ablehnungsbereich")
legend(0.3, 15, c("N(0.5, sqrt(0.5*0.5/200))", "N(0.6, sqrt(0.6*0.4/200))"),
lty = c(1, 2), lwd = c(2, 2), cex = 0.8)
polygon(cord.x1, cord.y1, col = 'gray67')
curve(dnorm(x, 0.5, sqrt(0.5*0.5/200)), add = TRUE, lwd = 1.5)
curve(dnorm(x, 0.6, sqrt(0.6*0.4/200)), add = TRUE, lty = 2, lwd = 2)
text(0.615, 1.3, "alpha"); text(0.49, 1.3, "beta"); text(0.605, 3.5, "Power")
segments(0.57, 0.5, 0.59, 1); segments(0.53, 0.5, 0.51, 1)
```

p0 = 0.5, p1 = 0.6, alpha = 0.05, oberseitig



In der Abbildung oben sind zwei Normalverteilungen dargestellt. Die linke Normalverteilung ist um 0.5 zentriert und ergibt sich aus der (hier falschen) Nullhypothese mit $p = p_0 = 0.5$. Die rechte Normalverteilung ist um 0.6 zentriert und ergibt sich aus dem wahren Anteilswert $p_1 = 0.6$. Aus dem Abstand der Mittelwerte ergibt sich die Effektgröße, hier $0.6 - 0.5 = 0.1$ (10%). Die Nullhypothese wird verworfen, wenn der Stichprobenanteil h im Ablehnungsbereich (rechts der gestrichelten vertikalen Linie) liegt, hier wenn $h > 0.558$. Wenn $\alpha = 0.05$, ergibt sich β als Fläche unter der rechten Normalverteilung links von $h = 0.558$. β ist

also die Wahrscheinlichkeit, die Nullhypothese von $p = p_0 = 0.5$ nicht zu verwerfen, obwohl diese eigentlich falsch ist (es gilt ja $p_1 = 0.6$). Die **Power**, d.h. die Wahrscheinlichkeit, die falsche H_0 richtigerweise zu verwerfen, ergibt sich dann als grau markierte Fläche unter der Dichte der rechten Normalverteilung im Ablehnungsbereich.

In R kann man die Power leicht berechnen.

```
# Berechnung der Power für Beispiel 1 oben
1 - pnorm(0.558, 0.6, sqrt(0.6*0.4/200)) # Power = grau markierte Fläche
```

```
## [1] 0.88733
```

```
# Alternativ mit propTestPower(), o.g. Pakete müssen geladen sein
power <- propTestPower(n.or.n1 = 200, alt = "greater", p.or.p1 = 0.6, p0 = 0.5)
round(power, 3)
```

```
## [1] 0.886
```

Was folgt daraus?

Für eine empirische Studie sind **vier Faktoren** zu berücksichtigen:

- 1) Der **Fehler 1. Art** α ("false positive"): Meist als Signifikanzniveau bezeichnet, i.d.R. wird $\alpha = 0.05$ (5%) gesetzt.
- 2) Die **Power** ($1 - \beta$, Gegenwahrscheinlichkeit zum Fehler 2. Art): Die Power (auch Teststärke genannt) ist die Wahrscheinlichkeit, dass ein Effekt entdeckt wird, wenn der Effekt auch tatsächlich existiert. Es wird i.d.R. eine Power von 0.8 (80%) angestrebt ($\Leftrightarrow \beta = 0.2$ (20%)).
- 3) Die **Effektgröße**, also die Größe des Unterschieds oder des Zusammenhangs, den man aufdecken möchte.
- 4) Die **Stichprobengröße** (i.d.R. die Zahl der Teilnehmer an der Studie).

Diese vier Größen werden auch mit **APES** bezeichnet. Interessant ist, dass, wenn man drei der Größen aus APES kennt, man die vierte berechnen kann.

In der Praxis wird diese Logik folgendermaßen angewendet:

- 1) Die Effektgröße ist vorgegeben oder man hat eine Erwartung darüber (z.B. aus der Literatur oder aus einer Pilotstudie), α (i.d.R. $0.05 = 5\%$) und Power (i.d.R. $0.80 = 80\%$) sind gegeben und man berechnet dann die nötige Stichprobengröße.
- 2) Man berechnet für eine gegebene Stichprobengröße, α (i.d.R. $0.05 = 5\%$) und Power (i.d.R. $0.80 = 80\%$) die kleinste Effektgröße, die man mit dem Test gerade noch entdecken kann (auch "Minimum Detectable Effect (MDE)").

Einige weitere Berechnungen zu Beispiel 1: $H_0 : p = 0.5$ vs. $H_A : p > 0.5$ (oberseitig, $\alpha = 0.05$): (a) Was ist die Power für eine Stichprobengröße von 30, wenn $p_1 = 0.75$? (b) Welche Stichprobengröße wird benötigt, um eine Power von 80% bei $p_1 = 0.65$ zu erreichen? (c) Welche Stichprobengröße wird benötigt, um eine Power von 80% bei $p_1 = 0.55$ zu erreichen? (d) Welche Effektgröße lässt sich für eine Stichprobengröße von 100 und eine Power von 80% gerade noch entdecken?

```
# a)
power <- propTestPower(n.or.n1 = 30, alpha = 0.05, alt = "greater", p.or.p1 = 0.75, p0 = 0.5)
round(power, 3)
```

```
## [1] 0.897
```

```
# Die Power ist 89.7%.
```

```
# b)
power <- propTestPower(n.or.n1 = 67, alpha = 0.05, alt = "greater", p.or.p1 = 0.65, p0 = 0.5)
round(power, 3)
```

```
## [1] 0.802
```

```
# Es wird eine Stichprobengröße von 67 benötigt.
```

```
# c)
power <- propTestPower(n.or.n1 = 616, alpha = 0.05, alt = "greater", p.or.p1 = 0.55, p0 = 0.5)
round(power, 3)
```

```
## [1] 0.8
```

```
# Es wird eine Stichprobengröße von 616 benötigt.
```

```
# d)
power <- propTestPower(n.or.n1 = 100, alpha = 0.05, alt = "greater", p.or.p1 = 0.623, p0 = 0.5)
round(power, 3)
```

```
## [1] 0.8
```

```
# Eine Effektgröße von  $0.623 - 0.5 = 0.123$  (12.3%) kann gerade noch entdeckt werden.
```

Power-Analysen machen eine Aussage darüber, wie hoch die statistische Power für ein Studiendesign ist. Sie werden i.d.R. vor der eigentlichen Datenerhebung durchgeführt (a priori power analysis), um abzuschätzen, wie viele Versuchspersonen für die Durchführung der Studie nötig sind.

Beispiel 2: Angenommen, 50 % der Patienten mit einer bestimmten Krebsart überleben fünf Jahre. Forscher haben eine neue Behandlung entwickelt, um den Prozentsatz der Personen zu erhöhen, die fünf Jahre überleben. Obwohl die Forscher nicht wissen, wie hoch der tatsächliche Prozentsatz der Patienten ist, die mit der neuen Behandlung überleben werden, möchten sie untersuchen, welche Aussagekraft die Ergebnisse haben, wenn der Prozentsatz unter der neuen Behandlung 60% (oder 55%) beträgt. Die Aussagekraft wird für Studien mit Stichprobengrößen von 50, 100, 200, 300, 500 oder 800 und einem Signifikanzniveau von 0.05 (zweiseitig) bestimmt. Ziel ist es, mit einer Abbildung den Zusammenhang zwischen Stichprobengröße (sample size) und Power für unterschiedliche Effektgrößen (hier 5%- und 10%-Punkte) zu ermitteln.


```
power <- propTestPower(n.or.n1 = c(50, 100, 200, 300, 500, 800), alpha = 0.05,
  alt = "two.sided", p.or.p1 = 0.6, p0 = 0.5)
pwrplis0.60 <- round(power, 3)
```

```

power <- propTestPower(n.or.n1 = c(50, 100, 200, 300, 500, 800), alpha = 0.05,
                      alt = "two.sided", p.or.p1 = 0.55, p0 = 0.5)
pwrplis0.55 <- round(power, 3)

plot(c(50, 100, 200, 300, 500, 800), pwrplis0.60, type = "b", ylim = c(0,1),
     xlab = "sample size n", ylab = "Power",
     main= "p0 = 0.5, alpha = 0.05, two-sided",
     cex = 1.5, col = "blue", lwd = 2)
lines(c(50, 100, 200, 300, 500, 800), pwrplis0.55, type = "b",
      col = "red", lwd = 2, cex = 1.5)
grid()
legend(600, 0.4, c("p1 = 0.60", "p1 = 0.55"), lwd = 2, col = c("blue", "red"))

```



Aus der Abbildung oben wird deutlich, dass für eine Effektgröße von 5%-Punkten (10%-Punkten) eine Stichprobengröße von 800 (200) Teilnehmern nötig ist, um eine Power von 80% zu erreichen. Wir sehen also, dass für eine gegebene Effektgröße eine Erhöhung der Stichprobengröße die Power erhöht. Es wird auch deutlich, dass für eine bestimmte Stichprobengröße die Power größer ist, wenn die Effektgröße größer ist.

Wichtig ist, zu verstehen:

- 1) für eine gegebene Stichprobengröße und α , ist die Power umso größer, je größer die Effektgröße ist.
- 2) für eine gegebene Effektgröße und α , ist die Power umso größer, je größer die Stichprobengröße ist (weil dies die Standardabweichung reduziert).

Abschließend wollen wir die Power mit Hilfe einer Simulation verdeutlichen. Wir beziehen uns wieder auf das Beispiel 1: $H_0 : p = 0.5$ vs. $H_A : p > 0.5$ (oberseitig, $\alpha = 0.05$) und setzen die Stichprobengröße $n =$

200 und $p_1 = 0.6$. Wir erzeugen zunächst eine Grundgesamtheit mit $p = 0.6$. Aus dieser Grundgesamtheit ziehen wir 1000 Mal eine Zufallsstichprobe mit $n = 200$ und berechnen einen Stichprobenanteilswert und einen z-Wert. Daraus lässt sich dann ermitteln, ob man H_0 verwirft (richtige Entscheidung) oder nicht (falsche Entscheidung).

```
# Erzeuge eine Grundgesamtheit mit p = 0.6
set.seed(3); pop <- c(rep(1, 600000), rep(0, 400000))
table(pop)

## pop
##      0      1
## 4000000 6000000

sample_prop <- c()
for(i in 1:1000) {set.seed(i); sample_prop[i] = mean(sample(pop, size = 200, replace = TRUE))}
SD <- sqrt((0.6*0.4)/200)
sample_prop_st <- (sample_prop - 0.5)/SD
# hist(sample_prop_st)

# H0 wird verworfen, wenn sample_prop_st > 1.645 = 95%-Quantil von N(0,1)
prop.table(table(sample_prop_st > qnorm(0.95)))

##
## FALSE  TRUE
## 0.124 0.876
```

Das Ergebnis: Wir verwerfen H_0 in 87.6% aller Fälle und treffen dann die richtige Entscheidung. Die Power ist also hier 87.6%. In 12.4% der Fälle verwerfen wir H_0 nicht und treffen die falsche Entscheidung (“false negative”), d.h. $\beta = 0.124$ (12.4%). Das Ergebnis stimmt also näherungsweise mit den theoretischen Überlegungen oben überein.

Anpassungstest

Bei diesem Test geht es darum, ob ein bestimmtes theoretisches Modell in der Lage ist, die beobachtete Verteilung qualitativer Daten angemessen zu erklären. Konkret: Man vergleicht eine Stichprobenverteilung, die aus einer unbekannten Verteilung F in der Grundgesamtheit gewonnen wurde, mit einer vorgegebenen theoretischen Verteilung F_0 .

Die Nullhypothese

$$H_0 : F = F_0$$

wird verworfen, wenn die Verteilung F relativ stark von F_0 abweicht. Die Alternativhypothese ist daher $H_A : F \neq F_0$. Dieser Test wird Anpassungstest (auch “goodness-of-fit test”) genannt.

Die Testvariable beim Anpassungstest ist

$$\sum_{j=1}^m \frac{(n_j - E_j)^2}{E_j} \sim \chi_{m-1}^2$$

Die Testvariable folgt unter Gültigkeit von H_0 unter bestimmten Bedingungen (vgl. unten) einer χ^2 -Verteilung mit $df = m - 1$ und m als Zahl Klassen. Die Logik hinter dem Summenoperator ist Folgende: Die qualitativen Daten liegen mit absoluter Häufigkeit n_j in m Klassen vor. Zugleich kann man unter Gültigkeit von H_0 die erwarteten absoluten Häufigkeiten E_j gemäß der theoretischen Verteilung bestimmen. Für jede Klasse wird die Differenz zwischen beobachteter und erwarteter Häufigkeit bestimmt, diese quadriert und in Relation zur erwarteten Häufigkeit gesetzt. Die so gewonnenen m Werte werden aufaddiert.

Wird die Abweichung zwischen beobachteten und erwarteten Häufigkeiten sehr groß, ist H_0 zu verwerfen. Ein großer Wert der Prüfgröße spricht also gegen H_0 . Die Entscheidungsregel bei diesem Test ist daher:

$$\sum_{j=1}^m \frac{(n_j - E_j)^2}{E_j} > \chi^2_{m-1[1-\alpha]} \Rightarrow H_0 \text{ verwerfen}$$

Die Berechnung des p-value erfolgt mit:

$$p\text{-value} = 1 - F_{\chi^2}\left(\sum_{j=1}^m \frac{(n_j - E_j)^2}{E_j}, m - 1\right)$$

Hierbei ist $F_{\chi^2}(\dots, m - 1)$ die Verteilungsfunktion der χ^2 -Verteilung mit $m - 1$ Freiheitsgraden. Der Anpassungstest ist immer ein **oberseitiger Test**.

Folgende **Annahmen und Bedingungen** müssen für den Anpassungstest gültig sein:

1. Es müssen qualitative Daten vorliegen.
2. Die beobachteten Werte müssen unabhängig voneinander sein. Diese Annahme kann als erfüllt angesehen werden, wenn die Beobachtungen eine Zufallsstichprobe aus der Grundgesamtheit darstellen und der Auswahlatz klein ist ($n/N \leq 0.05$).
3. Die Stichprobe muss hinreichend groß sein. Konkret ist $E_j \geq 5$ zu fordern (mind. fünf erwartete Beobachtungen in jeder Klasse).


Betrachten wir das folgende Beispiel (vgl. auch unfall.csv): Es liegen Zahlen zu 130 Arbeitsunfällen pro Arbeitstag (Mo bis Fr) vor. Die Beobachtungen wurden zufällig aus einer großen Grundgesamtheit gewonnen. Die Frage ist, ob die Arbeitsunfälle sich gleichmäßig auf die Arbeitstage verteilen oder nicht. Bei einer Gleichverteilung würden sich $130/5 = 26$ Unfälle pro Arbeitstag ergeben.

Wir stellen zunächst die beobachtete Häufigkeitsverteilung mit einem Barplot graphisch dar.

```
unfall <- c(39, 23, 12, 21, 35); sum(unfall)
```

```
## [1] 130
```

```
barplot(unfall, ylab = "absolute Häufigkeit", xlab = "Wochentage", ylim = c(0, 40),  
names.arg = c("Mo", "Di", "Mi", "Do", "Fr"))  
abline(h = 26, lty = 2)
```



Der Barplot zeigt eine deutliche Abweichung von der Gleichverteilung (gestrichelte Linie), die aber gleichwohl zufällig bedingt sein kann. Mit dem Anpassungstest können wir diese Unsicherheit quantifizieren. Die Nullhypothese ist, dass in der Grundgesamtheit eine Gleichverteilung vorliegt. Die Alternativhypothese ist, dass in der Grundgesamtheit keine Gleichverteilung vorliegt.

Wir berechnen den p-value folgendermaßen:

```
unfall <- c(39, 23, 12, 21, 35); sum(unfall)
```

```
## [1] 130
```

```
Exp <- c(26, 26, 26, 26, 26)
```

```
Chi <- sum((unfall - Exp)^2/Exp); Chi # Berechnung der Prüfgröße
```

```
## [1] 18.462
```

```
p.value <- 1 - pchisq(Chi, df = 4); p.value
```

```
## [1] 0.0010024
```

Mit R können wir den Test einfach so durchführen:

```
chisq.test(unfall, p = c(26/130, 26/130, 26/130, 26/130, 26/130))
```

```
##
## Chi-squared test for given probabilities
##
## data: unfall
## X-squared = 18.5, df = 4, p-value = 0.001
```

Hierzu müssen wir mit `p = c()` die Wahrscheinlichkeit für die Verteilung unter der Nullhypothese angeben (hier $26/130 = 0.2$). Die Interpretation des p-value ist folgende: Wenn in der Grundgesamtheit die Arbeitsunfälle tatsächlich gleichverteilt sind, ist die Wahrscheinlichkeit, bei einer Zufallsstichprobe von 130 Unfällen eine Verteilung wie in der Stichprobe oder extremer zu beobachten, gleich 0.1%. Auf Grund dieser geringen Wahrscheinlichkeit können wir davon ausgehen, dass die Arbeitsunfälle nicht gleichverteilt sind. Oder m.a.W.: Die Verteilung der Unfälle unterscheidet sich statistisch signifikant von der Gleichverteilung.

Auf die Darstellung von Maßzahlen für die Effektgröße verzichten wir hier.

Exkurs: Anpassungstest bei zwei Klassen Der Anpassungstest ist bei zwei Klassen (z.B. Ausschuss: ja oder nein) äquivalent zum Anteilswert-z-Test (vgl. oben). Um den exakten p-value zu erhalten, müssen wir dabei nur die Stetigkeitskorrektur in R deaktivieren (`correct = FALSE`). H_0 bestimmt die erwartete Verteilung, und die beobachtete Verteilung ergibt sich aus der Stichprobe.

Betrachten wir Beispiel 3 mit der Ausschussquote oben:

```
prop.test(x = 92, n = 517, p = 0.2, correct = FALSE)
```

```
##
## 1-sample proportions test without continuity correction
##
## data: 92 out of 517, null probability 0.2
## X-squared = 1.57, df = 1, p-value = 0.21
## alternative hypothesis: true p is not equal to 0.2
## 95 percent confidence interval:
##  0.14739 0.21326
## sample estimates:
##           p
## 0.17795
```

Hier muss mit `prop.test()` zweiseitig getestet werden, weil es um die Abweichung vom Anteilswert in H_0 geht (Abweichung nach oben und unten ist möglich). Die Zahl Freiheitsgrade ist $df = 1$. Der χ^2 -Wert und der p-value ergeben sich mit:

```
chi <- (92 - 0.2*517)^2/(0.2*517) + (425 - 0.8*517)^2/(0.8*517); chi
```

```
## [1] 1.5711
```

```
p.value <- 1 - pchisq(chi, df = 1); p.value
```

```
## [1] 0.21005
```

Wert der Prüfgröße und p-value sind für beide Rechenmethoden identisch.

Unabhängigkeitstest

Bei einem Unabhängigkeitstest möchte man die Hypothese testen, dass zwei qualitative Merkmale, X und Y , voneinander unabhängig sind. Man testet also:

H_0 : X und Y sind unabhängig vs. H_A : X und Y sind nicht unabhängig

Der Test erfolgt unter Berücksichtigung der Verteilung in einer Stichprobe. Wird in der Stichprobe eine hinreichend starke Abhängigkeit zwischen beiden Merkmalen gefunden, wird H_0 verworfen. Der Unabhängigkeitstest verwendet die **quadratische Kontingenz QK** als Testvariable. QK ist unter Gültigkeit von H_0 näherungsweise χ^2 -verteilt mit $(k-1)(l-1)$ Freiheitsgraden, wobei k für die Zeilenzahl und l für die Spaltenzahl der Kontingenztabelle steht.

Die Entscheidungsregel lautet daher:

$$QK = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{ij} - E_{ij})^2}{E_{ij}} > \chi^2_{(k-1)(l-1)[1-\alpha]} \Rightarrow H_0 \text{ verwerfen}$$

Hierbei sind n_{ij} die beobachteten Werte in der Kontingenztabelle für Zeile i und Spalte j , E_{ij} sind die erwarteten Werte bei statistischer Unabhängigkeit. Wie beim Anpassungstest spricht ein hoher Wert der Prüfgröße gegen H_0 .

Die Berechnung des p-value erfolgt mit:

$$p\text{-value} = 1 - F_{\chi^2}(QK, (k-1)(l-1))$$

mit $F_{\chi^2}(\dots, (k-1)(l-1))$ als Verteilungsfunktion der χ^2 -Verteilung mit $(k-1)(l-1)$ Freiheitsgraden.

Der Unabhängigkeitstest ist immer ein **oberseitiger Test**.

Für den Unabhängigkeitstest müssen folgende Annahmen und Bedingungen gültig sein (analog zum Anpassungstest, vgl. oben):

1. Die Merkmale müssen in Klassen erhoben bzw. qualitativ sein.
2. Die Beobachtungen müssen unabhängig voneinander sein bzw. aus einer Zufallsstichprobe stammen. Der Auswahlstich muss klein sein ($n/N \leq 0.05$).
3. Die erwartete absolute Häufigkeit in jeder Zelle der Kontingenztabelle muss mindestens fünf sein, d.h. $E_{ij} \geq 5$.

Betrachten wir ein Beispiel (Lehrbuch S. 261): Vor den US-Präsidentswahlen werden 1000 zufällig ausgewählte Wahlberechtigte nach Geschlecht und Wahlpräferenz befragt. Die Daten liegen in **Bsp._11.7.csv** vor. Es stellt sich die Frage, ob das Geschlecht einen Effekt auf die Wahlpräferenz hat. Das Signifikanzniveau sei 0.05.

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("Bsp._11.7.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/Bsp._11.7.csv")
data[1:2,]; attach(data)
```

```
##   X vote gender
## 1 1  rep   male
## 2 2  rep   male
```

Mit R lässt sich der Test auf Unabhängigkeit einfach so durchführen:

```
addmargins(table(gender, vote))
```

```
##          vote
## gender  dem  ind  rep  Sum
##   fem   300   50  250  600
##   male  150   50  200  400
##   Sum   450  100  450 1000
```

```
chisq.test(table(gender, vote))
```

```
##
## Pearson's Chi-squared test
##
## data:  table(gender, vote)
## X-squared = 16.2, df = 2, p-value = 0.0003
```

Wir wollen hier QK “per Hand” berechnen und den p-value reproduzieren.

```
Chi2 <- chisq.test(table(gender, vote))
Chi2$expected      # erwartete Werte bei Unabhängigkeit  $E_{ij}$ 
```

```
##          vote
## gender dem ind rep
##   fem  270  60 270
##   male 180  40 180
```

```
Chi2$observed      # beobachtete Werte  $n_{ij}$ 
```

```
##          vote
## gender dem ind rep
##   fem  300  50 250
##   male 150  50 200
```

```
QK <- sum((Chi2$observed - Chi2$expected)^2/Chi2$expected)
QK      # Quadratische Kontingenz
```

```
## [1] 16.204
```

```
p.value <- 1 - pchisq(QK, df = 2); p.value
```

```
## [1] 0.00030298
```

Interpretation: Wir lehnen H_0 ab und können damit schlussfolgern, dass die Merkmale Geschlecht und Wahlpräferenz statistisch signifikant voneinander abhängig sind. Wenn in der Grundgesamtheit die Merkmale Geschlecht und Wahlpräferenz tatsächlich voneinander unabhängig sind, ist die Wahrscheinlichkeit, bei einer Zufallsstichprobe von $n = 1000$ eine Verteilung wie in der Stichprobe oder extremer zu erhalten, gleich 0.03%. Auf Grund dieser geringen Wahrscheinlichkeit verwerfen wir die Hypothese der Unabhängigkeit und können davon ausgehen, dass die beiden Merkmale voneinander abhängig sind. Hier: Das Geschlecht beeinflusst das Wahlverhalten.

Ein kleiner p-value ($< \alpha$) beim Unabhängigkeitstest signalisiert, dass die Abhängigkeit nicht zufällig zustande gekommen ist, sondern tatsächlich auch in der Grundgesamtheit vorliegt (“statistische Signifikanz”). Als deskriptives Maß zur Messung der Stärke der Abhängigkeit zwischen zwei nominal skalierten Merkmalen in einer Stichprobe (“ökonomische Signifikanz”) wird u.a. der korrigierte Kontingenzkoeffizient KK^* genutzt.

```
n <- 1000; m <- 2
KK_stern <- sqrt( QK*m /((QK + n)*(m - 1))); KK_stern
```

```
## [1] 0.17858
```

Im Beispiel liegt ein statistisch hochsignifikanter Effekt vor, d.h. der p-value ist sehr klein. KK^* als Maß für die Stärke der Abhängigkeit (Effektgröße) ist aber relativ klein mit $KK^* = 0.18$. Wir haben also hier einen ökonomisch eher unbedeutenden Effekt (kleine effect size, KK^*), und erhalten wegen der relativ großen Stichprobe aber dennoch ein statistisch signifikantes Resultat.

Inferenz für quantitative Daten (alle Module)

In diesem Abschnitt werden wir uns mit Methoden der Inferenzstatistik (auch “induktive Statistik”) für quantitative Daten beschäftigen. Dabei geht es darum, was wir aus den Stichprobenbeobachtungen über einen unbekannten Parameter in der Grundgesamtheit (hier der Mittelwert μ) schließen können.

Vorab Immer dann, wenn man die Standardabweichung der Grundgesamtheit (σ) nicht kennt (und das ist die Regel), muss man diese aus den Stichprobeninformationen schätzen ($\hat{\sigma}$). Wir berechnen dann mit Hilfe von $\hat{\sigma}$ die geschätzte Standardabweichung des Stichprobenmittels, auch als **Standardfehler** bezeichnet ($SE = \hat{\sigma}_{\bar{X}} = \frac{\hat{\sigma}}{\sqrt{n}}$). In diesem Fall ist bei einer großen Stichprobe ($n > 30$) der standardisierte Stichprobenmittelwert, $(\bar{x} - \mu)/SE$, nicht mehr näherungsweise $N(0,1)$ -verteilt, sondern folgt - unabhängig von der Verteilung des Merkmals in der Grundgesamtheit - näherungsweise einer t-Verteilung mit $df = n-1$ ($df = \text{degrees of freedom}$). Bei einer kleinen Stichprobe ($n \leq 30$) folgt der standardisierte Stichprobenmittelwert näherungsweise einer t-Verteilung, wenn das Merkmal in der Grundgesamtheit einer $N(\mu, \sigma)$ -Verteilung folgt. Diese Erkenntnis geht auf William Sealy **Gosset** (1876-1937) zurück. Gosset war Head Brewer der Guinness Brewery in Dublin und beschäftigte sich mit der betriebswirtschaftlich hochrelevanten Frage, was man aus kleinen Stichproben über den wahren Mittelwert der Grundgesamtheit lernen kann. Er publizierte seine Erkenntnisse unter dem Pseudonym “Student” (Student: The Probable Error of a Mean, Biometrika, 6(1), 1-24, 1908), daher wurde die zugrundeliegende Verteilung später auch als Student-t-Verteilung (oder nur t-Verteilung) benannt.

Konfidenzintervall (KI) für μ

Einführung Es gibt zwei unterschiedliche Verteilungen für den standardisierten Stichprobenmittelwert: Die $N(0,1)$ -Verteilung (wenn σ bekannt) und die t-Verteilung (wenn σ unbekannt). Kennt man die Verteilung, kann man aus dem Stichprobenmittel, der zugehörigen Standardabweichung und dem $(1 - \alpha/2)$ -Quantil der entsprechenden Verteilung das $(1 - \alpha)$ -Konfidenzintervall für μ berechnen.

Die folgende Tabelle zeigt die möglichen Fallunterscheidungen für die Berechnung des $(1 - \alpha)$ -KI für μ .

Table 4: KI für den Mittelwert der Grundgesamtheit (GG)

	σ bekannt	σ unbekannt
$n > 30$	$\bar{x} \pm z_{[1-\alpha/2]} \sigma_{\bar{X}}$	$\bar{x} \pm t_{n-1[1-\alpha/2]} \hat{\sigma}_{\bar{X}}$
$n \leq 30$	$\bar{x} \pm z_{[1-\alpha/2]} \sigma_{\bar{X}}$ wenn GG normalverteilt	$\bar{x} \pm t_{n-1[1-\alpha/2]} \hat{\sigma}_{\bar{X}}$ wenn GG normalverteilt

mit:

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} \text{ und } SE = \hat{\sigma}_{\bar{X}} = \frac{\hat{\sigma}}{\sqrt{n}}$$

für $n > 30$ gilt zudem: $t_{n-1[1-\alpha/2]} \approx z_{[1-\alpha/2]}$.

Generell muss zur Berechnung und Interpretation des KI die Annahme der Unabhängigkeit der Stichprobenbeobachtungen erfüllt sein. Hierfür sollte geprüft werden, ob eine Zufallsstichprobe vorliegt und die Stichprobe in Relation zur Grundgesamtheit klein ist ($n/N \leq 0.05$).

Wir betrachten im Folgenden nur die praxisrelevanten Fälle mit unbekanntem σ .

Fall: $n > 30$ und σ unbekannt In diesem Fall ("große Stichprobe") ist das KI definiert als:

$$KI(1 - \alpha)_\mu = \bar{x} \pm t_{n-1[1-\alpha/2]} \hat{\sigma}_{\bar{X}}$$

Betrachten wir zunächst das mittlere monatliche Einkommen von HTWK-Studierenden im Jahr 2009.


```
setwd("C:/Users/sturm/Desktop/dataR")      # setze das Arbeitsverzeichnis
stud.data_oA <- read.csv("student_ohne_Ausr.csv") # bereinigter Datensatz, nur 2009
# stud.data_oA <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/student_ohne_Ausr.csv")
attach(stud.data_oA); stud.data_oA[1:3, ]
```

```
##   fem age height weight shoe sport veg_fruits income
## 1   0  20   175    58   41    3         0    300
## 2   1  20   168    63   39    1         5    700
## 3   1  22   160    62   39    5         3    750
```

```
summary(stud.data_oA$income); hist(stud.data_oA$income, xlab = "Income in Euro")
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##         0     400     600     606    735    3500
```

Histogram of stud.data_oA\$income



Die Verteilung der Stichprobe ist stark linkssteil (skewed to the right), so dass die Normalverteilungsannahme für die Grundgesamtheit klar verletzt ist. Auf Grund der großen Stichprobe können wir aber davon ausgehen, dass der Stichprobenmittelwert unabhängig von der Verteilung des Merkmals in der Grundgesamtheit näherungsweise t-verteilt mit $df = n-1$ ist.

Wir wollen ein 95%-KI für das mittlere Einkommen in der Grundgesamtheit berechnen.

1. Methode: “per Hand” mit Hilfe der Formel oben.

```
n <- length(stud.data_oA$income); n

## [1] 159

SE <- sd(stud.data_oA$income)/sqrt(n); SE

## [1] 30.151

t <- qt(0.975, df = n - 1); t

## [1] 1.9751

CI_low <- mean(stud.data_oA$income) - t*SE
CI_up <- mean(stud.data_oA$income) + t*SE
CI_low; CI_up

## [1] 546.94

## [1] 666.04
```

2. Methode: mit `t.test()`. Wir nutzen hier nur einen Teil des Outputs (vgl. für den Rest unten)

```
t.test(stud.data_oA$income, xlab = "Einkommen in Euro")

##
## One Sample t-test
##
## data: stud.data_oA$income
## t = 20.1, df = 158, p-value <2e-16
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
## 546.94 666.04
## sample estimates:
## mean of x
## 606.49
```

Interpretation: Wenn man 100 Stichproben nach dieser Methode ziehen würde, würde man 100 unterschiedliche KIs erhalten. Von diesen 100 KIs werden im Mittel 95 den wahren Mittelwert beinhalten und 5 nicht. Unser KI, [547 Euro, 666 Euro], ist eines dieser 100 KIs. Das **Vertrauen** (“confidence”) bezieht sich also nicht auf das einzelne KI, sondern auf die **Methode**, solche Intervalle zu konstruieren. Kürzer:

Wir können zu 95% darauf vertrauen, dass ein nach dieser Methode erzeugtes Intervall, das wahre mittlere Einkommen in der Grundgesamtheit beinhaltet. Unser KI, [547 Euro, 666 Euro], ist ein solches Intervall.

Bei einer großen Stichprobe ($n > 30$, das ist hier der Fall) können wir das Quantil der t-Verteilung durch das Quantil der $N(0, 1)$ -Verteilung approximieren. Hier im Beispiel ist - wie zu erwarten - die Abweichung sehr gering:

```
t <- qt(0.975, df = n - 1); t # sollte nah an 1.96 sein
```

```
## [1] 1.9751
```

```
z <- qnorm(0.975); z
```

```
## [1] 1.96
```

```
CI_low_z <- mean(stud.data_oA$income) - z*SE
CI_up_z <- mean(stud.data_oA$income) + z*SE
CI_low_z; CI_up_z
```

```
## [1] 547.39
```

```
## [1] 665.58
```

Fall: $n \leq 30$ und σ unbekannt In diesem Fall (“kleine Stichprobe”) ist das KI wie oben definiert als:


$$KI(1 - \alpha)_\mu = \bar{x} \pm t_{n-1[1-\alpha/2]} \hat{\sigma}_{\bar{X}}$$

wenn (!) das Merkmal in der Grundgesamtheit normalverteilt ist. Diese Eigenschaft ist durch ein Histogramm bzw. qq-Plot der Stichprobenwerte zu prüfen (ggf. auch durch einen Shapiro-Wilk-Test auf Normalverteilung).


Betrachten wir das folgende Beispiel: Sie trinken in einer Kneipe mit Ihren Freunden ein paar Bier und möchten gerne wissen, wie viel Bier “im Mittel” pro Glas ausgeschenkt wird. Die Füllmengen der Gläser (in Liter) sind: 0.51, 0.48, 0.52, 0.47, 0.48, 0.40, 0.44, 0.43, 0.48, 0.49, 0.47, 0.45, 0.45, 0.46, 0.5.

```
bier <- c(0.51, 0.48, 0.52, 0.47, 0.48, 0.40, 0.44, 0.43, 0.48, 0.49, 0.47, 0.45, 0.45, 0.46, 0.5)
hist(bier, xlab = "Bier in Liter")
```

Histogram of bier



```
qqnorm(bier, cex = 1.1); qqline(bier)
```



```
shapiro.test(bier)
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  bier  
## W = 0.979, p-value = 0.97
```

Die Normalverteilungsannahme kann als erfüllt angesehen werden (sie kann zumindest nicht verworfen werden).

Das KI berechnet sich folgendermaßen:

1. Methode: “per Hand” mit Hilfe der Formel oben.

```
n <- length(bier); n
```

```
## [1] 15
```

```
SE <- sd(bier)/sqrt(n); SE
```

```
## [1] 0.0081572
```

```
t <- qt(0.975, df = n - 1); t
```

```
## [1] 2.1448
```

```
CI_low <- mean(bier) - t*SE  
CI_up <- mean(bier) + t*SE  
CI_low; CI_up
```

```
## [1] 0.45117
```

```
## [1] 0.48616
```

2. Methode: mit `t.test()`. Wir nutzen hier nur einen Teil des Outputs (vgl. für den Rest unten)

```
t.test(bier)
```

```
##  
## One Sample t-test  
##  
## data: bier  
## t = 57.5, df = 14, p-value <2e-16  
## alternative hypothesis: true mean is not equal to 0  
## 95 percent confidence interval:  
## 0.45117 0.48616  
## sample estimates:  
## mean of x  
## 0.46867
```

Interpretation: Wenn man 100 Stichproben nach dieser Methode ziehen würde, würde man 100 unterschiedliche KIs erhalten. Von diesen 100 KIs werden im Mittel 95 den wahren Mittelwert beinhalten und 5 nicht. Unser KI, [0.45 l, 0.49 l], ist eines dieser 100 KIs. Das **Vertrauen** (“confidence”) bezieht sich also nicht auf das einzelne KI, sondern auf die **Methode**, solche Intervalle zu konstruieren. Kürzer: Wir können zu 95% darauf vertrauen, dass ein nach dieser Methode erzeugtes Intervall, die wahre mittlere Biermenge in der Grundgesamtheit beinhaltet. Unser KI, [0.45 l, 0.49 l], ist ein solches Intervall. Man beachte, dass die Normmenge, 0.5 Liter, nicht im KI liegt. Dies ist ein Argument gegen die Behauptung, dass der Wirt 0.5 Liter pro Glas ausschenkt (vgl. unten zum Hypothesentest für dieses Beispiel).

Trade-off zwischen Präzision und Sicherheit Aus der Formel zur Berechnung des KI ergibt sich, dass es zwei Optionen gibt, zu einer präziseren Aussage (also zu einem schmalen KI) zu gelangen:

- (1) Reduzierung der Vertrauenswahrscheinlichkeit: Ein kleineres $1 - \alpha$ führt zu einem schmalen KI, da sich das $(1 - \alpha/2)$ -Quantil der t-Verteilung dann verkleinert. Wir müssen also einen “Preis” (geringeres Vertrauen) für höhere Präzision zahlen.

Zum Beispiel für $df = 10$ und $df = 100$:

```
qt(0.95, df = 10); qt(0.95, df = 100) # 1 - alpha = 0.90
```

```
## [1] 1.8125
```

```
## [1] 1.6602
```

```
qt(0.975, df = 10); qt(0.975, df = 100) # 1 - alpha = 0.95
```

```
## [1] 2.2281
```

```
## [1] 1.984
```

Werte unter 90% für die Vertrauenswahrscheinlichkeit sind unüblich.

- (2) Größere Stichprobe: Ein höheres n reduziert den Standardfehler $SE = \hat{\sigma}_{\bar{X}} = \frac{\hat{\sigma}}{\sqrt{n}}$ und damit auch den Margin of Error. Zugleich wird auch der t-Wert kleiner, da mit einem höheren df -Wert der t-Wert von oben näher an den kleineren z-Wert heranrückt.

Es gibt also einen **trade-off** (“Abwägen” oder auch “Zielkonflikt”) zwischen **Präzision** der Aussage (Breite des KI) und der **Sicherheit** der Aussage (Vertrauen in KI). Eine höhere Sicherheit bzgl. der Aussage über μ geht einher mit geringerer Präzision und umgekehrt. Das ist das fundamentale Problem der schließenden Statistik. Glücklicherweise können wir oft mit Aussagen ausreichend präzise (gemessen durch den ME, abhängig vom Sachverhalt) und sicher (z.B. mit $1 - \alpha = 0.95$) sein.

Hypothesentest für μ

Die t-Verteilung kann nicht nur für die Berechnung eines Konfidenzintervalls für μ , sondern auch zum Testen einer Hypothese bzgl. des wahren Mittelwerts μ verwendet werden.

Schrittfolge Wir wollen eine Hypothese über einen unbekannten Parameter (Mittelwert μ) in der Grundgesamtheit testen. Dazu nehmen wir die Hypothese als wahr an und vergleichen die Stichprobeninformation mit dem, was man unter Gültigkeit der Hypothese erwarten kann. Gibt es einen großen Unterschied zwischen der Erwartung basierend auf der Hypothese und Stichprobeninformation, verwerfen wir die Hypothese.

Wir werden im Folgenden mit folgender Schrittfolge für den Hypothesentest arbeiten:

1) *Hypothesen aufstellen und Signifikanzniveau (maximale Wahrscheinlichkeit für Fehler 1. Art, α) festlegen.* Die Ausgangshypothese wird als Nullhypothese H_0 bezeichnet. H_0 wird als wahr angenommen. Das eigentlich interessante Ergebnis wird i.d.R. in der Alternativhypothese H_A “versteckt”. Ziel ist letztlich die Ablehnung der Nullhypothese und die Akzeptanz der Alternative. Die Ablehnung von H_0 ist aber nur möglich, wenn wir begründete Zweifel an der Nullhypothese haben. Der Hypothesentest liefert Regeln, um diese “begründeten Zweifel” zu belegen.

Es werden zweiseitige und einseitige Tests unterschieden (je nach Richtung der H_A):

- zweiseitig: $H_0: \mu = \mu_0$ vs. $H_A: \mu \neq \mu_0$
- oberseitig: $H_0: \mu = \mu_0$ vs. $H_A: \mu > \mu_0$
- unterseitig: $H_0: \mu = \mu_0$ vs. $H_A: \mu < \mu_0$

Die Überlegungen zum Fehler 1. Art und 2. Art sind exakt die gleichen wie beim Einstichproben-z-Test.

2) *Festlegung der Testverteilung und der Testvariable (T).* Wenn die Standardabweichung der Grundgesamtheit unbekannt ist (und dies ist in der Praxis die Regel), sind zwei Fälle zu unterscheiden:

- große Stichprobe $n > 30$

In diesem Fall gilt: $\frac{\bar{X} - \mu_0}{\hat{\sigma}_{\bar{X}}} = T \sim T_{n-1}$ und die Approximation $T \approx Z$ ist möglich.

- kleine Stichprobe $n \leq 30$

In diesem Fall gilt: $\frac{\bar{X} - \mu_0}{\hat{\sigma}_{\bar{X}}} = T \sim T_{n-1}$, wenn das Merkmal in der Grundgesamtheit normalverteilt ist.

3) *Berechnung der Prüfgröße t und des p-value.* Der empirische Wert der Testvariable T , die Prüfgröße t , berechnet sich folgendermaßen:

$$t = \frac{\bar{x} - \mu_0}{\hat{\sigma}_{\bar{x}}}$$

Der **p-value** berechnet sich:

- zweiseitig: $\text{p-value} = 2(1 - F_t(|t|, n - 1))$
- unterseitig: $\text{p-value} = F_t(t, n - 1) = 1 - F_t(|t|, n - 1)$
- oberseitig: $\text{p-value} = 1 - F_t(t, n - 1)$

mit $F_t(t, n - 1)$ als Verteilungsfunktion der t-Verteilung mit $\text{df} = n - 1$.

4) *Entscheidung und Interpretation.* Die Entscheidung basierend auf dem p-value erfolgt nach der Regel: Ablehnung von H_0 , wenn $\text{p-value} < \alpha$ (alternativ über den Vergleich von t-Wert und dem kritischen Wert der t-Verteilung, vgl. Lehrbuch). Die Interpretation der Entscheidung über H_0 hat (wie die Interpretation des p-value) im Kontext zu erfolgen.

Der hier erläuterte Test wird auch **Einstichproben-t-Test** (one sample t-test) genannt.

Beispiel Sie trinken in einer Kneipe mit Ihren Freunden ein paar Bier und vermuten, dass der Wirt zu wenig ausschenkt. Die Füllmengen der Gläser (in Liter) sind: 0.51, 0.48, 0.52, 0.47, 0.48, 0.40, 0.44, 0.43, 0.48, 0.49, 0.47, 0.45, 0.45, 0.46, 0.5. Man soll hier seine Vermutung durch einen Hypothesentest untermauern (vgl. oben, auch zur Prüfung der Annahmen). Das Signifikanzniveau sei 0.05.

```
bier <- c(0.51, 0.48, 0.52, 0.47, 0.48, 0.40, 0.44, 0.43, 0.48, 0.49, 0.47, 0.45, 0.45, 0.46, 0.5)
summary(bier)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   0.400   0.450   0.470   0.469   0.485   0.520
```

Die Hypothesen sind $H_0 : \mu = 0.5$ vs. $H_A : \mu < 0.5$. Wir testen also unterseitig, da uns nur die Abweichung nach unten interessiert. Es liegt eine kleine Stichprobe vor und die Stichprobenwerte folgen näherungsweise einer Normalverteilung. Wir können also T als Testvariable verwenden und aus der Prüfgröße einen p-value berechnen. Darüber hinaus können wir von einer in Relation zur Grundgesamtheit kleinen Zufallsstichprobe ausgehen.

Methode 1:

```
n <- length(bier)
sigma_x_dach <- sd(bier)/sqrt(n)
t <- abs((mean(bier) - 0.5)/sigma_x_dach); t
```

```
## [1] 3.8412
```

```
p.value <- 1 - pt(t, df = n - 1); p.value
```

```
## [1] 0.00089925
```

Methode 2:

```
t.test(bier, mu = 0.5, alternative = "less")

##
## One Sample t-test
##
## data: bier
## t = -3.84, df = 14, p-value = 0.0009
## alternative hypothesis: true mean is less than 0.5
## 95 percent confidence interval:
##      -Inf 0.48303
## sample estimates:
## mean of x
##      0.46867
```

Das Ergebnis des unterseitigen Tests ist ein p-value von 0.09%. Wenn also tatsächlich der wahre Mittelwert aller ausgeschenkten Biere gleich 0.5 Liter ist, dann ist die Wahrscheinlichkeit, bei einer Zufallsstichprobe von 15 Bieren einen Mittelwert von 0.469 Liter oder weniger zu finden, gleich 0.09%. Es ist also extrem unwahrscheinlich, ein solches Ergebnis oder noch kleinere Werte zufällig zu beobachten, wenn der Wirt im Mittel tatsächlich 0.5 Liter ausschenkt. Auf Grund dieser geringen Wahrscheinlichkeit verwerfen wir H_0 und nehmen H_A an. Es wird also statistisch signifikant zu wenig Bier ausgeschenkt.

Als Maß für die Effektgröße (ökonomische Signifikanz) wird Cohen's d berechnet (vgl. Exkurs unten).

Statistische vs. ökonomische Signifikanz Der empirische Wert der Testvariablen $t = (\bar{x} - \mu_0)/\hat{\sigma}_{\bar{x}}$ ($\Leftrightarrow$ p-value) ist der Indikator für statistische Signifikanz und damit für die Frage, ob ein bestimmtes Stichprobenergebnis oder extremere Werte sich zufällig ergeben haben können. Ist t betragsmäßig groß (und damit der p-value klein, d.h. $< \alpha$) spricht man von einem "statistisch signifikanten" Resultat. In diesem Fall können wir also davon ausgehen, dass das beobachtete Stichprobenergebnis nicht zufällig zustande gekommen ist. H_0 wird verworfen und H_A angenommen.

Die Effektgröße $|\bar{x} - \mu_0|$ ist hingegen der Indikator für ökonomische Signifikanz, also für die Abweichung zwischen dem beobachteten Stichprobenwert und dem als wahr angenommenen Wert in der Nullhypothese (als Maßzahl wird hier i.d.R. Cohen's d genutzt, vgl. Exkurs). Unter sonst gleichen Bedingungen steigt die statistische Signifikanz mit der Effektgröße. Das Problem ist aber: Es gibt ökonomisch signifikante Effekte, die nicht statistisch signifikant sind und umgekehrt. Entscheidend ist hierbei die **Stichprobengröße**. Wenn n klein ist, ist $\hat{\sigma}_{\bar{x}} = \frac{\hat{\sigma}}{\sqrt{n}}$ groß, t ist dann klein und es liegt auch bei einer relativ großen Effektgröße keine statistische Signifikanz vor. Ist hingegen n groß, kann auch eine relativ kleine Effektgröße statistisch signifikant werden. Mit anderen Worten: jede noch so kleine Effektgröße kann durch ein hinreichend großes n "statistisch signifikant" werden. Ziel ist daher, mit relativ geringem n statistisch signifikante Effekte zu zeigen. Man sollte daher bei der Präsentation von Testergebnissen immer Effektgröße, Prüfgröße, n und den p-value angeben. Dann wird deutlich, ob man statistische Signifikanz durch eine übergroße Stichprobengröße erzeugt hat.

Exkurs: Fehler 2. Art In diesem Exkurs soll gezeigt werden, wie der Fehler 2. Art für den Einstichproben-t-Test berechnet werden kann. Der Fehler 1. Art (α) besteht darin, H_0 zu verwerfen, obwohl diese Hypothese wahr ist. Der Fehler 2. Art (β) besteht darin, H_0 zu nicht verwerfen, obwohl diese Hypothese falsch ist. Mit $1 - \beta$ wird die **Power** (Teststärke) eines Hypothesentests bezeichnet. Die Power gibt an, mit welcher Wahrscheinlichkeit man eine falsche H_0 richtigerweise verwirft. Mit anderen Worten: Die Power gibt an, wie gut ein Test einen echten Effekt findet.

Beispiel: Angenommen, wir möchten die Nullhypothese testen, dass eine Variable X einen Mittelwert von 100 hat, gegenüber der Alternativhypothese, dass der Mittelwert größer als 100 ist. Zudem sei angenommen,

frühere Studien haben gezeigt, dass die Standardabweichung $\sigma = 40$ ist. Es wird eine Zufallsstichprobe $n = 100$ genutzt.

Zunächst berechnen wir über das 95%-Quantil der t-Verteilung mit $df = 99$ den kritischen Wert $t_{crit} = 106.6$. Wenn der aus der Stichprobe berechnete Mittelwert größer als 106.6 ist, wird die Nullhypothese, dass der Mittelwert 100 beträgt, verworfen. Andernfalls wird die Nullhypothese nicht verworfen. Wir bezeichnen den Bereich größer als 106.6 als Ablehnungsbereich und Werte kleiner oder gleich 106.6 als Akzeptanz- oder Nichtverwerfungsbereich des Signifikanztests.

Um die Power zu berechnen, müssen wir einen alternativen Wert für den Mittelwert angeben. Wir beschließen, die Power zu berechnen, wenn der wahre Mittelwert 110 ist. Die Abbildung unten zeigt, wie die Power in diesem Fall berechnet wird. Die linke t-Verteilung mit $df = 99$ ist um 0 zentriert (für H_0). Die rechte t-Verteilung ist um $\delta/SE = 10/4 = 2.5$ nach rechts verschoben. Die Effektgröße δ ist hier 10 oder in Einheiten des Standardfehlers 2.5. Die Power ist die Wahrscheinlichkeit, H_0 zu verwerfen, wenn der wahre Mittelwert 110 ist. Da wir H_0 verwerfen, wenn der berechnete Mittelwert größer als 106.6 ist, wird die Wahrscheinlichkeit eines Fehlers 2. Art (β) durch den dunkel schattierten Bereich der Abbildung angegeben. Dieser Wert beträgt hier 0.20. Die Power entspricht dann $1 - \beta = 0.80$. Man beachte, dass es in dieser Situation sechs Parameter gibt, die variiert werden können: zwei Mittelwerte, Standardabweichung, α , Power und Stichprobengröße.

```
SE <- 40/sqrt(100); SE
```

```
## [1] 4
```

```
t_crit <- qt(0.95, df = 99); t_crit
```

```
## [1] 1.6604
```


```
t_crit*SE + 100 # z = (x - mu)/s
```

```
## [1] 106.64
```

```
# Koordinaten für polygon() unten
cord.x1 <- c(1.66, seq(1.6604, 6, 0.001), 1.6604)
cord.y1 <- c(0, dt(seq(1.6604, 6, 0.001) - 2.5, df = 99), 0)

curve(dt(x, df = 99), xlab = "t", lwd = 2,
main= "H0 = 100, p1 = 110, n = 100, sigma = 40, alpha = 0.05, oberseitig",
ylab = "Dichte", xlim = c(-6, 7), ylim = c(0, 0.5))
abline(v = 1.66, lty = 2)
curve(dt(x - 2.5, df = 99), add = TRUE, lty = 2, lwd = 2)
text(3.8, 0.46, "Ablehnungsbereich")
legend(-6, 0.5, c("t(df=99) for mu = 100", "t(df=99) for mu = 110"),
      lty = c(1, 2), lwd = c(2, 2), cex = 0.9)
polygon(cord.x1, cord.y1, col = 'gray67')
curve(dt(x, df = 99), xlab = "t", lwd = 2, add = TRUE)
curve(dt(x, df = 99), xlab = "t", lwd = 2, add = TRUE, lty = 2)
text(3, 0.05, "alpha"); text(-0.4, 0.05, "beta"); text(2.8, 0.15, "Power")
segments(0.1, 0.05, 0.7, 0.02); segments(1.8, 0.02, 2.4, 0.05)
```

$H_0 = 100$, $\mu_1 = 110$, $n = 100$, $\sigma = 40$, $\alpha = 0.05$, oberseitig



```
# distance from 1.6604 to 2.5 = 2.5 - 1.6604 = 0.8396
beta <- pt(-0.8396, df = 99); beta
```

```
## [1] 0.20158
```

```
power <- 1 - beta; power
```

```
## [1] 0.79842
```

In R kann die Power berechnet werden mit:

```
power.t.test(n = 100, delta = 10, sd = 40, sig.level = 0.05,
             type = c("one.sample"),
             alternative = c("one.sided"))
```

```
##
##      One-sample t test power calculation
##
##              n = 100
##             delta = 10
##              sd = 40
##      sig.level = 0.05
##              power = 0.79899
##      alternative = one.sided
```

Wenn man keine gerichtete Hypothese hat (was meistens der Fall ist), muss man zweiseitig testen. In der Abbildung oben wird deutlich, dass bei einem zweiseitigen Test der Ablehnungsbereich nach rechts geht und damit die Power kleiner ist. Wir wiederholen die Berechnungen oben, jetzt aber für einen zweiseitigen t-Test.

```
SE <- 40/sqrt(100); SE
```

```
## [1] 4
```

```
t_crit <- qt(0.975, df = 99); t_crit
```

```
## [1] 1.9842
```

```
t_crit*SE + 100 #  $z = (x - \mu)/s$ 
```

```
## [1] 107.94
```

```
# distance from 1.9842 to 2.5 = 2.5 - 1.9842 = 0.5158
beta <- pt(-0.5158, df = 99); beta
```

```
## [1] 0.30357
```

```
power <- 1 - beta; power
```

```
## [1] 0.69643
```

```
power.t.test(n = 100, delta = 10, sd = 40, sig.level = 0.05,
             type = c("one.sample"),
             alternative = c("two.sided"))
```

```
##
##      One-sample t test power calculation
##
##              n = 100
##             delta = 10
##              sd = 40
##      sig.level = 0.05
##             power = 0.69698
##      alternative = two.sided
```

Die Power ist jetzt nur noch ca. 70%.

Auch hier wollen wir die Power für dieses Beispiel (one-sided, vgl. oben) mit einer Simulation verdeutlichen.

```
# Simulation for  $H_0: \mu = 100$  vs.  $H_A: \mu > 100$  (one-sided, upper tail,  $\alpha = 0.05$ ),  $n = 100$ 
set.seed(3); pop1 <- rnorm(10000000, 110, 40)
mean(pop1); sd(pop1)
```

```
## [1] 110
```

```
## [1] 39.998
```

```

sample_mean <- c()
sample_sd <- c()
for(i in 1:100000) {set.seed(i); sample_mean[i] = mean(sample(pop1, size = 100, replace = TRUE))}
for(i in 1:100000) {set.seed(i); sample_sd[i] = sd(sample(pop1, size = 100, replace = TRUE))}
SE <- sample_sd/sqrt(100)
mean_st <- (sample_mean - 100)/SE
# hist(mean_st)

```

Wir verwerfen H_0 , wenn der Mittelwert der Stichprobe $> t_{crit}$ ist. Hier ist $t_{crit} = 1.6604$, das 95%-Quantil der t-Verteilung bei $df = 99$.

```
table(mean_st > 1.6604)
```

```
##
## FALSE TRUE
## 20049 79951
```

Wir verwerfen H_0 in 80% der Fälle und treffen dann die richtige Entscheidung. Wir verwerfen H_0 nicht (“false negative”) in 20% der Fälle und treffen dann die falsche Entscheidung.

Inferenz für zwei Stichproben (nicht klausurrelevant)

Wir betrachten hier den t-Test für zwei unabhängige Stichproben (Welch-Test) und den t-Test für zwei abhängige Stichproben.

Zweistichproben-t-Test

Dieser Test wird auch Welch-Test oder two sample t-test genannt. Die Frage ist hier, ob es einen Unterschied zwischen den arithmetischen Mitteln in zwei Grundgesamtheiten, X und Y , gibt.

Die Hypothesen sind also:

$H_0 : \mu_X = \mu_Y$ bzw. $H_0 : \mu_X - \mu_Y = \Delta_0$, wobei üblicherweise $\Delta_0 = 0$, vs. H_A : entsprechend zweiseitig oder einseitig.

Testvariable:

$$T = \frac{(\bar{x} - \bar{y} - \Delta_0)}{SE(\bar{x} - \bar{y})} \sim T_{df}$$

mit

$$SE(\bar{x} - \bar{y}) = \sqrt{\frac{\hat{\sigma}_X^2}{n_X} + \frac{\hat{\sigma}_Y^2}{n_Y}}$$

T folgt einer t-Verteilung mit df als Zahl Freiheitsgrade und $df = \frac{Z}{N}$, wobei

$$Z = \left(\frac{\hat{\sigma}_X^2}{n_X} + \frac{\hat{\sigma}_Y^2}{n_Y} \right)^2$$

$$N = \frac{1}{n_X - 1} \left(\frac{\hat{\sigma}_X^2}{n_X} \right)^2 + \frac{1}{n_Y - 1} \left(\frac{\hat{\sigma}_Y^2}{n_Y} \right)^2$$

Es gibt folgende Annahmen:

1. Unabhängigkeit der Beobachtungen: Idealerweise Zufallsstichprobe aus beiden Grundgesamtheiten. Kleiner Auswahlssatz mit $n/N \leq 0.05$.

2. Normalverteilungsannahme: Beide Grundgesamtheiten folgen einer Normalverteilung. Diese Annahme ist nur bei kleinen Stichproben ($n \leq 30$) nötig. Prüfen mit Histogramm bzw. qq-Plot und Shapiro-Wilk-Test. Bei Verletzung dieser Annahme kann der MWU-Test (vgl. Lehrbuch) genutzt werden.
3. Unabhängige Gruppen: Es darf keinerlei Beeinflussung der Gruppen untereinander geben. Bei Abhängigkeit ist der gepaarte t-Test (vgl. unten) zu verwenden.

Betrachten wir Bsp. 11.1 (vgl. Lehrbuch S. 246, S. 267).

Das Problem: 45 Nutzer von Kreditkarten erhalten Bonus-Punkte, 45 andere Nutzer dagegen nicht. Frage: Haben Bonus-Punkte einen umsatzsteigernden Effekt? Es gibt $45+45=90$ Beobachtungen (große Stichprobe) für die Veränderungen der Ausgaben innerhalb von 6 Monaten.

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("Bsp._11.1.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/Bsp._11.1.csv")
attach(data); data[1:2, ] # B = Bonus, kB = kein Bonus
```


```
##   X      B      kB
## 1 1  360.98 -442.41
## 2 2 -142.79 -471.71
```

```
nB <- length(B); nkB <- length(kB)
```


Zunächst vergleichen wir die Verteilungen.

```
boxplot(kB, B, col = c("grey", "red"), ylab = "Euro",
main = "Boxplot für das Bonusprogramm",
names = c("kein Bonus", "Bonus"))
```

Boxplot für das Bonusprogramm



```
par(mfrow = c(1,2)) # beide Abbildungen in 1 Zeile & 2 Spalten
hist(kB, xlab = "Euro", main = "ohne Bonus", ylim = c(0, 20), xlim = c(-2000, 2000))
hist(B, xlab = "Euro", main = "mit Bonus", ylim = c(0, 20), xlim = c(-2000, 2000))
```



```
par(mfrow = c(1,1)) # zurücksetzen auf 1 Zeile & 1 Spalte
```

Der Boxplot zeigt, dass es einen deutlichen Unterschied zwischen den Ausgaben gibt. Mit Bonus sind die Ausgaben im Mittel größer als ohne. Dieser Unterschied könnte aber auch zufällig zustande gekommen sein. Um unsere Vermutung bzgl. des Bonus-Effektes zu untermauern, führen wir einen Hypothesentest durch.

Wir testen $H_0 : \mu_X = \mu_Y$ vs. $H_A : \mu_X > \mu_Y$ zu $\alpha = 0.05$. Wir testen hier oberseitig, da wir davon ausgehen können, dass der Bonus einen positiven Effekt hat.

```
t.test(B, kB, alt = "greater")
```

```
##
## Welch Two Sample t-test
##
## data: B and kB
## t = 2, df = 88, p-value = 0.025
## alternative hypothesis: true difference in means is greater than 0
## 95 percent confidence interval:
##  41.67      Inf
## sample estimates:
## mean of x mean of y
## 251.4054    1.8388
```

Interpretation: Wenn es in der Grundgesamtheit keinen Unterschied zwischen den mittleren zusätzlichen Ausgaben mit und ohne Bonus gibt (wenn also H_0 wahr wäre), liegt die Wahrscheinlichkeit bei einer Zufallsstichprobe von 90 Teilnehmern eine Abweichung zwischen den mittleren Ausgaben wie in der Stichprobe

oder größer zu beobachten, bei 2.5%. Wir verwerfen also die Nullhypothese (kein Unterschied) und nehmen die Alternative (Mittel mit Bonus ist größer als ohne) an. Es gibt also einen positiven und statistisch signifikanten Effekt des Bonusprogramms auf die Ausgaben.

Was noch fehlt, ist die Berechnung des Tests “per Hand”. Zu berechnen ist der Wert für df , die Teststatistik t und schließlich der p-value.

```
n_x <- 45; n_y <- 45
var_x <- var(B); var_y <- var(kB)
SE <- sqrt(var_x/n_x + var_y/n_y)

Z <- (var_x/n_x + var_y/n_y)^2
N <- (1/(n_x - 1))*(var_x/n_x)^2 + (1/(n_y - 1))*(var_y/n_y)^2
df <- Z/N; df                                # exakt der für df im R Output
```

```
## [1] 87.979
```

```
t <- (mean(B) - mean(kB))/SE; t              # exakt der für df im R Output
```

```
## [1] 1.9956
```

```
pnorm(1.96)
```

```
## [1] 0.975
```

```
p_value <- 1 - pt(t, df); p_value           # exakt der für df im R Output
```

```
## [1] 0.024538
```

Betrachten wir nun das zum Welch-Test korrespondierende KI

$$KI(1 - \alpha)_{\mu_X - \mu_Y} = (\bar{x} - \bar{y}) \pm t_{n-1[1-\alpha/2]} SE(\bar{x} - \bar{y})$$

Für die Berechnung des 95%-KI ist es nötig, einen zweiseitigen Test durchzuführen.

```
t.test(B, kB, alt = "two.sided", conf.level = 0.95)
```

```
##
## Welch Two Sample t-test
##
## data: B and kB
## t = 2, df = 88, p-value = 0.049
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## 1.0333 498.1000
## sample estimates:
## mean of x mean of y
## 251.4054 1.8388
```

```
#t.test(B, kB, alt = "two.sided", conf.level = 0.90) # schmaleres KI
```

Das 95%-KI für die wahre Differenz der Mittelwerte ist [1.03 Euro, 498.10 Euro]. Die “quick & dirty“-Interpretation ist: Mit 95% Wahrscheinlichkeit liegt die wahre mittlere Veränderung der Ausgaben im Intervall [1.03 Euro, 498.10 Euro]. Richtig wäre: Wenn wir 100 solcher Zufallsstichproben ziehen würden, würden sich 100 verschiedene KIs ergeben. Von diesen 100 KIs werden im Mittel 95 den wahren mittleren Unterschied beinhalten und 5 nicht. Unser KI [1.03 Euro, 498.10 Euro] ist eines dieser 100 KIs. Ein solches KI macht Sinn für Berechnungen, ob ein solches Bonus-Programm profitabel ist (worst case, best case).

Der Zweistichproben-t-Test mit Varianzhomogenität wird hier nicht behandelt (vgl. Lehrbuch zu den Gründen). In `t.test()` muss dann `var.equal = TRUE` gesetzt werden.

Exkurs: Messung der Effektgröße (effect size) mit Cohen’s d Cohen’s d ist eines der am häufigsten verwendeten Maße für die Effektgröße und beschreibt, wie stark sich die Mittelwerte zweier Stichproben unterscheiden (es kann aber auch für eine Stichprobe berechnet werden, vgl. unten). Da Cohen’s d ein standardisiertes Abstandsmaß ist, ist es unerheblich, in welcher Einheit die Variable erhoben wurde. Denn durch die Standardisierung werden die Mittelwerte auf eine neue, gemeinsame und dimensionslose Einheit gebracht und dadurch direkt vergleichbar. Ein weiterer Vorteil ist, dass Cohen’s d im Gegensatz zum p-Wert nicht von der Stichprobengröße abhängt. Aufgrund der Berechnung von Mittelwerten wird Cohen’s d i.d.R. nur bei metrischen Skalen ($\Leftrightarrow$ quantitative Daten, Zahlen mit Einheiten) angewendet.

Berechnung von Cohen’s d :

$$d = \frac{\bar{x}_A - \bar{x}_B}{\hat{\sigma}_{AB}}$$

mit $\hat{\sigma}_{AB}$ als Standardabweichung.

Für die Standardabweichung gibt es zwei Berechnungsmethoden:

- Wenn die Stichprobengröße beider Gruppen (X und Y) gleich ist: $\hat{\sigma}_{XY} = \sqrt{\frac{\hat{\sigma}_X^2 + \hat{\sigma}_Y^2}{2}}$
- Wenn die Stichprobengröße beider Gruppen (X und Y) ungleich ist: $\hat{\sigma}_{XY} = \sqrt{\frac{\hat{\sigma}_X^2 n_X + \hat{\sigma}_Y^2 n_Y}{n_X + n_Y}}$

Für die Interpretation der mit d gemessenen Mittelwertunterschiede gilt folgende Regel: vernachlässigbar für $|d| \leq 0.2$, klein für $0.2 < |d| \leq 0.5$, mittel für $0.5 < |d| \leq 0.8$ und groß für $|d| > 0.8$.

Ein Beispiel für den Einstichproben-t-Test (vgl. oben), wobei die Nullhypothese $\mu_0 = 0.5$ ist:

```
library(rstatix) # muss installiert sein
bier <- c(0.51, 0.48, 0.52, 0.47, 0.48, 0.40, 0.44, 0.43, 0.48, 0.49, 0.47, 0.45, 0.45, 0.46, 0.5)
# Die Daten müssen in einem data frame stehen.
data <- data.frame(bier); head(data, 2)
```

```
##   bier
## 1 0.51
## 2 0.48
```

```
cohens_d(bier ~ 1, data = data, mu = 0.5) # ~1 bedeutet: Es gibt nur eine Variable
```

```
## # A tibble: 1 x 6
##   .y.   group1 group2   effsize     n magnitude
## * <chr> <chr>  <chr>      <dbl> <int> <ord>
## 1 bier   1      null model -0.992    15 large
```

```
# per Hand
d <- (mean(bier) - 0.5)/sd(bier); round(d, 3)
```

```
## [1] -0.992
```

Hier ist $|d| = 0.992$, was als ein großer Effekt eingeschätzt werden kann. Die Abweichung von der Nullhypothese $\mu_0 = 0.5$ nach unten beträgt 0.992 Standardabweichungen (also ca. 1 SD). Der Effekt ist also sowohl ökonomisch ($\Leftrightarrow$ Effektgröße) als auch statistisch (p-value < 0.05) signifikant.

Ein Beispiel für den Zweistichproben-t-Test (vgl. oben):

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("Bsp._11.1.csv")
head(data, 2)
```

```
##      X      B      kB
## 1 1 360.98 -442.41
## 2 2 -142.79 -471.71
```

```
# data in long format = alle Werte in einer Spalte
value <- c(data$B, data$kB); value[1:4]
```

```
## [1] 360.98 -142.79 696.45 1177.23
```

```
length(data$B)
```

```
## [1] 45
```

```
treat <- c(rep("B", 45), rep("kB", 45))
data <- data.frame(treat, value)
head(data, 2)
```

```
##   treat  value
## 1     B 360.98
## 2     B -142.79
```

```
cohens_d(value ~ treat, data = data, mu = 0, var.equal = FALSE)
```

```
## # A tibble: 1 x 7
##   .y. group1 group2 effsize  n1    n2 magnitude
## * <chr> <chr> <chr>    <dbl> <int> <int> <ord>
## 1 value B      kB      0.421   45    45 small
```

```
# per Hand
diff <- mean(value[treat == "B"]) - mean(value[treat == "kB"]); diff
```

```
## [1] 249.57
```

```
var_X <- var(value[treat == "B"]); var_Y <- var(value[treat == "kB"])
n_X <- length(value[treat == "B"]); n_Y <- length(value[treat == "kB"])
sd_XY <- sqrt((var_X*n_X + var_Y*n_Y)/(n_X + n_Y))
d <- diff/sd_XY; round(d, 3)
```

```
## [1] 0.421
```

Es liegt eine mittlere Effektgröße vor. Die Werte unterscheiden sich im Mittel um 0.421 Standardabweichungen.

Exkurs: A-priori-Power-Analyse In diesem Exkurs soll gezeigt werden, wie man eine a-priori-Power-Analyse für einen zweiseitigen t-Test durchführt. Eine a-priori-Power-Analyse ist eine statistische Methode, die vor der Datenerhebung durchgeführt wird, um die benötigte Stichprobengröße (n) zu bestimmen, die nötig ist, um einen erwarteten Effekt mit einer bestimmten Wahrscheinlichkeit (Power) zu entdecken und eine verlässliche Entscheidung zu treffen. Sie ist essenziell für eine gute Versuchsplanung und legt Signifikanzniveau (α), Teststärke (Power = $1 - \beta$) und die minimale Effektgröße fest, um eine aussagekräftige Schlussfolgerung zu ermöglichen.

Wir nutzen hier den Befehl `power.t.test()` für einen zweiseitigen Test. Wir setzen d auf 0.2, 0.4, 0.6, 0.8 und 1. Der Befehl berechnet dann die Power gemäß APES (vgl. oben).

```
library(stats) # muss installiert sein
pwrn10 <- power.t.test(n = 10, delta = seq(0.2, 1, 0.2), sd = 1, sig.level = 0.05,
                      power = NULL, type = "two.sample", alt = "two.sided")
pwrn10$power
```

```
## [1] 0.062265 0.132966 0.245322 0.394943 0.561985
```

```
pwrn20 <- power.t.test(n = 20, delta = seq(0.2, 1, 0.2), sd = 1, sig.level = 0.05,
                      power = NULL, type = "two.sample", alt = "two.sided")
pwrn30 <- power.t.test(n = 30, delta = seq(0.2, 1, 0.2), sd = 1, sig.level = 0.05,
                      power = NULL, type = "two.sample", alt = "two.sided")
pwrn40 <- power.t.test(n = 40, delta = seq(0.2, 1, 0.2), sd = 1, sig.level = 0.05,
                      power = NULL, type = "two.sample", alt = "two.sided")
pwrn50 <- power.t.test(n = 50, delta = seq(0.2, 1, 0.2), sd = 1, sig.level = 0.05,
                      power = NULL, type = "two.sample", alt = "two.sided")
pwrn50$power
```

```
## [1] 0.16609 0.50815 0.84388 0.97728 0.99861
```


```
pwr0.2 <- c(pwrn10$power[1], pwrn20$power[1], pwrn30$power[1], pwrn40$power[1], pwrn50$power[1])
pwr0.2
```

```
## [1] 0.062265 0.089581 0.115434 0.140849 0.166088
```

```
pwr0.4 <- c(pwrn10$power[2], pwrn20$power[2], pwrn30$power[2], pwrn40$power[2], pwrn50$power[2])
pwr0.6 <- c(pwrn10$power[3], pwrn20$power[3], pwrn30$power[3], pwrn40$power[3], pwrn50$power[3])
pwr0.8 <- c(pwrn10$power[4], pwrn20$power[4], pwrn30$power[4], pwrn40$power[4], pwrn50$power[4])
pwr1.0 <- c(pwrn10$power[5], pwrn20$power[5], pwrn30$power[5], pwrn40$power[5], pwrn50$power[5])
n <- c(10, 20, 30, 40, 50)
```

Wir erstellen nun einen Plot, in dem wir die Stichprobengröße auf die x-Achse und die Power auf die y-Achse setzen. In diesem Plot gibt es fünf Funktionen, je eine für $d = 0.2, 0.4, 0.6, 0.8$ und 1.0 . Um eine Power von 80% zu erreichen, benötigt man bei $d = 1.0$ eine Stichprobe von (approx.) $n = 18$, bei $d = 0.8$ von $n = 26$ und bei $d = 0.6$ von $n = 45$. Wie zu erwarten: Bei größerer Effektstärke steigt die Power für eine gegebene Stichprobengröße bzw. für eine gegebene Effektstärke steigt die Power mit größerer Stichprobe.

```
par(mar=c(5.1, 4.1, 4.1, 9), xpd=TRUE)
plot(n, pwr0.2, type = "l", ylim = c(0,1),
main = "Power analysis, n = [10, 50], d = [0.2, 1.0]", xlim = c(10, 50),
xlab = "Stichprobengröße n", ylab = "Power",
col = "grey20", lwd = 2)
lines(n, pwr0.4, type = "l", col = "grey40", lwd = 2)
lines(n, pwr0.6, type = "l", col = "grey60", lwd = 2)
lines(n, pwr0.8, type = "l", col = "grey80", lwd = 2)
lines(n, pwr1.0, type = "l", col = "grey95", lwd = 2)
segments(10, 0.8, 50, 0.8, lty = 2)
legend(55, 1.04, lwd = c(rep(2, 10)), title = "d = ",
c("1.0", "0.8", "0.6", "0.4", "0.2"), inset=c(-0.2,0),
col = c("grey95","grey80","grey60","grey40","grey20"),
cex = 1)
```



t-Test für gepaarte Stichproben

Dieser Test wird auch paired t-test genannt. Die Frage ist hier, ob es einen Unterschied zwischen den arithmetischen Mitteln zweier verbundener Grundgesamtheiten, X und Y , gibt.

Die Hypothesen sind:

$H_0 : \mu_D = \Delta_0$ mit μ_D als wahrer Mittelwert der Differenzen $d = x - y$ und H_A ist entsprechend zweiseitig oder einseitig zu wählen.

Die Testvariable ist:

$T = \frac{\bar{D} - \Delta_0}{SE(\bar{D})} \sim T$ mit df als Zahl Freiheitsgrade

$df = n - 1$ mit n als Zahl der Paare

$SE(\bar{D}) = \frac{\hat{\sigma}_D}{\sqrt{n}}$ als Standardfehler der paarweisen Differenzen

Folgende Annahmen sind zu prüfen:

1. Gepaarte Daten. Folgt aus dem Kontext der Datenerhebung. Es gibt einen Bezug zwischen den Beobachtungen, z.B. before/after oder Ehepartner-Befragungen.
2. Unabhängigkeit der Differenzen (idealerweise Zufallsstichprobe) und kleiner Auswahlssatz mit $n/N \leq 0.05$.
3. Normalverteilungsannahme der Differenzen (nur bei $n \leq 30$). Zu prüfen mit qq-plot und Shapiro-Wilk-Test.

Betrachten wir Bsp. 11.3 (vgl. Lehrbuch, S. 251, S. 268). Das Problem ist hier: 13 Tester testen ein Getränk zu Zeitpunkt 1 und dann das gleiche Getränk zu Zeitpunkt 2. Die Süße wird auf einer $[0,10]$ -Skala angegeben. Wir wollen wissen, ob die Süßkraft abnimmt. Achtung: $[0,10]$ -Skala ist eigentlich ordinal, wird hier aber kardinal (mit Punkte als Einheit) interpretiert.

Wir geben die Daten ein:

```
T1 <- c(9, 3, 6, 4, 1, 4, 6, 4, 7, 8, 5, 1, 5) # Süßkraft
T2 <- c(8, 2, 6, 2, 3, 2, 4, 0, 4, 5, 4, 2, 3)
n <- length(T1)
D <- T1 - T2; D # Differenzen
```


```
## [1] 1 1 0 2 -2 2 2 4 3 3 1 -1 2
```

```
mean(D)
```

```
## [1] 1.3846
```


Folgende Abbildungen lassen sich erstellen:

```
hist(D, main = "Histogramm",
xlab = "Differenz der Süßkraft T1 - T2")
```



```
qqnorm(D, cex = 1.2); qqline(D)
```

Normal Q-Q Plot



```
shapiro.test(D) # p-value > 0.05, Null wird nicht verworfen
```

```
##
## Shapiro-Wilk normality test
##
## data: D
## W = 0.949, p-value = 0.58
```

Die Normalverteilungsannahme der Differenzen ist erfüllt. Das Histogramm ähnelt einer Glockenkurve, ist symmetrisch und unimodal. Mit dem Shapiro-Wilk-Test lässt sich die Nullhypothese, dass eine Normalverteilung in der Grundgesamtheit vorliegt, nicht verwerfen. Das Histogramm deutet darauf hin, dass es im Mittel eine positive Differenz gibt, die Süßkraft also abnimmt.

Wir testen $H_0 : \mu_D = 0$ vs. $H_A : \mu_D > 0$. Wir testen oberseitig, da wir vermuten, dass die Süßkraft abnimmt. Der Test wird folgendermaßen durchgeführt:

```
t.test(T1, T2, alt = "greater", paired = TRUE)
```

```
##
## Paired t-test
##
## data: T1 and T2
## t = 3.01, df = 12, p-value = 0.0055
## alternative hypothesis: true mean difference is greater than 0
```

```
## 95 percent confidence interval:
## 0.56393      Inf
## sample estimates:
## mean difference
##          1.3846
```

Interpretation: Wenn der wahre Unterschied in der Grundgesamtheit Null ist, ist die Wahrscheinlichkeit, bei einer Zufallsstichprobe von $n = 13$ eine Abweichung wie in der Stichprobe oder größer zu beobachten, gleich 0.55%. Dieses Ereignis ist also extrem unwahrscheinlich und unser Vertrauen in die Nullhypothese ist “erschüttert”. H_0 wird verworfen, weil der p-value < 0.05 . Es gibt eine statistisch signifikante Verringerung der Süßkraft. Wir können also davon ausgehen, dass die Süßkraft des Süßstoffes nachlässt.

Was hier noch fehlt ist die Berechnung des Tests “per Hand” (vgl. Lehrbuch, analog zum Welch-Test). Zu berechnen ist der Wert für df , die Teststatistik t und schließlich der p-value.

Wir haben also “statistische Signifikanz” gezeigt (p-value $< \alpha$), aber ist das Resultat auch “ökonomisch signifikant”? Dazu berechnen wir ein KI, mit dessen Grenzen wir Hinweise auf die ökonomische Relevanz des Problems erhalten.

Das Intervall (zweiseitig) bestimmt sich mit:

$$KI(1 - \alpha)_{\mu_D} = \bar{d} \pm t_{n-1[1-\alpha/2]} SE(\bar{D})$$

```
t.test(T1, T2, alt = "two.sided", paired = TRUE)
```

```
##
## Paired t-test
##
## data: T1 and T2
## t = 3.01, df = 12, p-value = 0.011
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
## 0.38134 2.38789
## sample estimates:
## mean difference
##          1.3846
```

Das 95%-KI ist $[0.38, 2.39]$. Das Intervall liefert eine Art best-case-and-worst-case Szenario. Im worst-case reduziert sich die Süßkraft um 2.39 Punkte, im best-case nur um 0.38. Wir können also zu 95% darauf vertrauen, dass ein mit dieser Methode erzeugtes Intervall die wahre mittlere Süßkraftdifferenz beinhaltet. Unser Intervall, $[0.38, 2.39]$, ist ein solches Intervall.

Bei Annahmeverletzungen (Stichprobengröße, Normalverteilungsannahme) bieten sich für die hier vorgestellten t-Tests folgende Alternativen (vgl. Lehrbuch) an:

- MWU-Test für den Welch-Test
- Wilcoxon-Test für gepaarte Stichproben für den gepaarten t-Test

Inferenz für Einfachregression und Korrelation (nur W662)

Wir wollen nun die Abhängigkeit einer Variablen Y von einer Variablen X beschreiben. Dabei versuchen wir wieder von der Stichprobe auf die Grundgesamtheit zu schließen. Wir konzentrieren uns zunächst auf eine **lineare Abhängigkeit** (lineare Einfachregression). Später erweitern wir die Betrachtung auf nicht-lineare Zusammenhänge, die wir durch eine geeignete Transformation in einen linearen Zusammenhang überführen (log-Transformation).

Schätzen des Modells

Das wahre (unbekannte) Modell für den linearen Zusammenhang in der **Grundgesamtheit** sei:

$$\hat{y} = \beta_0 + \beta_1 x$$

bzw. da es Abweichungen (Fehlerterme u) zwischen den vom Modell prognostizierten Werten $\hat{y}$ und den wahren Werten y gibt:

$$y = \beta_0 + \beta_1 x + u \text{ mit } U \sim N(0, \sigma)$$

Wir nennen Y “abhängige” (oder “zu erklärende”) Variable und X “unabhängige” (oder “erklärende”) Variable. Die wahren Fehlerterme u sind annahmegemäß normalverteilt mit Mittelwert null und konstanter Standardabweichung σ .

Das Ergebnis der Schätzung basierend auf einer **Stichprobe** aus der Grundgesamtheit ist:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

bzw.

$$y = \hat{\beta}_0 + \hat{\beta}_1 x + e$$

Die beobachteten Fehler (“Residuen” genannt) sind also:

$$e = \text{observed} - \text{predicted} = y - \hat{y}$$

Die geschätzten Parameter des linearen Regressionsmodells berechnen sich mit:

$$\hat{\beta}_1 = \frac{\widehat{cov(x,y)}}{\hat{\sigma}_x^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Die Berechnung von $\hat{\beta}_1$ und $\hat{\beta}_0$ ergibt sich aus der **Minimierung der Summe der quadrierten Residuen**. Der Berechnung liegt also eine Optimierung zu Grunde.

Annahmen

Folgende Annahmen müssen erfüllt sein, damit wir das Regressionsmodell schätzen und sinnvoll interpretieren können:

1. Linearität: Die Regressionsanalyse ist nur dann sinnvoll, wenn der Zusammenhang zwischen X und Y tatsächlich linear ist.
2. Unabhängigkeit: Die Fehlerterme des Regressionsmodells müssen unabhängig voneinander sein. Liegt eine Zufallsstichprobe vor? Ist die Stichprobe in Relation zur Grundgesamtheit klein?
3. Konstante Varianz der Fehlerterme (Homoskedastizität): Die Streuung der Residuen e sollte die gleiche sein für alle Werte von X . Dies ist mit einem Streudiagramm der Residuen und prognostizierten Werte $\hat{Y}$ (“Kontrollplot”) zu prüfen. Dabei ist darauf zu achten, dass die Streuung der Datenpunkte konstant ist und keine Struktur (Trichter, Klumpen usw.) zu erkennen sind.
4. Normalverteilung der Fehlerterme: Wir nehmen an, dass die wahren Fehlerterme u um die Regressionsgerade für jeden Wert von X einer Normalverteilung $N(0, \sigma)$ folgen und der Erwartungswert der Fehler Null ist. Wir benötigen diese Annahme (für kleine Stichproben), um mit Hilfe der Normalverteilung von der Stichprobe auf die Grundgesamtheit schließen zu können.

Folgende Schritte zur Regressionsgeraden lassen sich identifizieren:

1. Man erstellt zunächst ein Streudiagramm der Daten und prüft, ob ein (näherungsweise) linearer Zusammenhang vorliegt. Ggf. sind die Daten zu transformieren.

2. Ist der Zusammenhang hinreichend linear, schätzt man die Regressionsgerade und ermittelt die Residuen e sowie die prognostizierten Werte $\hat{y}$.
3. Für den Fall zeitabhängiger Daten sollten die Residuen und die Zeitvariable in einem Streudiagramm dargestellt werden. Damit kann die Unabhängigkeitsannahme geprüft werden.
4. Man erstellt ein Streudiagramm der Residuen e und der prognostizierten Werte $\hat{y}$. Dieses Streudiagramm ("Kontrollplot") sollte keine Struktur, auffällige Muster oder ungewöhnliche Beobachtungen zeigen. Ggf. sind zwei Regressionen durchzuführen (mit ungewöhnlichen Beobachtungen und ohne diese).
5. Schließlich erstellt man ein qq-Plot (ggf. inkl. Shapiro-Wilk-Test) oder ein Histogramm der Residuen und prüft die Normalverteilungsannahme und ob Ausreißer vorliegen. Für große Stichproben ($n > 30$, besser $n > 50$) ist die Erfüllung der Normalverteilungsannahme nicht nötig, da hier wieder der Zentrale Grenzwertsatz greift.

Eigenschaften

Wichtige Eigenschaften der Regressionsgeraden sind:

- Die Regressionsgerade geht durch den Schwerpunkt des Streudiagramms, also den Punkt $(\bar{x}, \bar{y})$.
- Die Summe der Fehlerterme ist Null, d.h. $\sum e = 0$. Damit ist auch das arithmetische Mittel der Fehler Null ($\bar{e} = 0$).
- Die Varianz der abhängigen Variablen, $\hat{\sigma}_Y^2$, kann in zwei Teile zerlegt werden mit: $\hat{\sigma}_Y^2 = \hat{\sigma}_Y^2 + \hat{\sigma}_E^2$. Dabei ist $\hat{\sigma}_Y^2$ die Varianz der Werte auf der Regressionsgeraden (der "fitted values") und $\hat{\sigma}_E^2$ die Varianz der Fehlerterme in der Stichprobe.

Hypothesentest für den Anstiegparameter

Inferenz bedeutet das Schließen von der Stichprobe auf die Grundgesamtheit (analog: Induktion, d.h. das Schließen vom Einzelfall auf das Allgemeine). Wir testen hier eine Nullhypothese über den unbekannten Anstiegparameter β_1 in der Grundgesamtheit.

$$H_0 : \beta_1 = 0 \text{ vs. } H_A : \beta_1 \neq 0$$

Normalerweise wird immer die Nullhypothese "wahrer Anstiegparameter ist gleich Null, d.h., X hat keinen Effekt auf Y " getestet.

Wenn H_0 wahr ist, gilt:

$$\frac{\hat{\beta}_1}{SE(\hat{\beta}_1)} \sim T_{df} \text{ mit } df = n - 2$$

mit

$$SE(\hat{\beta}_1) = \frac{\hat{\sigma}_E}{\sigma_X \sqrt{n-1}}$$

mit

$$\hat{\sigma}_E = \text{Standardabweichung der Residuen} = \sqrt{\frac{\sum (y - \hat{y})^2}{(n-2)}}$$

$$\hat{\sigma}_X = \text{Standardabweichung von } X$$

Die Realisation der Testvariablen T_{df} wird genutzt, um einen p-value zu berechnen. Entsprechend lässt sich auch ein Hypothesentest für den Achsenabschnitt durchführen (vgl. Lehrbuch S. 278/279).

Wir können damit auch leicht ein KI für den wahren Anstiegparameter (β_1) konstruieren:

$$KI(1 - \alpha)_{\beta_1} = \hat{\beta}_1 \pm t_{df[1-\alpha/2]} SE(\hat{\beta}_1)$$


Betrachten wir Bsp. 5.2 aus dem Lehrbuch (S. 91, 279). Wir unterstellen, dass die Beobachtungen zufällig aus einer großen Grundgesamtheit gezogen wurden.

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("Bsp._5.2.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/Bsp._5.2.csv")
data[1:2, ]; attach(data)
```

```
##      output totalcost
## 1      20      25.1
## 2      21      25.2
```

Die Variable output wird in Mengeneinheiten (ME) gemessen, totalcost in 1000 Euro.

```
plot(output, totalcost,
      xlab = "Output in ME", ylab = "Kosten in 1000 Euro")
abline(lm(totalcost ~ output))
```



```
ols <- lm(totalcost ~ output) # speichert die Regression, Zugriff später
summary(ols)                  # Output der Regression
```

```
##
## Call:
## lm(formula = totalcost ~ output)
```

```
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.293 -1.620  0.222  1.548  3.452
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    5.658      4.876    1.16  0.26293
## output         0.892      0.202    4.42  0.00043 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.21 on 16 degrees of freedom
## Multiple R-squared:  0.55,    Adjusted R-squared:  0.521
## F-statistic: 19.5 on 1 and 16 DF,  p-value: 0.000431
```

```
n <- length(output)                                # Zahl Beobachtungen
s_e <- sqrt(sum(ols$residuals^2)/(n-2)); s_e # Residual standard error
```

```
## [1] 2.2128
```

```
b1_dach <- cov(output, totalcost)/var(output); b1_dach
```

```
## [1] 0.8925
```

```
b0_dach <- mean(totalcost) - b1_dach*mean(output); b0_dach
```

```
## [1] 5.6578
```

Mit `summary()` kann das Regressionsmodell ausgewertet werden. Für den Anstiegsparameter β_1 werden ausgegeben: geschätzter Parameter (**Estimate**), Standardfehler des Parameters (**Std. Error**), t-Wert (**t value**) und p-value (**Pr(>|t|)**).

Der Output der Regression für β_1 in R (also “per Hand”) ist:

```
SE_b1_dach <- s_e / (sd(output)*sqrt(n-1)); SE_b1_dach
```

```
## [1] 0.202
```

```
t_b1_dach <- (b1_dach - 0)/SE_b1_dach; t_b1_dach
```

```
## [1] 4.4183
```

```
p_value_b1_dach <- 2*(1 - pt(t_b1_dach, n - 2)); p_value_b1_dach
```

```
## [1] 0.00043058
```

Das 95%-KI kann mit dem Befehl `confint()`, der auf das Objekt `ols` zugreift, erzeugt werden.

```
confint(ols, "output", level = 0.95) # 95%-KI für Anstiegsparameter
```

```
##           2.5 % 97.5 %
## output 0.46428 1.3207
```

Das Modell prognostiziert, dass eine Erhöhung des Outputs um 1 ME im Mittel die Kosten um 892.5 Euro erhöht. Dieser Effekt ist statistisch signifikant (p-value < 0.05). Interpretation: Wenn es in der Grundgesamtheit keinen Effekt von `output` auf `totalcost` gibt, dann ist die Wahrscheinlichkeit, einen Effekt wie in der Stichprobe oder extremer zu beobachten, unter 5%. Der F-Test wird im Kapitel “Multiple Regression” behandelt.

Generell ist die **Prognose** eine wichtige Anwendung der Regression. Man kann z.B. einen beliebigen Wert für `output` nehmen und für diesen Wert mit Hilfe der Regressionsgleichung den Wert der abhängigen Variablen, hier `totalcost`, prognostizieren. Dabei ist natürlich der Kontext des Modells zu beachten.

```
pred_35 <- b0 + b1*35 # Prognose für totalcost(output = 35)
pred_35
```

```
## [1] 36.895
```

Bestimmtheitsmaß

R^2 ist das Bestimmtheitsmaß der Regression und definiert als Anteil der vom Modell erklärten Varianz an der zu erklärenden Varianz.

Es gilt:

$$R^2 = \frac{\hat{\sigma}_Y^2}{\sigma_Y^2} \text{ mit } 0 \leq R^2 \leq 1.$$

Das Bestimmtheitsmaß wird konstruiert basierend auf der **Varianzzerlegung** (vgl. oben):

$$\hat{\sigma}_Y^2 = \hat{\sigma}_{\hat{Y}}^2 + \hat{\sigma}_E^2$$

Ganz analog gilt (ohne den Term $\frac{1}{n-1}$ in der Varianz):

$$SST = SSReg + RSS$$

$SST = \sum (y - \bar{y})^2$ = Total Sum of Squares. Ein größeres SST bedeutet eine größere Streuung der Y-Variablen, entweder auf Grund von mehr Rauschen in den Residuen (RSS) oder Modellkorrelation (SSReg).

$SSReg = \sum (\hat{y} - \bar{y})^2$ = Regression Sum of Squares. Ein größeres SSReg bedeutet eine größere Streuung der vom Modell erklärten Werte $\hat{y}$ (Modellkorrelation).

$RSS = \sum (e^2)$ = Residual Sum of Squares. Ein höheres RSS bedeutet mehr “Rauschen” in den Daten bzw. Residuen und eine weniger präzise Vorhersage.

Daher gilt:

$$R^2 = \frac{SSReg}{SST} \text{ mit } 0 \leq R^2 \leq 1$$

Betrachten wir das R^2 zu Bsp. 5.2 im Lehrbuch oben:

```
ols$residuals[1:4] # Residuen
```

```
##           1           2           3           4
## 1.59222 0.79972 -3.29278 0.51472
```

```
ols$fitted[1:4]      # fitted values = predicted values
```

```
##      1      2      3      4  
## 23.508 24.400 25.293 26.185
```

```
mean(totalcost); mean(ols$fitted) # beide Werte sind gleich
```

```
## [1] 27.078
```

```
## [1] 27.078
```

```
RSS <- sum(ols$residuals^2); RSS
```

```
## [1] 78.344
```

```
SSReg <- sum((ols$fitted.values - mean(totalcost))^2); SSReg
```

```
## [1] 95.587
```

```
SST <- sum((totalcost - mean(totalcost))^2); SST
```

```
## [1] 173.93
```

```
R2 <- SSReg/SST; R2      # Berechnung R2
```

```
## [1] 0.54957
```

```
var(ols$fitted)/var(totalcost) # Alternativ für R2
```

```
## [1] 0.54957
```

Der Anteil der vom Modell erklärten Varianz an der Varianz der abhängigen Variablen beträgt 55%. M.a.W. unser Modell ist in der Lage, 55% der Streuung der abhängigen Variablen zu erklären.

Bei der Einfachregression gilt:

$$R^2 = (r_{XY})^2$$

Hier:

```
cor(output, totalcost)^2
```

```
## [1] 0.54957
```

Im Kapitel “Multiple Regression” wird R^2_{adj} eingeführt. R^2_{adj} führt eine “Strafe” ein für komplexere Modelle (mit vielen erklärenden Variablen). Die Abweichung zum R^2 ist aber meist relativ gering.

$$R^2_{adj} = 1 - (1 - R^2) \frac{(n-1)}{(n-k-1)} \text{ mit } k \text{ als Zahl erklärende Variablen}$$

Hier ist $k = 1$.


```
R2adj <- 1 - (1 - R2)*(n - 1)/(n - 1 - 1); R2adj
```

```
## [1] 0.52141
```

Hier noch nötig: Man erstellt ein Streudiagramm der Residuen e und der prognostizierten Werte $\hat{y}$. Dieses Streudiagramm sollte keine Struktur, auffällige Muster oder ungewöhnliche Beobachtungen zeigen.

Das Streudiagramm zu Bsp. 5.2 im Lehrbuch oben:


```
plot(ols$fitted.values, ols$residuals)
abline(h = 0, lty = 2)
```



Man erstellt ein qq-Plot oder ein Histogramm der Residuen und prüft die Normalverteilungsannahme (hier liegt eine kleine Stichprobe mit $n \leq 30$ vor) und ob Ausreißer vorliegen.

```
qqnorm(ols$residuals)      # qq-Plot
qqline(ols$residuals)      # mit Linie
```

Normal Q-Q Plot



```
# H0 der Normalverteilung kann nicht verworfen werden
shapiro.test(ols$residuals)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  ols$residuals
## W = 0.95, p-value = 0.43
```

Für die weitere Diagnose vgl. Kapitel “Multiple Regression”.

Betrachten wir ein weiteres Beispiel.

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("wage1.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/wage1.csv")
names(data)[1:7]; attach(data)
```


```
## [1] "wage"      "educ"      "exper"     "tenure"    "nonwhite"  "female"    "married"
```

```
summary(wage); summary(educ)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1.43   3.33   4.65   5.91   6.88  24.98
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      0.0   12.0   12.0    12.6   14.0    18.0
```

```
n <- length(wage)
plot(educ, wage)
abline(lm(wage ~ educ))
```



```
ols1 <- lm(wage ~ educ); summary(ols1)
```

```
##
## Call:
## lm(formula = wage ~ educ)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
##    -5.34   -2.16   -0.98    1.19   16.60
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -0.8863     0.6843   -1.3    0.2
## educ           0.5407     0.0532   10.2   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.37 on 523 degrees of freedom
```

```
## Multiple R-squared:  0.165, Adjusted R-squared:  0.163  
## F-statistic: 103 on 1 and 523 DF,  p-value: <2e-16
```

```
b1_dach <- cov(wage, educ)/var(educ); b1_dach
```

```
## [1] 0.54065
```


```
b0_dach <- mean(wage) - b1_dach*mean(educ); b0_dach
```

```
## [1] -0.8863
```

Gemäß der Modellprognose erhöht ein zusätzliches Jahr Bildung den Stundenlohn um im Mittel 0.54\$. Dieser Effekt ist statistisch hochsignifikant (p-value < 0.01). Aber: Offensichtlich ist hier die Annahme eines linearen Zusammenhangs und der Homoskedastizität verletzt.

Ausgabe der Residuen:


```
hist(ols1$residuals)
```



Auch die Normalverteilungsannahme ist verletzt (das ist aber hier unkritisch, weil eine große Stichprobe vorliegt). Dies zeigt auch der Shapiro-Wilk-Test.

```
qqnorm(ols1$residuals); qqline(ols1$residuals)
```

Normal Q-Q Plot



```
shapiro.test(ols1$residuals)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  ols1$residuals
## W = 0.844, p-value <2e-16
```


Die Verletzung der Homoskedastizitätsannahme (konstante Varianz der Fehlerterme) lässt sich auch mit einem Streudiagramm der prognostizierten Werte $\hat{y}$ und der Residuen e zeigen. Wir wollen die Residuen in diesem Plot standardisiert darstellen (vgl. Kapitel “Multiple Regression”). Für die Standardisierung benötigen wir die Standardabweichung der Residuen (auch “Residual Standard Error” genannt, wird auch mit `summary()` ausgegeben):

$$\hat{\sigma}_E = \sqrt{\frac{\sum (y - \hat{y})^2}{(n-2)}}$$

```
SE_res <- sqrt(sum(ols1$residuals^2)/(n-2)); SE_res
```

```
## [1] 3.3744
```

```
res_st <- ols1$residuals/SE_res
plot(ols1$fitted.values, res_st)
abline(h = 0, lty = 2)
```




Auf der y-Achse ist die Dimension jetzt nicht mehr USD (dies wäre der Fall, wenn man die nicht-standardisierten Residuen darstellen würde), sondern die Standardabweichung von e .

Offensichtlich liegt hier eine deutliche Struktur im Streudiagramm vor. Das Modell verletzt die Regressionsannahmen. Wir müssen also das Modell um zusätzliche erklärende Variablen wie z.B. Geschlecht, Job-Erfahrung usw. erweitern und/oder die Variablen transformieren, damit ein linearer Zusammenhang entsteht.

Wir transformieren hier die abhängige Variable Y , um diese “zu stauchen”. Hier ist $\log(\text{wage}) = \ln(\text{wage}) = \text{lwage}$ schon definiert.

```
plot(educ, lwage)
abline(lm(lwage ~ educ))
```




Die Annahme der Homoskedastizität ist deutlich besser erfüllt. Jetzt liegt eine gleichmäßigere Streuung der Beobachtungen um die Regressionsgerade vor. Auch ist der Zusammenhang nun näherungsweise linear.

```
ols2 <- lm(lwage ~ educ)
summary(ols2)
```

```
##
## Call:
## lm(formula = lwage ~ educ)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.223 -0.367 -0.077  0.293  1.519
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.59188    0.09545     6.2   1.1e-09 ***
## educ         0.08243    0.00742    11.1   < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.471 on 523 degrees of freedom
## Multiple R-squared:  0.191, Adjusted R-squared:  0.189
## F-statistic: 123 on 1 and 523 DF, p-value: <2e-16
```

```
qqnorm(ols2$residuals); qqline(ols2$residuals)
```



```
shapiro.test(ols2$residuals)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data:  ols2$residuals  
## W = 0.981, p-value = 2.7e-06
```

Auch hier ist die Normalverteilungsannahme verletzt. Allerdings ist dies unproblematisch, da die Stichprobe hinreichend groß ist.

Für die Interpretation des Anstiegsparameters $\hat{\beta}_1$ müssen wir berücksichtigen, dass Y logarithmisch transformiert wurde, also $\log(\text{wage})$ die abhängige Variable ist. Der folgende Abschnitt betrachtet diesen wichtigen Punkt.

log-Transformation


In der Praxis liegen häufig **nicht-lineare Zusammenhänge** vor. Die lineare Einfachregression kann dann nicht angewendet werden. Durch eine geeignete Transformation lassen sich nicht-lineare Zusammenhänge aber häufig in lineare Zusammenhänge umwandeln. Das Konzept der linearen Einfachregression ist dann wieder anwendbar, allerdings ändert sich die Interpretation der Parameter des Regressionsmodells.

Exkurs: Logarithmus Als Logarithmus x einer Zahl y bezeichnet man den Exponenten, mit dem eine vorher festgelegte Zahl, die Basis, potenziert werden muss, um die gegebene Zahl y zu erhalten. Wird als Basis $e = 2.71828$, die Eulersche Zahl, gewählt, so erhält man den natürlichen Logarithmus.

$$y = e^x \Rightarrow x = \log_e y = \ln y$$

In R wird der natürliche Log durch `log()` berechnet.

```
x <- seq(0, 30, 0.1); y <- log(x)
plot(x, y, ylab = "log(x)", main = "natürlicher Logarithmus")
```



Offensichtlich ist der natürliche Log eine nicht-lineare Funktion. Daher kann der natürliche Log auch verwendet werden, um bestimmte nicht-lineare Zusammenhänge zu linearisieren. Weiterhin hat der natürliche Log eine nützliche Eigenschaft: die logarithmierte Differenz einer Variablen misst näherungsweise die relative Änderung der ursprünglichen Variable.

```
1.05/1 - 1          # Wachstumsrate = 5%
```

```
## [1] 0.05
```

```
log(1.05) - log(1)   # Differenz der Logs = ca. 5%
```

```
## [1] 0.04879
```

Ausgehend von einem linearen Modell $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ unterscheiden wir drei Arten der **log-Transformation**: (1) das log-linear Modell, (2) das linear-log Modell, und (3) das log-log Modell (vgl. folgende Tabelle).

Beim **log-linear Modell** (wie im Beispiel mit dem Stundenlohn) wird nur die abhängige Variable einer log-Transformation unterzogen:

$$\widehat{\log(y)} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Beim **linear-log Modell** wird nur die unabhängige Variable einer log-Transformation unterzogen:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \log(x)$$

Beim **log-log Modell** werden beide Variablen logarithmiert und es gibt einen linearen Zusammenhang zwischen den Logs:

$$\widehat{\log(y)} = \hat{\beta}_0 + \hat{\beta}_1 \log(x)$$

Das log-log Modell ist vor allem deshalb so wichtig, weil es zum **Schätzen von Elastizitäten** verwendet wird (vgl. unten).

Table 5: Interpretation des Anstiegsparameters $\hat{\beta}_1$

	x	$\log(x)$
$\hat{y}$	$\hat{\beta}_1 = d\hat{y}/dx$	$\hat{\beta}_1 = d\hat{y}/(dx/x)$
$\widehat{\log(y)}$	$\hat{\beta}_1 = (d\hat{y}/\hat{y})/dx$	$\hat{\beta}_1 = (d\hat{y}/\hat{y})/(dx/x)$

Interpretation:

linear: $\hat{\beta}_1 = d\hat{y}/dx \Rightarrow$ Wenn x um 1 Einheit steigt, steigt $\hat{y}$ um $\hat{\beta}_1$ Einheiten

log-linear: $\hat{\beta}_1 = (d\hat{y}/\hat{y})/dx \Rightarrow$ wenn x um 1 Einheit steigt, erhöht sich $\hat{y}$ um $\hat{\beta}_1 \cdot 100\%$

linear-log: $\hat{\beta}_1 = d\hat{y}/(dx/x) \Rightarrow$ wenn x um 1% steigt, erhöht sich $\hat{y}$ um $\hat{\beta}_1/100$ Einheiten

log-log: $\hat{\beta}_1 = (d\hat{y}/\hat{y})/(dx/x) \Rightarrow$ wenn x um 1% steigt, erhöht sich $\hat{y}$ um $\hat{\beta}_1\%$


Betrachten wir nochmal unser Beispiel mit **wage** und **educ**. Interpretation: Das Modell prognostiziert, dass ein Jahr mehr Bildung im Mittel den Stundenlohn um 8% erhöht. Der Anstiegsparameter $\hat{\beta}_1$ ist in diesem log-linear Modell also eine konstante relative Größe (eine sog. **Semi-Elastizität**)

Die Rücktransformation und grafische Darstellung im Plot für **educ** und **wage** erfolgt folgendermaßen:

```
log(2.718) # Der Log der Eulerschen Zahl e muss 1 sein
```

```
## [1] 0.9999
```

```
educ_ols <- seq(0, 18, 0.01)
wage_ols <- 2.718^(0.59188 + 0.08243*educ_ols)
plot(data$educ, data$wage, cex = 1.2, ylab = "Stundenlohn in USD", xlab = "Jahre in Bildung")
lines(educ_ols, wage_ols, lwd = 2, col = "red")
legend(0, 25, pch = c(1, NA), c("Beobachtungen", "Regressionsmodell (log-linear)"), lwd = c(NA, 2),
col = c("black", "red"), cex = 0.8)
```



Wir sehen in der Abbildung oben, dass ein konstanter relativer Anstieg (ca. +8% pro Jahr) zu einem absolut zunehmenden Effekt von `educ` auf `wage` führt. Wenn `educ` = 10, prognostiziert das Modell ca. 0.35 USD mehr Stundenlohn für ein zusätzliches Jahr Bildung (von 4.11 USD zu 4.46 USD, ca. +8.5%). Wenn `educ` = 15, prognostiziert das Modell ca. 0.53 USD mehr Stundenlohn (von 6.21 USD zu 6.74 USD, ca. +8.5%) für ein zusätzliches Jahr Bildung. Die Abweichungen zum Modell ergeben sich u.a. dadurch, dass wir runden und einen stetigen Zusammenhang diskret (+1 Jahr) interpretieren.

Wir betrachten nun das folgende Beispiel:

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("GDPpc_pm_live.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/GDPpc_pm_live.csv")
data[1:2, ]; attach(data); dim(data)
```

```
##   code GDPpc   pm  live
## 1  AFG  496.6 58.331 62.941
## 2  AGD 2189.9 24.599 63.051
```


```
## [1] 186  4
```

```
data <- subset(data, live > 40, ); attach(data); dim(data) # Hier ohne den Ausreißer
```

```
## [1] 185  4
```

Wir interessieren uns für die Variablen `GDPpc` (pro-Kopf GDP in USD) und `live` (Lebenserwartung bei Geburt in Jahre). Die Daten wurden von der Weltbank für 2019 erhoben (vollständig für 186 Länder).

```
plot(GDPpc/1000, live, xlab = "GDP p.c. in 1000 USD", ylab = "Lebenserwartung bei Geburt in Jahre",
     main = "GDP p.c. und Lebenserwartung")
```




Wie wir sehen, gibt es einen positiven Zusammenhang zwischen GDP p.c. und Lebenserwartung. Allerdings ist dieser positive Zusammenhang nicht linear. Für geringe GDP p.c. Werte führt ein höheres Einkommen zu drastischen Zugewinnen bei der Lebenserwartung, bei höheren GDP p.c. Werten sind die Zugewinne nur noch relativ klein.

Wenn wir GDP p.c. logarithmieren, ändert sich das Bild.

```
plot(log(GDPpc/1000), live, xlab = "log(GDP p.c. in 1000 USD)", ylab = "Lebenserwartung bei Geburt in J",
     main = "Linear-log Modell")
abline(lm(live ~ log(GDPpc/1000)))
```

Linear-log Modell



Es gibt einen relativ starken, positiven, linearen Zusammenhang zwischen $\log(\text{GDPpc}/1000)$ und live . Wir schätzen ein linear-log Modell.

```
ols <- lm(live ~ log(GDPpc/1000))
summary(ols)
```


```
##
## Call:
## lm(formula = live ~ log(GDPpc/1000))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -15.065  -1.656   0.531   2.839   7.519
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    64.474     0.480   134.3   <2e-16 ***
## log(GDPpc/1000)  4.403     0.201    21.9   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.95 on 183 degrees of freedom
## Multiple R-squared:  0.723, Adjusted R-squared:  0.722
## F-statistic: 478 on 1 and 183 DF, p-value: <2e-16
```

Das geschätzte Modell (linear-log) ist: $\widehat{\text{live}} = 64.5 + 4.4 * \log(\text{GDPpc}/1000)$. Der Anstiegsparemeter dieses

Modells ist folgendermaßen zu interpretieren: Eine Erhöhung des GDP p.c. um 1% führt gemäß Modellprognose zu einer um 0.044 Jahre höheren Lebenserwartung. Oder: Eine Erhöhung des GDP p.c. um 10% führt gemäß Modellprognose zu einer um ca. 0.44 Jahre höheren Lebenserwartung.

Wir betrachten nochmal die ursprünglichen Daten mit dem geschätzten Modell.

```
gdp <- seq(1, 200, 0.1)
le <- 64.5 + 4.4*log(gdp)
plot(GDPpc/1000, live, xlab = "GDP p.c. in 1000 USD",
     ylab = "Lebenserwartung bei Geburt in Jahre",
     main = "GDP p.c. und Lebenserwartung")
lines(gdp, le, lwd = 2, col = "red")
legend(100, 50, pch = c(1,NA), c("Beobachtungen", "Regressionsmodell (linear-log)"),
      lwd = c(NA,2), col = c("black", "red"), cex = 0.8)
```



Wir prüfen das Modell: Bei einem GDP p.c. von 5000 USD prognostiziert das Modell eine Lebenserwartung von 71.56 Jahre. Steigt das GDP p.c. auf 5500 USD (+10%), so prognostiziert das Modell eine Lebenserwartung von 71.98 (ein Plus von 0.42 Jahre). Auf eine Diskussion der Modellannahmen und der Ausreißer verzichten wir hier aus Platzgründen.

```
64.474 + 4.403*log(5); 64.474 + 4.403*log(5.5)
```

```
## [1] 71.56
```

```
## [1] 71.98
```

Um die Varianzzerlegung zu illustrieren, können auch die Varianzen ausgegeben lassen.

```
var(live); var(ols$residuals); var(ols$fitted.values)
```

```
## [1] 55.937
```

```
## [1] 15.489
```

```
## [1] 40.448
```

Wir betrachten abschließend das folgende Beispiel mit den Variablen P und Q :


```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("Elasticity.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/Elasticity.csv")
data[1:2, ]; attach(data)
```

```
##   P    Q
## 1 1 220.0
## 2 1 196.2
```

Die Menge Q wird in Mengeneinheiten (ME) angegeben, der Preis P in Euro. Ziel ist, eine Nachfragefunktion $Q(P)$ zu schätzen. Wir schätzen zunächst das lineare Modell $\hat{Q} = \hat{\beta}_0 + \hat{\beta}_1 P$.

```
plot(P, Q, xlab = "Preis P in Euro", ylab = "Menge Q in ME",
     main = "Lineares Modell", xlim = c(0, 10))
abline(lm(Q ~ P), lwd = 2)
```

Lineares Modell




```
ols3 <- lm(Q ~ P); ols3
```

```
##
## Call:
## lm(formula = Q ~ P)
##
## Coefficients:
## (Intercept)          P
##      172.3       -12.7
```

Steigt der Preis um 1 Euro, geht gemäß der Modellprognose im Mittel die Nachfrage um 12.7 ME zurück. Offensichtlich ist aber die Annahme eines linearen Zusammenhangs verletzt. Auch das Streudiagramm der Residuen und der vorhergesagten Werte zeigt, dass das Modell die Abhängigkeit zwischen P und Q nicht richtig abbildet.


```
plot(ols3$fitted.values, ols3$residuals)
abline(h = 0, lty = 2)
```



In diesem Plot ist eine deutliche Struktur erkennbar. Wir müssen die Daten geeignet transformieren, um den Zusammenhang zu linearisieren. Hier bietet sich die Transformation von X und Y mit dem natürlich Logarithmus (log) an.

Betrachten wir ein Beispiel für das log-log Modell $\widehat{\log(y)} = \hat{\beta}_0 + \hat{\beta}_1 \log(x)$. Wir nutzen die Daten für P und Q aus dem Datensatz oben:

```
plot(log(P), log(Q), xlab = "log(Preis P in Euro)", ylab = "log(Menge Q in ME)",
     main = "Log-log model", xlim = c(0, 2.5))
abline(lm(log(Q) ~ log(P)), lwd = 2)
```



In diesem Streudiagramm ist ein starker, negativer und linearer Zusammenhang zwischen den Logs zu erkennen.

Die Ausgabe der Modellparameter $\hat{\beta}_0$ und $\hat{\beta}_1$ erfolgt folgendermaßen:

```
ols4 <- lm(log(Q) ~ log(P)); summary(ols4)
```


```
##
## Call:
## lm(formula = log(Q) ~ log(P))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.08303 -0.04002  0.00443  0.04234  0.08360
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   5.3172     0.0113   470.5  <2e-16 ***
## log(P)       -0.5023     0.0068  -73.9  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## Residual standard error: 0.0473 on 98 degrees of freedom
## Multiple R-squared:  0.982, Adjusted R-squared:  0.982
## F-statistic: 5.46e+03 on 1 and 98 DF,  p-value: <2e-16
```

Der Anstiegsparameter im log-log Modell kann als konstante **Elastizität** interpretiert werden. Hier: Steigt der Preis um 1%, dann reduziert sich gemäß der Modellprognose die Menge um 0.5%. Es liegt eine unelastische Nachfrage vor. Analog erfolgt die Berechnung für Einkommenselastizitäten, Kreuzpreiselastizitäten usw.


Betrachten wir das Streudiagramm zwischen E und $\hat{Y}$.

```
plot(ols4$fitted.values, ols4$residuals)
abline(h = 0, lty = 2)
```



Die Verteilung der Werte ist relativ unauffällig (zumindest aber besser als vor der Transformation). Die Normalverteilungsannahme muss verworfen werden (die Stichprobe ist aber hinreichend groß, daher ist dies unproblematisch).

```
qqnorm(ols4$residuals)      # qq-Plot
qqline(ols4$residuals)     # mit Linie
```



```
shapiro.test(ols4$residuals)    # verwerfe Normalverteilung
```

```
##
##  Shapiro-Wilk normality test
##
## data:  ols4$residuals
## W = 0.949, p-value = 0.00076
```


```
cor(log(Q), log(P), method = "pearson")^2
```

```
## [1] 0.98238
```

Das R^2 ist relativ hoch mit 98%. Interpretation: Der natürliche Log von P kann 98% der Streuung des natürlichen Logs von Q erklären.

Die Rücktransformation und grafische Darstellung im Plot für P und Q erfolgt folgendermaßen:

```
P_ols <- seq(0, 10, 0.01)
Q_ols <- 2.718^(5.3 - 0.5*log(P_ols))
plot(P, Q, ylab = "Menge Q in ME", xlab = "Preis P in Euro")
lines(P_ols, Q_ols, lwd = 2, col = "red")
legend(5, 200, pch = c(1, NA), c("Beobachtungen", "Regressionsmodell (log-log)", lwd = c(NA, 2),
col = c("black", "red"), cex = 0.8)
```



Exkurs: Konfidenz- und Vorhersageintervalle

Unsere Schätzung der wahren Regressionsgeraden in der Grundgesamtheit basiert auf Stichprobeninformationen und ist daher unsicher. Wir können aber die Unsicherheit quantifizieren mit Hilfe von Intervallaussagen. Bei der Prognose von y -Werten durch eine Regression gilt es dabei zwei Fälle zu unterscheiden:

- 1) Man will den mittleren y -Wert prognostizieren. In diesem Fall spricht man von einem **Konfidenzintervall** (confidence interval).
- 2) Man will einen einzelnen y -Wert prognostizieren. In diesem Fall spricht man von einem **Vorhersageintervall** (prediction interval).

Ausgangspunkt ist ein Wert für die unabhängige Variable X , bezeichnet mit x_v . Das geschätzte lineare Modell prognostiziert für x_v den Wert $\hat{y}_v = \beta_0 + \beta_1 x_v$.

Die gemeinsame Formel für beide Intervalle ist:

$$(1 - \alpha)\text{-Intervall} = \hat{y}_v \pm t_{[1-\alpha]n-2}^* SE$$

Beide Intervalle sind also zentriert um $\hat{y}_v$ und unterscheiden sich demnach in ihren Standardfehlern (SE), also der Streuung der Werte.

Konfidenzintervall für den mittleren Wert Die Formel für das Konfidenzintervall für den mittleren Wert ist:

$$(1 - \alpha)\text{-Intervall} = \hat{y}_v \pm t_{[1-\alpha]n-2}^* SE$$

mit

$$SE(\hat{\mu}_v) = \sqrt{SE(\beta_1)^2(x_v - \bar{x})^2 + \frac{\hat{\sigma}_e^2}{n}}$$

Der Standardfehler, d.h. die Streuung des vorhergesagten mittleren Wertes, und damit die Breite des Konfidenzintervalls wird durch drei Größen beeinflusst:

- 1) Das KI wird breiter (unsere Schätzung wird also unsicherer), je weiter man sich vom mittleren x-Wert entfernt. Dies ist der Term $(x_v - \bar{x})^2$ in der Formel für den SE .
- 2) Wie alle KIs variiert die Breite des Intervalls auch mit der Zahl der Beobachtungen. Eine größeres n generiert ein schmaleres KI und damit eine präzisere Vorhersage.
- 3) Der Streuung der Beobachtung um die Regressionsgerade, gemessen durch $\hat{\sigma}_e$, beeinflusst ebenfalls die Breite des KI. Wenn es eine größere Streuung der Werte um die Regressionsgerade gibt, ist die Vorhersage unsicherer und unser KI breiter.

Vorhersageintervall für einen individuellen Wert Die Formel für das Vorhersageintervall für einen individuellen Wert ist:

$$(1 - \alpha)\text{-Intervall} = \hat{y}_v \pm t_{[1-\alpha]n-2}^* SE$$

mit

$$SE(\hat{y}_v) = \sqrt{SE(\beta_1)^2(x_v - \bar{x})^2 + \frac{\hat{\sigma}_e^2}{n} + \hat{\sigma}_e^2}$$

Die größere Streuung dieses Intervalls drückt sich dadurch aus, dass in der Summe der Varianzen (unter der Quadratwurzel) noch die Varianz der Residuen ($\hat{\sigma}_e^2$) hinzuaddiert wird.

Betrachten wir Bsp. 5.2 aus dem Lehrbuch.

```
setwd("C:/Users/sturm/Desktop/dataR") # setze das Arbeitsverzeichnis
data <- read.csv("Bsp._5.2.csv")
# data <- read.csv("https://raw.githubusercontent.com/bodosturm/dataR/main/Bsp._5.2.csv")
attach(data); names(data)
```

```
## [1] "output"      "totalcost"
```

```
ols <- lm(totalcost ~ output)
```

Die Ausgabe des 95%-Konfidenzintervalls für die Regressionsgerade erfolgt mit `predict()` und der Angabe `int = 'c'`.

```
predict(ols, int = "c")[1:3, ] # Gebe die ersten 3 Werte des KI aus.
```

```
##      fit    lwr    upr
## 1 23.508 21.469 25.547
## 2 24.400 22.705 26.095
## 3 25.293 23.894 26.691
```

Die Ausgabe des 95%-Vorhersageintervalls für die y-Beobachtungen erfolgt entsprechend mit `int = 'p'`.


```
predict(ols, int = "p")[1:3, ] # Gebe die ersten 3 Werte des Intervalls aus.
```

```
##      fit    lwr    upr
## 1 23.508 18.393 28.623
## 2 24.400 19.413 29.388
## 3 25.293 20.398 30.188
```

Das 95%-KI ist - wie zu erwarten - deutlich schmaler als das 95%-Vorhersageintervall.

Der Plot der Intervalle erfordert etwas Arbeit. Wir erstellen hierfür einen neuen data frame (also eine Datentabelle), in dem wir die Vorhersagen bzw. Bänder (untere und obere Grenzen) abspeichern. Dann nutzen wir mit `matlines()` einen neuen Befehl, der es gestattet, die Spalten einer Matrix gegen einen Vektor zu plotten (`lines()` kann nur Vektor gegen Vektor plotten).

```
pred.frame <- data.frame(output = 20:28) # Begrenze die Ausgabe
pc <- predict(ols, int = "c", newdata=pred.frame)
pp <- predict(ols, int = "p", newdata=pred.frame)
pred.out <- pred.frame$output
plot(output, totalcost, xlab = "output in units", ylab = "totalcosts in 1000 Euro",
      ylim = range(totalcost, pp))
matlines(pred.out, pc, lty = c(1,2,2), col = "black")
matlines(pred.out, pp, lty = c(1,3,3), col = "black")
legend(24, 22, lty = 2, "95% confidence")
legend(20, 35.5, lty = 3, "95% prediction")
```



In der Abbildung ist gut zu erkennen, dass das Vorhersageintervall für einen einzelnen Wert deutlich breiter ist als das Konfidenzintervall für den wahren Mittelwert. Das macht intuitiv Sinn: Es ist viel unsicherer ($\Leftrightarrow$ Breite des Intervalls) einen bestimmten y -Wert gegeben x vorherzusagen, als eine Prognose über die

Lage des wahren Mittelwerts $\bar{y}$ gegeben x zu treffen (hier greift der Zentrale Grenzwertsatz mit größerem n). Auch gut zu erkennen: Je weiter man sich vom arithmetischen Mittel von X entfernt, desto größer wird SE und damit auch das Intervall.

Inferenz für Korrelation

Wir betrachten hier den Pearson-Korrelationskoeffizienten für quantitative Daten und den Spearman-Rang-Korrelationskoeffizienten für qualitative Daten mit ordinaler Skalierung. Beide Korrelationskoeffizienten sind Maße für die Effektgröße ($\Leftrightarrow$ ökonomische Signifikanz). Hier wird jetzt untersucht, ob die Korrelation auch statistisch signifikant ist.

Pearson-Korrelation Es sei ρ die wahre aber unbekannte Korrelation in der Grundgesamtheit.

Wir testen:

$$H_0 : \rho = 0 \text{ vs. } H_A : \rho \neq 0$$

Der Korrelationskoeffizient r in einer Stichprobe ist die Realisation der Zufallsvariablen R .

Unter bestimmten Annahmen (den Annahmen der Einfachregression) gilt:

$$R\sqrt{\frac{n-2}{1-R^2}} \sim T_{df} \text{ mit } df = n - 2$$

und wir können diesen Term als Testvariable nutzen. Wir können dann die Realisation der Testvariablen, $r\sqrt{\frac{n-2}{1-r^2}}$, zur Berechnung eines p-values verwenden.

Eigentlich ist der Test auf Korrelation redundant, denn es gilt:

$$\beta_1 = r \frac{\sigma_Y}{\sigma_X}$$

Wenn wir also für β_1 testen, ist das schon der Test für ρ (also für die wahre Korrelation in der Grundgesamtheit). Dennoch testet man manchmal die Korrelation separat, wenn keine Regression benötigt wird.

Das Problem: Die Berechnung eines KI für Pearson's ρ ist etwas umständlicher als im Fall des KIs für den Mittelwert μ einer Grundgesamtheit. Dies liegt daran, dass ρ im Intervall $[-1,1]$ definiert ist. Liegt z.B. eine Korrelation 0.95 vor, so kann die Korrelation in der Grundgesamtheit nicht größer als 1 sein, aber durchaus deutlich kleiner als 0.9 und daher ist das Intervall für ρ nicht symmetrisch um r .

Basis für das KI ist die sog. "Fisher-Transformation".

$$z = \frac{1}{2} \ln\left(\frac{1+\rho}{1-\rho}\right) \text{ mit } \rho \text{ als Korrelation in der Grundgesamtheit}$$

Es gilt:

$$z \sim N(\mu, s)$$

mit

$$E(z) = \mu = \frac{1}{2} \ln\left(\frac{1+\rho}{1-\rho}\right)$$

mit ρ als Korrelation in der Grundgesamtheit, die mit r geschätzt wird, und

$$s(z) = \sqrt{\frac{1}{n-3}}$$

Wir können also einen z-Wert aus dem in der Stichprobe beobachteten r berechnen. Mit diesem z-Wert aus der Stichprobe kann dann das KI für den wahren aber unbekannten z-Wert in der Grundgesamtheit (z_{GG}) bestimmt werden mit

$$KI(1 - \alpha)_{z_{GG}} = z \pm z_{[1-\alpha/2]} s(z)$$

Die Grenzen des KI für z_{GG} können wiederum transformiert werden mit

$$z = \frac{1}{2} \ln\left(\frac{1+\rho}{1-\rho}\right) \Leftrightarrow e^{2z} = \frac{1+\rho}{1-\rho}$$

$$\Longleftrightarrow r = \frac{e^2 z - 1}{e^2 z + 1}$$

Betrachten wir das Beispiel 4.3 aus dem Lehrbuch.

```
gewicht <- c(60,76,60,75,66,65,78,75,87,72,90,82,92)
groesse <- c(170,172,175,176,177,180,180,183,185,187,188,190,194)
cor.test(gewicht, groesse, method = "pearson")
```

```
##
## Pearson's product-moment correlation
##
## data:  gewicht and groesse
## t = 3.9, df = 11, p-value = 0.0025
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.36381 0.92475
## sample estimates:
##      cor
## 0.76204
```

Die Berechnung per Hand ergibt:

```
n <- length(gewicht)
r <- cor(gewicht, groesse, method = "pearson"); r
```

```
## [1] 0.76204
```

```
t <- r*sqrt((n-2)/(1-r^2)); t
```

```
## [1] 3.9032
```

Das 95%-KI bestimmt sich über die Fisher-Transformation:

```
z <- 0.5*log((1+r)/(1-r)); z      # Fisher Transformation
```

```
## [1] 1.0011
```

```
s <- sqrt(1/(n-3)); s      # Standardabweichung von z
```

```
## [1] 0.31623
```

```
mu <- 0.5*log((1+r)/(1-r)); mu  # E(z)
```

```
## [1] 1.0011
```

```
CI_up_z <- z + qnorm(0.975)*s; CI_up_z      # upper limit in z
```

```
## [1] 1.6209
```

```
CI_low_z <- z - qnorm(0.975)*s; CI_low_z      # lower limit in z
```

```
## [1] 0.38128
```

```
e <- exp(1); e                                # Eulersche Zahl
```

```
## [1] 2.7183
```

```
CI_up <- (e^(2*CI_up_z) - 1)/(e^(2*CI_up_z) + 1); CI_up
```

```
## [1] 0.92475
```

```
CI_low <- (e^(2*CI_low_z) - 1)/(e^(2*CI_low_z) + 1); CI_low
```

```
## [1] 0.36381
```

Es geht zum Glück auch etwas einfacher:

```
library(mada) # Paket "mada" muss installiert sein
CIrho(0.7620432, n, level = 0.95)
```

```
##          rho    2.5 %  97.5 %
## [1,] 0.76204 0.36381 0.92475
```

Spearman-Rang-Korrelation Die Überlegungen oben zu Pearson gelten hier entsprechend. Es sei ρ_{Sp} die wahre aber unbekannte Spearman-Korrelation in der Grundgesamtheit.

Wir testen:

$H_0 : \rho^{Sp} = 0$ vs. $H_A : \rho^{Sp} \neq 0$

Wenn $n > 10$ gilt approximativ:

$R^{Sp} \sqrt{\frac{n-2}{1-(R^{Sp})^2}} \sim T_{df}$ mit $df = n - 2$

Der Korrelationskoeffizient r^{Sp} ist die Realisation der Zufallsvariablen R^{Sp} .

Wir können dann $r^{Sp} \sqrt{\frac{n-2}{1-(r^{Sp})^2}}$ zur Berechnung eines p-values nutzen.

Betrachten wir Beispiel 4.4 im Lehrbuch.

```
M <- c(1.3, 4, 5, 2.3, 1, 1.7, 1, 3, 3.7, 2.7, 2.0)
S <- c(2, 3.7, 3.3, 2.7, 1.3, 1, 1.7, 2.3, 3, 3, 4.0)
cor.test(M, S, method = "spearman", exact = FALSE)
```

```
##
## Spearman's rank correlation rho
##
## data: M and S
## S = 64.3, p-value = 0.015
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
## rho
## 0.70776
```

Die Prüfgröße S (berechnet über MW-U Test, vgl. Lehrbuch) wird hier nicht betrachtet.

```
r_Sp <- 0.7077626; r_Sp
```

```
## [1] 0.70776
```

```
n <- 11  
t <- r_Sp*sqrt((n-2)/(1-r_Sp^2)); t
```

```
## [1] 3.0056
```

```
p_value <- 2*(1 - pt(t, n-2)); p_value
```

```
## [1] 0.014822
```